HW3

2025-03-08

Data: BankChurners

Variables:

“Attrition_Flag”

“Customer_Age”

“Gender”

“Dependent_count”

“Education_Level”

“Income_Category”

“Months_on_book”

“Total_Relationship_Count”

“Months_Inactive_12_mon”

“Contacts_Count_12_mon”

“Credit_Limit”

“Avg_Utilization_Ratio”

แปลงค่า Non-Numeric

```
dim(bank)
```

```
## [1] 10127    24
```

```
table(bank$Attrition_Flag)
```

```
##
## Attrited Customer Existing Customer
##              1627              8500
```

Smote 75% (ไม่ 100% เพราะ ป้องกัน Overfitting)

```
library(performanceEstimation)
bank <- smote(Attrition_Flag~., data = bank, perc.over = 3.45, perc.under =
1.75)

dim(bank)
```

```
## [1] 15049    24
```

```
table(bank$Attrition_Flag)
```

```
##
## Attrited Customer Existing Customer
##              6508              8541
```

#Model 1 ##Logistic Regession with Monte Cross-Validation

```
avg_table
```

```
##                          Attrited Customer Existing Customer
## Pred Attrited Customer              962.95             542.05
## Pred Existing Customer              337.85            1167.15
```

```
avg_acc
```

```
## [1] 0.7076744
```

```
avg_pre
```

```
## [1] 0.6398339
```

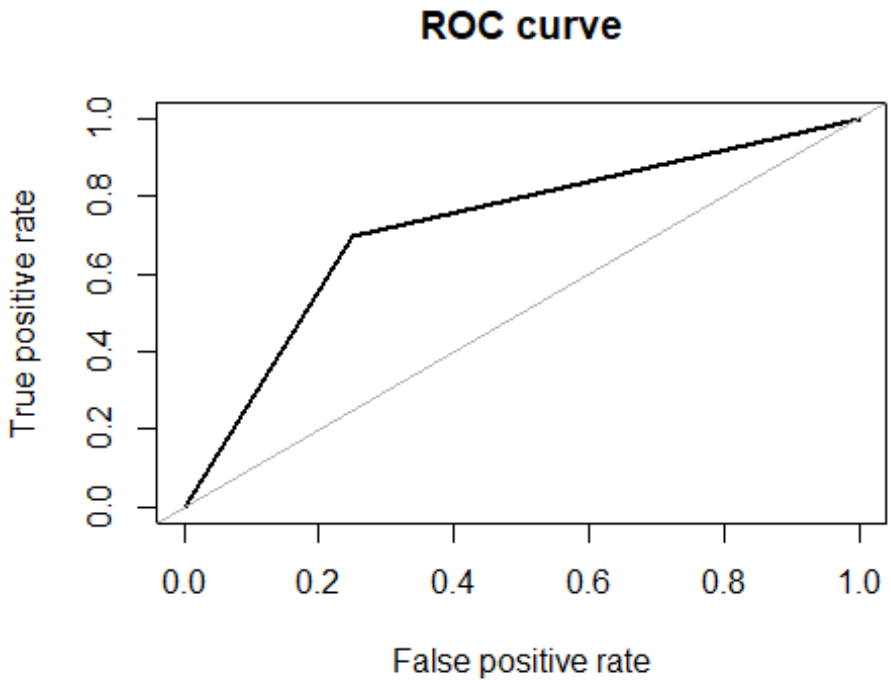
```
avg_rec
```

```
## [1] 0.7403409
```

```
avg_f1
```

```
## [1] 0.6863634
```

```
library(ROSE)
roc.curve(bank$Attrition_Flag[-train], pred)
```




```
## Area under the curve (AUC): 0.723
```

Model 2

เทียบ forward backward hybrid จาก rss

จำนวนตัวแปรที่ให้ ค่า rss น้อยสุด ของแต่ละ method

```
varia_select
```

```
##      Method     number of variable
## [1,] "Forward"  "23"
## [2,] "Backward" "23"
## [3,] "Hybrid"   "23"
```

เลือกใช้ hybrid method เพื่อความหยืดหยุ่นกับชุดข้อมูล

```
avg_hyb_table
```

```
##                         Attrited Customer Existing Customer
## Pred Attrited Customer              968.2              536.8
## Pred Existing Customer              336.4             1168.6
```

```
avg_hyb_acc
```

```
## [1] 0.7099003
```

```
avg_hyb_pre
```

```
## [1] 0.6433223
```

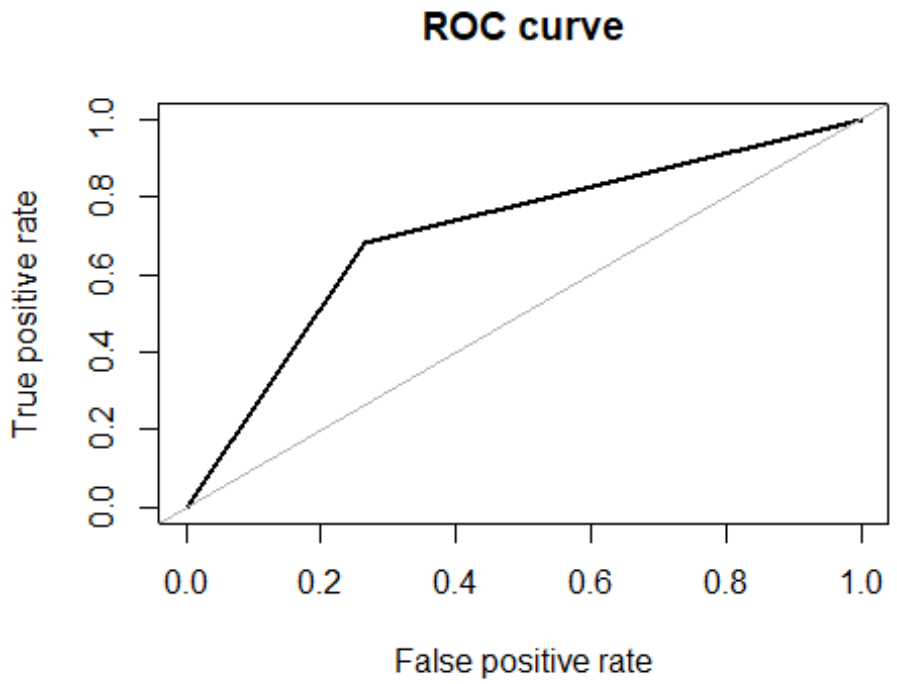
```
avg_hyb_rec
```

```
## [1] 0.7422032
```

```
avg_hyb_f1
```

```
## [1] 0.6891792
```

```
roc.curve(bank[-train,]$Attrition_Flag, hyb_pred)
```



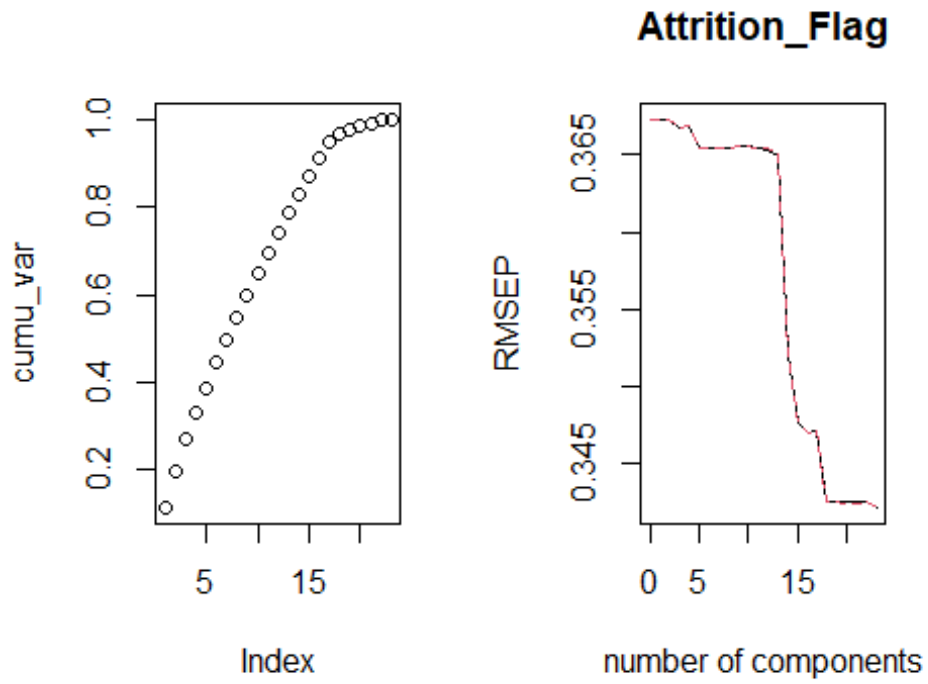

```
## Area under the curve (AUC): 0.707
```

Model 3

PCA

compare cumulative with cross-validation error

```
par(mfrow = c(1,2))
plot(cumu_var)
validationplot(pca_mod, val.type="RMSEP")
```




```
cumu_var[18]
```

```
## [1] 0.9669408
```

จากการพิจารณากราฟ จึงเลือก PCA 18

```
bank_pca <- data.frame(bank$Attrition_Flag, pca$x[,1:18])
bank_pca$bank.Attrition_Flag <- factor(bank_pca$bank.Attrition_Flag, levels =
c(0,1))

library(performanceEstimation)
bank_pca <- smote(bank.Attrition_Flag~., data = bank_pca, perc.over = 3.45,
perc.under = 1.75)

pca_mod <- glm(bank.Attrition_Flag~.,data = bank_pca, family = "binomial")

avg_pca_table
```

```
##                          Attrited Customer Existing Customer
## Pred Attrited Customer             980.65            524.40
## Pred Existing Customer             334.80           1170.15

avg_pca_acc

## [1] 0.7145515

avg_pca_pre
```

```
## [1] 0.6515731
```

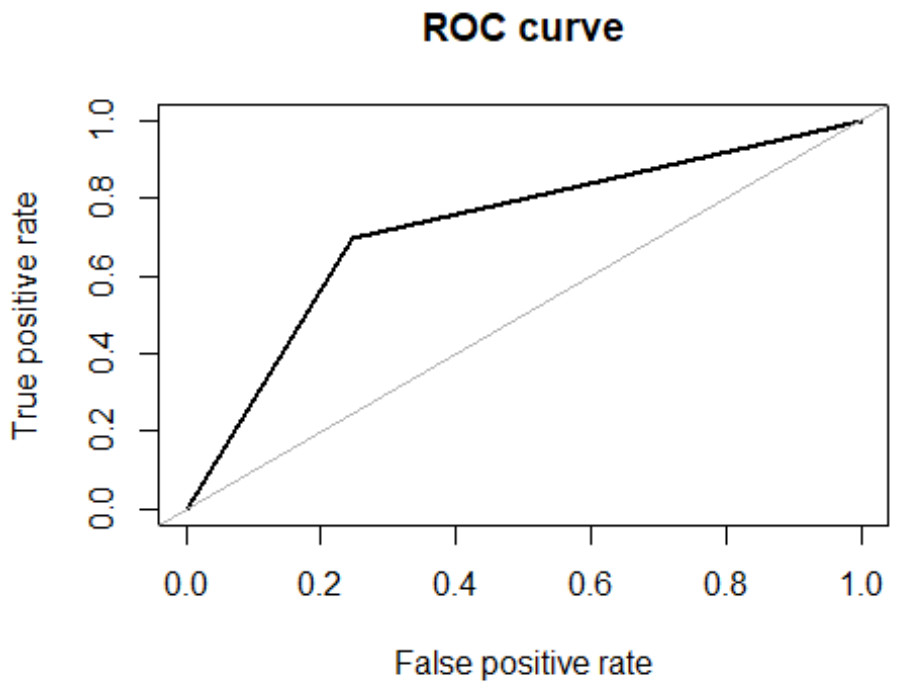
```
avg_pca_rec
```

```
## [1] 0.7455111
```

```
avg_pca_f1
```

```
## [1] 0.6953663
```

```
roc.curve(bank_pca[-train,]$bank.Attrition_Flag, pca_pred)$auc
```




```
## [1] 0.7251837
```

เปรียบเทียบ 3 model

```
compare_table
```

```
##             Model_1   Model_2   Model_3
## accuracy  0.7076744 0.7099003 0.7145515
## precision 0.6398339 0.6433223 0.6515731
## recall    0.7403409 0.7422032 0.7455111
## f1-score  0.6863634 0.6891792 0.6953663
## AUC       0.7228605 0.7072415 0.7251837
```

จากการที่ จุดประสงค์ในการสร้างตัวแบบ คือการ “หาลูกค้าที่ยกเลิกบัตร”
และจำเป็นต้องคำนึงถึงลูกค้าที่ยังคงเป็นลูกค้าบัตรอยู่ จึงใช้ AUC ทดสอบ ภาพรวมของ Model

จากการที่ Model_2 ให้ค่า AUC ที่มากที่สุด จึงจะนำ MOdel_2 มาพิจารณา

```
summary(hyb_mod)
```

```
##
## Call:
## glm(formula = Attrition_Flag ~ ., family = "binomial", data = bank[,
##     hyb_variable], subset = train)
##
## Coefficients:
##                                 Estimate Std. Error z value Pr(>|z|)
## (Intercept)                    6.197e-01  2.424e-01   2.556  0.01057 *
## Customer_Age                  -1.343e-02  4.625e-03  -2.903  0.00369 **
## GenderM                        6.787e-01  8.513e-02   7.973 1.55e-15 ***
## Dependent_count               -8.346e-02  1.764e-02  -4.732 2.22e-06 ***
## Education_LevelDoctorate      -2.207e-01  1.184e-01  -1.865  0.06222 .
## Education_LevelGraduate       -2.033e-02  7.832e-02  -0.260  0.79522
## Education_LevelHigh.School    -2.104e-02  8.326e-02  -0.253  0.80055
## Education_LevelPost.Graduate  -2.580e-01  1.150e-01  -2.244  0.02485 *
## Education_LevelUneducated     -1.162e-02  8.790e-02  -0.132  0.89483
## Education_LevelUnknown        -1.173e-01  8.792e-02  -1.334  0.18227
## Marital_StatusMarried         -9.213e-03  8.746e-02  -0.105  0.91611
## Marital_StatusSingle          -1.025e-01  8.791e-02  -1.165  0.24384
## Marital_StatusUnknown         -4.999e-02  1.138e-01  -0.439  0.66059
## Income_Category.40K....60K     7.964e-01  1.130e-01   7.049 1.81e-12 ***
## Income_Category.60K....80K     5.165e-01  9.977e-02   5.177 2.26e-07 ***
## Income_Category.80K....120K    8.950e-02  9.486e-02   0.944  0.34541
## Income_CategoryLess.than..40K  6.787e-01  1.248e-01   5.437 5.42e-08 ***
## Income_CategoryUnknown         8.923e-01  1.320e-01   6.761 1.37e-11 ***
## Months_on_book                 1.156e-02  4.629e-03   2.496  0.01255 *
## Total_Relationship_Count       3.319e-01  1.444e-02  22.983  < 2e-16 ***
## Months_Inactive_12_mon        -5.306e-01  2.441e-02 -21.742  < 2e-16 ***
## Contacts_Count_12_mon         -6.033e-01  2.216e-02 -27.230  < 2e-16 ***
## Credit_Limit                   4.937e-05  3.153e-06  15.658  < 2e-16 ***
## Avg_Utilization_Ratio          2.751e+00  9.475e-02  29.034  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 16466  on 12038  degrees of freedom
## Residual deviance: 13154  on 12015  degrees of freedom
## AIC: 13202
##
## Number of Fisher Scoring iterations: 4
```

จากผลของ Model ได้ว่า ตัวแปรที่เหมาะสมสำหรับ Model

GenderM

Education_LevelDoctorate

Education_LevelPost.Graduate

Income_Category.40K....60K

Income_Category.60K....80K

Income_CategoryLess.than..40K

Income_CategoryUnknown

Total_Relationship_Count ยิ่งมีสัมพันธ์ หรือพันธะกับธนาคารมาก ยิ่งส่งเสริม ให้เกิดข้อผูกมันกับทางธนาคารมาก เช่น เช่น สินเชื่อ, เงินฝาก, การลงทุน ทำให้เครดิตของการเป็นลูกค้าบัตรก็จะมีมาก

Months_Inactive_12_mon ลูกค้าลืม ไม่ใช้บัตรนาน เครดิตหมด

Contacts_Count_12_mon ลูกค้ามีปัญหาบ่อยกับธนาคาร

Credit_Limit วงเงินสูง อิสระทางการเงินของลูกค้ามีมาก ลูกค้าเกิดข้อผูกมัดกับธนาคารมาก ยิ่งใช้บัตรได้มากเท่าไหร่ ยิ่งมีเครดิตมากเท่านั้น และยิ่งเครดิตมีมาก สิทธิประโยชน์แก่เจ้าของบัตรก็จะมีมาก

Avg_Utilization_Ratio จ่ายยอดเกินวงเงินไม่ครบ ธนาคารไม่ปล่อย