# การวิเคราะห์ปัจจัยที่ส่งผลต่อคะแนนนักขับฟอร์มูล่าวันด้วยเทคนิคการเรียนรู้ด้วยเครื่อง

# Analyzing Factors Influencing Formula 1 Driver Scores Using Machine Learning

นายธนวินท์ แสงวิสุทธิ์ นายปิยพัทธ์ จันทร์ทวี นายศิรศักดิ์ คลังสมบูรณ์
ที่ปรึกษาโครงงาน ผศ. ดร. สุขุมาล สาริกะวณิช ที่ปรึกษาร่วม ดร.สุพัตรา วิริยะวิสุทธิสกุล
สาขาวิชา สถิติและวิทยาการข้อมูล ภาควิชา คณิตศาสตร์ คณะวิทยาศาสตร์ มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี

## บทคัดย่อ

งานวิจัยนี้มีวัตถุประสงค์เพื่อพัฒนาตัวแบบพยากรณ์การได้คะแนนของนักแข่ง Formula 1 (Top 10) ในรูปแบบ Binary Classification โดยใช้ข้อมูลช่วงปี ค.ศ. 2019–2024 จำนวน 2,559 รายการ จาก Ergast API, Open-Meteo และ Pirelli Motorsport ตัวแปรอธิบายประกอบด้วยข้อมูลสะสมของนักแข่งและทีม (เช่น Podium, คะแนนสะสม, DNF), ตำแหน่ง Grid และสภาพอากาศ โดยใช้เฉพาะข้อมูลก่อนการแข่งขันเพื่อป้องกัน Data Leakage นอกจากนี้ได้จัดกลุ่มสนามแข่ง 128 รายการด้วย Gower Distance และ Hierarchical Clustering ได้ 5 กลุ่ม เพื่อใช้เป็นตัวแปรเพิ่มเติม ตัวแบบ Random Forest และ XGBoost ถูกพัฒนาและประเมินด้วย Time Series Cross-Validation พบว่า XGBoost ให้ผลดีที่สุด โดยมีค่า ROC-AUC = 0.883, Accuracy = 0.81, Precision = 0.775, Recall = 0.875 และ F1-Score = 0.822 บนชุดทดสอบปี 2024 การวิเคราะห์ด้วย SHAP พบว่า ตำแหน่ง Grid มีอิทธิพลสูงสุด รองลงมาคือ ผลงานของทีมและนักแข่ง ขณะที่ตัวแปรสนามและสภาพอากาศมีอิทธิพลค่อนข้างต่ำ โดยสรุป ตัวแบบสามารถทำนายผลได้อย่างมีประสิทธิภาพ และชี้ให้เห็นว่าปัจจัยหลักของการได้คะแนนใน F1 คือศักยภาพของทีมและตำแหน่งออกตัวมากกว่าสภาพแวดล้อม

## คำนำ

การแข่งขันฟอร์มูล่าวัน (Formula 1: F1) เป็นกีฬาที่มีความซับซ้อนสูง โดยผลการแข่งขันไม่ได้ขึ้นอยู่กับทักษะของนักขับเพียงอย่างเดียว แต่ยังได้รับอิทธิพลจากหลายปัจจัย เช่น สมรรถนะของทีม ลักษณะของสนามแข่งขัน และสภาพอากาศ ในปัจจุบัน แม้ว่าจะมีการนำเทคนิค Machine Learning มาใช้ในการพยากรณ์ผลการแข่งขัน แต่ยังพบข้อจำกัดสำคัญในการนำ “ลักษณะของสนามแข่งขัน” มาใช้ในแบบจำลองอย่างเป็นระบบ รวมถึงการอธิบายผลลัพธ์ของตัวแบบที่มีความซับซ้อน ดังนั้น งานวิจัยนี้จึงมุ่งพัฒนาแบบจำลอง Machine Learning เพื่อทำนายการได้คะแนนของนักขับ (Top 10) โดยให้ความสำคัญกับ

- การจัดกลุ่มสนามแข่งขัน (Circuit Clustering)
- การใช้ Explainable AI (SHAP) เพื่ออธิบายผลลัพธ์

เพื่อเพิ่ม “ความแม่นยำ” และ “ความเข้าใจ” ของปัจจัยที่ส่งผลต่อผลการแข่งขัน

## ระเบียบวิธีการวิจัย

**Data Collection** รวบรวมข้อมูล F1 ปี 2019–2024 จาก Ergast API, Open-Meteo API และ Pirelli Motorsport

**Data Preprocessing** สร้างตัวแปรสะสมเชิงประสบการณ์ของนักแข่งและทีม โดยใช้เฉพาะข้อมูลก่อนการแข่งขันเพื่อป้องกัน Data Leakage

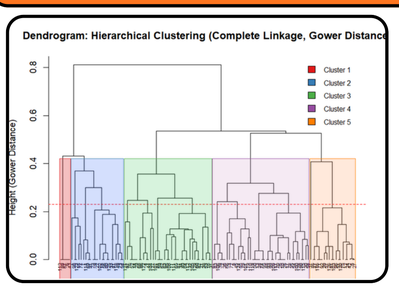
**Circuit Clustering** จัดกลุ่มสนามแข่งด้วย Gower Distance และ Hierarchical Clustering ได้ 5 กลุ่ม โดยใช้ Average Silhouette Width เป็นเกณฑ์ประกอบการตัดสินใจ โดยตัวแปรกลุ่มสนามที่ได้จะถูกนำไปใช้เป็นตัวแปรของตัวแบบการเรียนรู้ของเครื่อง

**Model Development** สร้างตัวแบบ Binary Classification ด้วย Random Forest และ XGBoost ปรับแต่ง Hyperparameter ด้วย Grid Search และ Time Series Cross-Validation แบบ Expanding Window 4 Fold โดยจะ train และ validate ด้วยข้อมูลปี 2019-2023 และ test ด้วยข้อมูลปี 2024

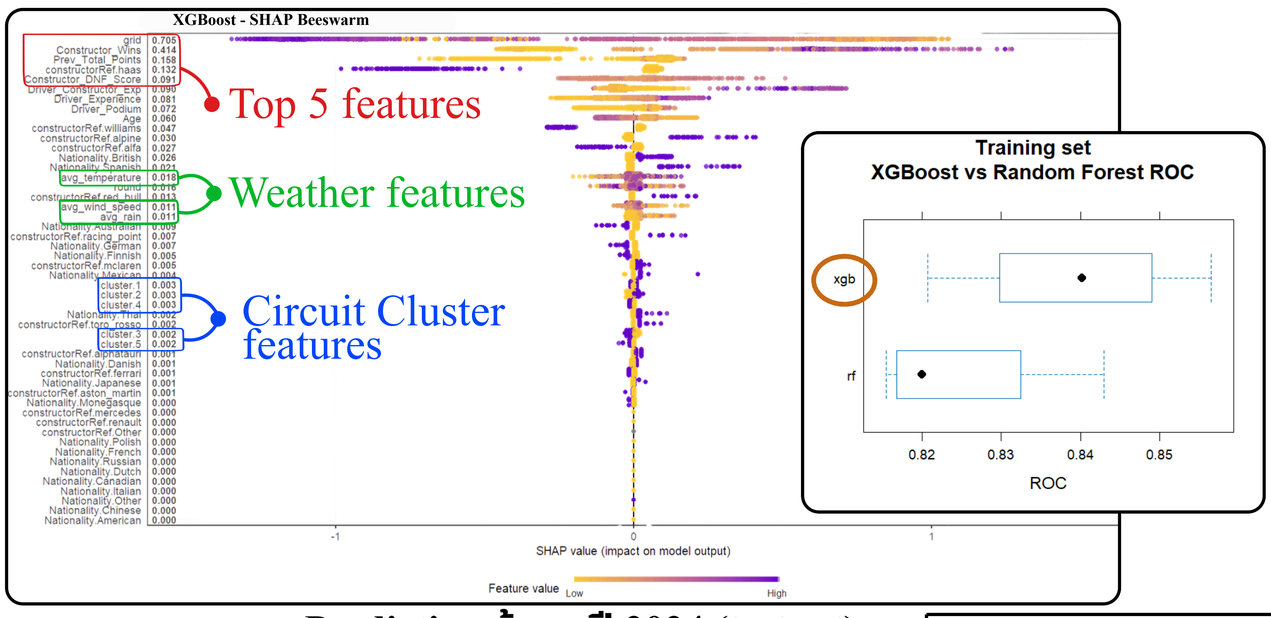
**Model Evaluation** ประเมินตัวแบบด้วย ROC-AUC, Accuracy, Precision, Recall และ F1-Score

**Model Interpretation** วิเคราะห์ความสำคัญของตัวแปรด้วย SHAP Values ทั้งภาพรวมและ Interaction Effects

## ผลวิจัย




**cluster1** (สนามแรงกดสูง)**:** 23 สนาม
**cluster2** (สนามความเร็วสูง-ยางสึกหนัก)**:** 42 สนาม
**cluster3** (สนามความเร็วสูง-แรงกดต่ำ): 38 สนาม
**cluster4** (สนามสั้น-ผิวหยาบ)**:** 20 สนาม
**cluster5** (สนาม “โมนาโก”)**:** 5 สนาม




**ผล Prediction ข้อมูลปี 2024 (test set)**

**Accuracy** = 0.810
**Precision** = 0.775
**Recall** = 0.875
**F1-Score** = 0.823
**AUC** = 0.823

| Prediction | Actual: *no_point* | Actual: *scored* |
|---|---|---|
| *no_point* | *178* | *30* |
| *scored* | *61* | *210* |

## บทสรุปและข้อเสนอแนะ

ผลการวิจัยพบว่า XGBoost มีประสิทธิภาพเหนือกว่า Random Forest ในทุกมิติ โดยให้ค่า AUC บนชุดทดสอบปี 2024 สูงถึง 0.8828 การวิเคราะห์ด้วยเทคนิค SHAP ระบุว่าปัจจัยที่ทรงอิทธิพลที่สุดคือ อันดับการออกตัว (Grid Position) และ ความแข็งแกร่งของทีม (Constructor Wins/Points) ซึ่งแปรผันตรงกับโอกาสการได้รับคะแนนอย่างมีนัยสำคัญ ในขณะที่สภาพอากาศและประเภทสนามมีอิทธิพลในระดับต่ำ สะท้อนว่าตำแน่งออกตัวเป็นตัวแปรชี้ขาดผลลัพธ์หลักก่อนเริ่มการแข่งขัน อย่างไรก็ตาม งานวิจัยมีข้อจำกัดด้านความแม่นยำของข้อมูลสภาพอากาศจาก API และการขาดปัจจัยด้านกลยุทธ์ เช่น การเลือกยางและเวลา Pit Stop ข้อเสนอแนะสำหรับการศึกษาในอนาคตจึงควรบูรณาการข้อมูลกลยุทธ์ดังกล่าวร่วมกับการพัฒนาระบบ Retraining เพื่อรองรับการเปลี่ยนแปลงของสมดุลการแข่งขันในแต่ละฤดูกาล

## กิตติกรรมประกาศ

คณะผู้จัดทำขอขอบพระคุณอาจารย์ที่ปรึกษาที่ให้คำแนะนำและชี้แนะแนวทางในการวิจัยเป็นอย่างดี ขอขอบคุณภาควิชาคณิตศาสตร์ คณะวิทยาศาสตร์ มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี ได้ให้ความรู้เป็นรากฐานในการดำเนินโครงงานนี้จนสำเร็จลุล่วง

## เอกสารอ้างอิง

Ergast Developer API. (2024). Motor racing data API [Dataset]. http://ergast.com/mrd/
Formula 1. (2023). Formula 1 official website. https://www.formula1.com
Pirelli Motorsport. (2023). Circuit guides and tyre information [Dataset]. https://www.pirelli.com/motorsport
van Kesteren, E.-J., & Bergkamp, T. (2023). Bayesian analysis of Formula One race results https://doi.org/10.1515/jqas-2022-0021