

การวิเคราะห์ปัจจัยที่ส่งผลต่อการได้คะแนนนักขับฟอร์มูล่าวัน ด้วยเทคนิคการเรียนรู้ของเครื่อง

นายธนวินท์ แสงวิสุทธิ์ 65090502414

นายปิยพัทธ์ จันทร์ทวี 65090502417

นายศิรศักดิ์ คลังสมบูรณ์ 65090502421

โครงงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร

ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาสถิติและวิทยาการข้อมูล

ภาควิชาคณิตศาสตร์ คณะวิทยาศาสตร์

มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี

ปีการศึกษา 2568



Analyzing Factors Influencing Formula 1 Driver Scores Using Machine Learning

MR.	THANAWIN	SANGVISUT	65090502414
MR.	PIYAPAT	JANTAWEE	65090502417
MR.	SIRASAK	KLANGSOMBOON	65090502421

A PROJECT SUBMITTED IN PARTIAL FULFILLMENT OF THE REQUIREMENT FOR

THE BACHELOR DEGREE OF SCIENCE (STATISTICS AND DATA SCIENCES)

DEPARTMENT OF MATHEMATICS FACULTY OF SCIENCE

KING MONGKUT'S UNIVERSITY OF TECHNOLOGY THONBURI

2025

การวิเคราะห์ปัจจัยที่ส่งผลต่อการได้คะแนนนักขับฟอร์มูล่าวัน ด้วยเทคนิคการเรียนรู้ของเครื่อง

นายธนวินท์ แสงวิสุทธิ์ วท.บ. (สถิติและวิทยาการข้อมูล)

นายปิยพัทธ์ จันทร์ทวี วท.บ. (สถิติและวิทยาการข้อมูล)

นายศิรศักดิ์ คลังสมบูรณ์ วท.บ. (สถิติและวิทยาการข้อมูล)

โครงงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร

ปริญญาวิทยาศาสตรบัณฑิต สาขาวิชาสถิติและวิทยาการข้อมูล

ภาควิชาคณิตศาสตร์ คณะวิทยาศาสตร์

มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี

ปีการศึกษา 2568

คณะกรรมการสอบปริญญานิพนธ์

..... กรรมการสอบและอาจารย์ที่ปรึกษาปริญญานิพนธ์

(ผศ.ดร.สุขุมาล สาริกะวณิช)

2026.06.04 11:23:50 +07'00'

..... กรรมการสอบและอาจารย์ที่ปรึกษาปริญญานิพนธ์(ร่วม)

(ผศ.ดร.สุพัตรา วิริยะวิสุทธิสกุล)

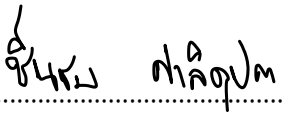
..... กรรมการ

(ผศ.ดร.ณภัทณ์จันทร์ ด่านสวัสดิ์)

..... กรรมการ

(ดร.พรทิพย์ เดชพิชัย)

คณะกรรมการสอบปริญญานิพนธ์



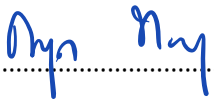
..... กรรมการ

(ผศ.ดร.ชื่นชม ศาลิคุปต)



..... กรรมการ

.(รศ.ดร.ณรรฐคุณ วิรุฬห์ศรี)



..... กรรมการ

(ผศ.ดร.ดาวุด ทองทา)

ลิขสิทธิ์ของมหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี

Analyzing Factors Influencing Formula 1 Driver Scores

Using Machine Learning

Mr. Thanawin Sangvisut B.Sc. (Statistics and Data Sciences)

Mr. Piyapat Jantawee B.Sc. (Statistics and Data Sciences)

Mr. Sirasak Klangsomboon B.Sc. (Statistics and Data Sciences)

A Project Submitted in Partial Fulfillment of the Requirements for

the Bachelor of Science (Statistics and Data Sciences)

Department of Mathematics, Faculty of Science

King Mongkut's University of Technology Thonburi

2025

Project Committee

..... Member and Project Advisor

(Asst. Prof. Sukuman Sarikavanij, Ph.D.)

2026.06.04 11:24:09 +07'00'

..... Member and Co- Project Advisor

(Asst. Prof. Supatta Viriyavisuthisakul,Ph.D.)

..... Member

(Asst. Prof. Napattchan Dansawad, Ph.D.)

..... Member

(Porntip Dechpichai, Ph.D.)

Project Committee

Chunchom Salikupata ..... Member

(Asst. Prof. Chunchom Salikupata, Ph.D.)

N. Wiroonsri ..... Member

(Assoc. Prof. Nathakhun Wiroonsri, Ph.D.)

Dawud Thongtha ..... Member

(Asst. Prof. Dawud Thongtha, Ph.D.)

Copyright reserved

หัวข้อโครงงานวิจัย	การวิเคราะห์ปัจจัยที่ส่งผลต่อการได้คะแนนนักขับฟอร์มูล่าวัน ด้วยเทคนิคการเรียนรู้ของเครื่อง
หน่วยกิต	2
ผู้เขียน	นายธนวินท์ แสงวิสุทธิ์ นายปิยพัทธ์ จันทร์ทวี นายศิรศักดิ์ คลังสมบูรณ์
อาจารย์ที่ปรึกษา	ผศ. ดร.สุขุมาล สาริกะวณิช ผศ. ดร.สุพัตรา วิริยะวิสุทธิสกุล
หลักสูตร	หลักสูตรวิทยาศาสตรบัณฑิต
สาขาวิชา	สถิติและวิทยาการข้อมูล
สายวิชา	คณิตศาสตร์
คณะ	วิทยาศาสตร์
ปีการศึกษา	2568

บทคัดย่อ

งานวิจัยนี้มีวัตถุประสงค์เพื่อพัฒนาตัวแบบพยากรณ์การได้คะแนนของนักขับฟอร์มูล่าวัน ในรูปแบบการจำแนกเชิงกลุ่มสองกลุ่ม โดยใช้ข้อมูลย้อนหลังระหว่างปี ค.ศ. 2019–2024 จำนวนทั้งสิ้น 2,559 รายการ ซึ่งรวบรวมจาก Ergast API, Open-Meteo และ Pirelli Motorsport ตัวแปรอิสระที่ใช้ประกอบด้วยข้อมูลพื้นฐานของนักขับและทีมผู้ผลิต ข้อมูลประสบการณ์และผลงาน ข้อมูลการแข่งขัน สภาพอากาศและบริบทการแข่งขัน คุณลักษณะทางกายภาพของสนามและคุณลักษณะทางเทคนิคของสนาม โดยคัดเลือกเฉพาะข้อมูลที่มีอยู่ก่อนการแข่งขันเพื่อป้องกันปัญหาการรั่วไหลของข้อมูล (Data Leakage) นอกจากนี้ งานวิจัยได้ประยุกต์ใช้การวัดระยะห่างแบบ Gower Distance และการวิเคราะห์ Hierarchical Clustering เพื่อจำแนกประเภทสนามแข่งจำนวน 128 รายการ ออกเป็น 5 กลุ่ม เพื่อใช้เป็นตัวแปรเพิ่มเติมในการพยากรณ์ จากการพัฒนาตัวแบบด้วยอัลกอริทึม Random Forest และ XGBoost ร่วมกับการประเมินผลด้วยวิธี Time Series Cross-Validation พบว่า XGBoost ให้ประสิทธิภาพสูงสุด โดยมีค่า ROC-AUC เท่ากับ 0.883, ความถูกต้อง (Accuracy) 0.810, ค่าความแม่นยำ (Precision) 0.775, ค่าความระลึก (Recall) 0.875 และ F1-Score 0.822 เมื่อทดสอบกับข้อมูลปี ค.ศ. 2024 ผลการวิเคราะห์ด้วยค่า SHAP (SHapley Additive exPlanations) บ่งชี้ว่าตำแหน่งออกตัวมีอิทธิพลต่อการได้คะแนนสูงสุด รองลงมาคือศักยภาพและผลงานย้อนหลังของทีมผู้ผลิตและนักขับ ในขณะที่ปัจจัยด้านประเภทสนามและสภาพอากาศมีอิทธิพลในระดับต่ำ สรุปได้ว่าตัวแบบที่พัฒนาขึ้นสามารถพยากรณ์ผลการแข่งขันได้อย่างมีประสิทธิภาพ และสะท้อนให้เห็นว่าปัจจัยหลักที่กำหนดผลแพ้ชนะในกีฬาฟอร์มูล่าวันคือสมรรถนะของทีมผู้ผลิตและตำแหน่งในการออกตัวเป็นสำคัญ

คำสำคัญ: การพยากรณ์การได้คะแนนของนักขับการจัดกลุ่มสนาม, การเรียนรู้ของเครื่อง, ค่าอธิบายเสริม แชปลีย์, ฟอร์มูล่าวัน

Research Project Title	Analyzing Factors Influencing Formula 1 Driver Scores Using Machine Learning
Research Project Credits	2
Candidate	Mr. Thanawin Sangvisut Mr. Piyapat Jantawee Mr. Sirasak Klangsomboon
Research Project Advisors	Asst. Prof. Sukuman Sarikavanij, Ph.D. Asst. Prof. Supatta Viriyavisuthisakul,Ph.D.
Program	Bachelor of Science
Field of Study	Statistics and Data Sciences
Department	Mathematics
Faculty	Science
Academic Year	2025

ABSTRACT

This research aims to develop a prediction model for Formula 1 drivers getting accumulated points in a binary classification format, using historical data between 2019–2024, totaling 2,559 records collected from Ergast API, Open-Meteo, and Pirelli Motorsport. The independent variables used consist of basic information of the drivers and teams, experience and performance data, race data, weather and race context, physical characteristics of the circuit, and technical characteristics of the circuit. Only data available before the race was selected to prevent the problem of data leakage. In addition, the research applied Gower Distance measurement and Hierarchical Clustering analysis to classify 128 race circuits into 5 groups to use as an additional variable in prediction. From developing the models with Random Forest and XGBoost algorithms, together with evaluation using the Time Series Cross-Validation method, it was found that XGBoost provided the highest performance, having an ROC-AUC value of 0.883, Accuracy 0.810, Precision 0.775, Recall 0.875, and F1-Score 0.822 when tested with the 2024 data. The analysis results using SHAP (SHapley Additive exPlanations) values indicate that the starting grid position has the highest influence on getting points, followed by the potential and past performance of the team and driver, while the factors of circuit type and weather have a low level of influence. It can be concluded that the developed model can predict race results efficiently, and reflects that the main factors determining winning and losing in Formula 1 sports are team performance and starting position.

Keywords: Circuit Clustering, Driver Points Prediction, Formula 1, Machine Learning, SHAP Values

กิตติกรรมประกาศ

ปริญญานิพนธ์ฉบับนี้สำเร็จลุล่วงได้ด้วยความกรุณาและความช่วยเหลืออย่างดียิ่งจากบุคคลหลายท่าน ผู้วิจัยขอกราบขอบพระคุณอย่างสูงแด่ ผู้ช่วยศาสตราจารย์ ดร.สุขุมาล สาริกะวณิช อาจารย์ที่ปรึกษาปริญญานิพนธ์หลัก และ ผู้ช่วยศาสตราจารย์ ดร.สุพัตรา วิริยะวิสุทธิสกุล อาจารย์ที่ปรึกษาปริญญานิพนธ์ร่วม ที่ได้กรุณาให้คำแนะนำ ตรวจสอบ และแก้ไขงานวิจัยด้วยความเอาใจใส่อย่างสม่ำเสมอตลอดระยะเวลาการศึกษา ขอกราบขอบพระคุณคณะกรรมการสอบปริญญานิพนธ์ทุกท่าน ได้แก่ ผู้ช่วยศาสตราจารย์ ดร.ณภัทณ์จันทร์ด่านสวัสดิ์ ดร.พรทิพย์ เดชพิชัย ผู้ช่วยศาสตราจารย์ ดร.ชื่นชม ศาลิคุปต รองศาสตราจารย์ ดร.ณรรฐคุณ วิรุฬห์ศรี และ ผู้ช่วยศาสตราจารย์ ดร.ดาวุด ทองทา ที่ได้สละเวลาอันมีค่าในการตรวจสอบปริญญานิพนธ์และให้ข้อเสนอแนะที่เป็นประโยชน์อย่างยิ่งต่อการพัฒนางานวิจัยฉบับนี้ให้มีความสมบูรณ์ยิ่งขึ้น ขอขอบพระคุณคณาจารย์ทุกท่านในหลักสูตรที่ได้ประสิทธิ์ประสาทวิชาความรู้และให้กำลังใจในการศึกษาตลอดมา รวมถึงเพื่อนร่วมรุ่นทุกท่านที่ให้ความช่วยเหลือและแลกเปลี่ยนความรู้ซึ่งกันและกันเป็นอย่างดี

ประโยชน์อันใดที่เกิดจากปริญญานิพนธ์นี้ ย่อมเป็นผลมาจากความกรุณาของท่านดังกล่าวข้างต้น ผู้วิจัยขอขอบพระคุณมา ณ โอกาสนี้

สารบัญ

	หน้า
บทคัดย่อภาษาไทย	**จ**
บทคัดย่อภาษาอังกฤษ	**ช**
กิตติกรรมประกาศ	**ฌ**
สารบัญ	**ญ**
รายการตาราง	**ฐ**
รายการรูปประกอบ	**ฑ**
บทที่	
1. บทนำ	**1**
1.1 ความสำคัญและที่มาของงานวิจัย	1
1.2 วัตถุประสงค์ของงานวิจัย	2
1.3 ประโยชน์และผลที่คาดว่าจะได้รับจากงานวิจัย	3
1.4 ขอบเขตงานวิจัย	3
1.5 ขั้นตอนการดำเนินงาน	4
2. เอกสารและงานวิจัยที่เกี่ยวข้อง	**5**
2.1 ความรู้เกี่ยวกับการแข่งขันฟอร์มูล่าวัน	5
2.2 การเรียนรู้ของเครื่อง	8
2.3 การแปลผลตัวแบบ	28
2.4 งานวิจัยที่เกี่ยวข้องกับการแข่งขันฟอร์มูล่าวัน	30

สารบัญ (ต่อ)

หน้า

บทที่

3. การดำเนินงานวิจัย 33

3.1 การรวบรวมข้อมูล 33

3.2 การเตรียมข้อมูล 34

3.3 ตัวแปรที่ใช้ในงานวิจัย 35

3.4 การวิเคราะห์ข้อมูลเบื้องต้น 39

3.5 การสร้างตัวแบบ 41

3.6 การเปรียบเทียบประสิทธิภาพของตัวแบบ 44

3.7 การแปลผลและการวิเคราะห์ปฏิสัมพันธ์ของตัวแปร 45

4. ผลการดำเนินงานวิจัยและการวิเคราะห์ข้อมูล **46**

4.1 ผลการวิเคราะห์ข้อมูลเชิงสำรวจ 46

4.2 ผลการจัดกลุ่มสนามแข่งขัน 48

4.3 การเปรียบเทียบตัวแบบ 52

4.4 การวิเคราะห์ปัจจัยสำคัญของตัวแบบ 55

4.5 การกำหนดรูปแบบตัวแบบพยากรณ์สำหรับการเปรียบเทียบ 57

5. สรุปผล อภิปรายผล และข้อเสนอแนะ **68**

5.1 สรุปผลการวิจัย 68

5.2 อภิปรายผล 69

5.3 ข้อจำกัดของงานวิจัย 71

สารบัญ (ต่อ)

หน้า

บทที่

5.4 ข้อเสนอแนะสำหรับการวิจัยในอนาคต 72

เอกสารอ้างอิง 74

รายการตาราง

หน้า

ตาราง

3.1 ตารางคุณลักษณะทางกายภาพของสนาม 35

3.2 ตารางคุณลักษณะทางเทคนิคของสนาม 36

3.3 ตารางตัวแปรตาม(y) 36

3.4 ตารางข้อมูลพื้นฐานของนักขับและทีมผู้ผลิต 37

3.5 ตารางข้อมูลประสบการณ์และผลงาน 37

3.6 ตารางข้อมูลสนามในรูปแบบกลุ่ม 38

3.7 ตารางข้อมูลการแข่งขัน 38

3.8 ตารางข้อมูลสภาพอากาศและบริบทการแข่งขัน 39

3.9 ตารางปรับแต่งพารามิเตอร์สำหรับ Random Forest 42

3.10 ตารางปรับแต่งพารามิเตอร์สำหรับ XGBoost 43

4.1 ตาราง Confusion Matrix ของตัวแบบ XGBoost บนชุดข้อมูลทดสอบ 53

4.2 ตารางประสิทธิภาพของตัวแบบ XGBoost บนชุดข้อมูลทดสอบ 53

4.3 ตารางเปรียบเทียบค่า ROC-AUC ระหว่างชุดฝึกฝนและชุดทดสอบ 54

4.4 ตารางสรุปการเลือกใช้กลุ่มตัวแปรในตัวแบบพยากรณ์แต่ละรูปแบบ 58

4.5 ตารางเปรียบเทียบประสิทธิภาพตัวแบบ 66

4.6 ตารางเปรียบเทียบค่า ROC-AUC ระหว่างตัวแบบ 67

รายการรูปประกอบ

หน้า

รูป

2.1 แผนภาพการทำงานของตัวแบบ Random Forest 23

2.2 แผนภาพการทำงานของตัวแบบ XGBoost 24

4.1 แผนภาพแสดงโครงสร้างข้อมูลตัวแปรเชิงปริมาณและเชิงลำดับ 47

4.2 แผนภาพแสดงโครงสร้างข้อมูลตัวแปรเชิงกลุ่ม 47

4.3 แผนภาพเดนโดรแกรมแสดงการจัดกลุ่มรายการแข่งขันด้วยวิธี Hierarchical Clustering (Complete Linkage) 48

4.4 กราฟ Silhouette Width แสดงการพิจารณาจำนวนกลุ่มที่เหมาะสม 49

4.5 Heatmap แสดงค่าเฉลี่ยและค่ามัธยฐานลักษณะสนามแข่งขันในแต่ละกลุ่ม 50

4.6 กราฟ Boxplot เปรียบเทียบค่า ROC ระหว่าง XGBoost และ Random Forest 52

4.7 กราฟ SHAP Bar Plot แสดงค่า Mean $|SHAP|$ ของ 15 ตัวแปรสำคัญสูงสุดในตัวแบบ 55

4.8 กราฟ SHAP Beeswarm แสดงทิศทางและขนาดผลกระทบของ 15 ตัวแปรสำคัญสูงสุดในตัวแบบ 56

4.9 กราฟ Boxplot เปรียบเทียบค่า CV ROC ระหว่างตัวแบบ M1 และตัวแบบ M2 59

4.10 กราฟ SHAP Beeswarm แสดงอิทธิพลของตัวแปรกลุ่มสนามและสภาพอากาศในตัวแบบ M1 60

4.11 กราฟ SHAP Beeswarm แสดงอิทธิพลของตัวแปรลักษณะสนามดิบและสภาพอากาศในตัวแบบ M2 61

รายการรูปประกอบ (ต่อ)

หน้า

รูป

4.14 SHAP Beeswarm แสดงอิทธิพลของตัวแปรลักษณะสนามดิบและสภาพอากาศในตัวแบบ M4 64

4.15 กราฟ Boxplot เปรียบเทียบค่า CV ROC ของตัวแบบทั้งหมด M1–M7 65

บทที่ 1 บทนำ

1.1 ความสำคัญและที่มาของงานวิจัย

การแข่งขันฟอร์มูล่าวัน (Formula 1: F1) เป็นการแข่งขันรถยนต์ทางเรียบระดับสูงสุดของโลก ซึ่งจัดขึ้นภายใต้การกำกับดูแลของสหพันธ์ยานยนต์นานาชาติ (Fédération Internationale de l'Automobile: FIA) และได้รับการยอมรับว่าเป็นหนึ่งในกีฬายานยนต์ที่มีชื่อเสียงและได้รับความนิยมอย่างแพร่หลาย (Formula 1, 2023). การแข่งขันฟอร์มูล่าวัน ไม่ได้เป็นเพียงการทดสอบทักษะการขับขี่ในระดับสูง แต่ยังเป็นเวทีแห่งนวัตกรรมที่ผสานเทคโนโลยีวิศวกรรมยานยนต์ขั้นสูงเข้ากับกลยุทธ์การแข่งขันที่ซับซ้อนอย่างลงตัว (Williams Racing, 2023)

เป้าหมายสูงสุดของการแข่งขันคือการสะสมคะแนนเพื่อชิงตำแหน่งแชมป์โลกประเภทนักขับ และประเภททีมผู้ผลิต โดยในแต่ละสนามแข่งขัน นักขับที่เข้าเส้นชัยใน 10 อันดับแรกจะได้รับคะแนนตามลำดับดังนี้ 25, 18, 15, 12, 10, 8, 6, 4, 2 และ 1 คะแนน นอกจากนี้ยังมีการมอบคะแนนพิเศษ 1 คะแนนให้แก่นักขับที่ทำเวลาต่อรอบได้เร็วที่สุด (Fastest Lap) โดยมีเงื่อนไขว่าต้องจบการแข่งขันใน 10 อันดับแรกด้วย ระบบการให้คะแนนนี้ทำให้ทุกตำแหน่งมีความหมายและผลักดันให้เกิดการแข่งขันที่เข้มข้นตลอดทั้งฤดูกาล (Formula 1, 2023)

ผลลัพธ์การแข่งขันในแต่ละสนามแข่งขันมีความซับซ้อนสูงและไม่ได้ขึ้นอยู่กับสมรรถนะของรถแต่เพียงอย่างเดียว แต่เป็นผลจากปฏิสัมพันธ์ของปัจจัยหลากหลายมิติ ไม่ว่าจะเป็นปัจจัยด้านเทคนิคของรถแข่ง เช่น การออกแบบตามหลักอากาศพลศาสตร์ (Aerodynamics) ประสิทธิภาพของระบบขับเคลื่อนไฮบริดและระบบกู้คืนพลังงาน (Energy Recovery System) ปัจจัยด้านกลยุทธ์ของทีม เช่น การเลือกใช้ยางและการวางแผนเข้าจุดพัก (Pit Stop) ทักษะและความสามารถของนักขับในการควบคุมรถภายใต้แรง G สูงตลอดจนปัจจัยภายนอกที่ไม่สามารถควบคุมได้อย่างสมบูรณ์ เช่น คุณลักษณะเฉพาะของสนามแข่งขันแต่ละแห่งและสภาพอากาศที่เปลี่ยนแปลงตลอดเวลา (Choi, 2025; Daly, 2019)

ด้วยความซับซ้อนดังกล่าว การวิเคราะห์เพื่อทำความเข้าใจและทำนายผลการแข่งขันจึงมีความท้าทายสูง ในปัจจุบันได้มีการนำเทคนิคการเรียนรู้ของเครื่อง(Machine Learning: ML) มาประยุกต์ใช้เพื่อวิเคราะห์ข้อมูลการแข่งขันจำนวนมาก อย่างไรก็ตาม ตัวแบบ ML ที่มีประสิทธิภาพสูงหลายชนิดเช่น Random Forest หรือตัวแบบอย่าง Deep Neural Networks (DNN) ซึ่งเป็นส่วนหนึ่งของ Deep Learning มักมีลักษณะเป็น "กล่องดำ" (Black Box) ซึ่งแม้จะให้ผลการทำนายที่แม่นยำ แต่กลับไม่สามารถอธิบายเหตุผล

เบื้องหลังการตัดสินใจได้อย่างโปร่งใส ทำให้ยากต่อการทำความเข้าใจว่าปัจจัยใดมีอิทธิพลต่อผลลัพธ์มากน้อยเพียงใด (Breiman, 2001; El Haber et al., 2021) เพื่อแก้ไขข้อจำกัดนี้ เทคนิคในกลุ่มปัญญาประดิษฐ์ที่สามารถอธิบายได้ (Explainable AI: XAI) และ SHAP SHapley Additive exPlanations (SHAP) จึงเข้ามามีบทบาทสำคัญในการเพิ่มความโปร่งใส โดยช่วยให้สามารถวัดระดับและตีความอิทธิพลของแต่ละปัจจัยที่มีต่อผลการทำนายของตัวแบบได้ (Lundberg & Lee, 2017)

แม้จะมีความพยายามในการสร้างตัวแบบเพื่อทำนายผลการแข่งขัน แต่จากภาพรวมของงานวิจัยที่ผ่านมา (El Haber et al., 2021; Zhao, 2024) พบว่ายังคงมีช่องว่างความรู้ที่สำคัญในการบูรณาการและวิเคราะห์คุณลักษณะเฉพาะของสนามแข่งขันอย่างเป็นระบบ สนามแต่ละแห่งมีลักษณะทางกายภาพที่แตกต่างกันอย่างมีนัยสำคัญ เช่น รูปแบบของโค้ง ทางตรง ระดับแรงเหวี่ยง หรือสภาพพื้นผิว ซึ่งปัจจัยเหล่านี้ส่งผลโดยตรงต่อกลยุทธ์การแข่งขันและสมรรถนะของรถและนักขับที่แตกต่างกันออกไป (Rockerbie, 2021; Choi, 2025) ดังนั้น การศึกษาที่ขาดการวิเคราะห์อย่างละเอียดในมิติของสนามแข่งขันอาจทำให้ตัวแบบขาดความสามารถในการอธิบายความแปรผันของผลลัพธ์ระหว่างสนามได้อย่างสมบูรณ์ งานวิจัยฉบับนี้จึงมุ่งที่จะเติมเต็มช่องว่างดังกล่าว โดยการวิเคราะห์คุณลักษณะของสนามแข่งขันเพื่อจัดกลุ่มและพัฒนาตัวแบบการเรียนรู้ของเครื่องที่สามารถพยากรณ์ผลคะแนนได้อย่างแม่นยำ พร้อมทั้งใช้เทคนิค Explainable AI เพื่ออธิบายปัจจัยสำคัญที่ส่งผลต่อการได้คะแนนของผู้ขับขี่ในบริบทของกลุ่มสนามที่แตกต่างกัน ซึ่งจะนำไปสู่ความเข้าใจในพลวัตของการแข่งขันฟอร์มูล่า ที่ชัดเจนและครอบคลุมมากยิ่งขึ้น

1.2 วัตถุประสงค์ของงานวิจัย

1) เพื่อจำแนกและจัดกลุ่มสนามแข่งขันฟอร์มูล่าวันตามลักษณะเฉพาะของสนามแข่งขัน

2) เพื่อเปรียบเทียบประสิทธิภาพของตัวแบบการพยากรณ์การได้คะแนนของนักขับในแต่ละรอบการแข่งขัน

3) เพื่อวิเคราะห์และอธิบายความสำคัญของปัจจัยต่าง ๆ ที่ส่งผลต่อการได้คะแนนของนักขับ

1.3 ประโยชน์และผลที่คาดว่าจะได้รับจากงานวิจัย

1) ได้ตัวแบบการพยากรณ์คะแนนนักขับที่มีประสิทธิภาพและความแม่นยำ

2) สามารถเข้าใจและระบุปัจจัยสำคัญที่มีอิทธิพลต่อคะแนนของนักขับ

3) เป็นข้อมูลที่ช่วยเสริมประสิทธิภาพในการวางแผนและตัดสินใจเชิงกลยุทธ์ของทีมแข่งภายใต้เงื่อนไขการแข่งขันที่หลากหลาย

1.4 ขอบเขตงานวิจัย

1.4.1 ขอบเขตด้านข้อมูล (Data Scope)

โครงงานนี้อ้างอิงข้อมูลการแข่งขันฟอร์มูล่าวัน (Formula 1) ในช่วงฤดูกาลปี ค.ศ. 2019 ถึง ค.ศ. 2024 โดยรวบรวมจากแหล่งข้อมูลสำคัญ 3 แหล่ง รวมเป็นชุดข้อมูลย่อยจำนวน 16 ชุด ดังนี้

1) Ergast Developer API แหล่งข้อมูลหลักสำหรับผลการแข่งขัน จำนวน 14 ชุดข้อมูล

2) Pirelli Motorsport แหล่งข้อมูลเชิงลึกเกี่ยวกับยางและสนามแข่ง ซึ่งเป็นผู้จัดจำหน่ายยางอย่างเป็นทางการของการแข่งขันฟอร์มูล่าวัน จำนวน 1 ชุดข้อมูล

3) Open-Meteo API แหล่งข้อมูลอุตุนิยมวิทยาในวันแข่งขัน ณ สถานที่ตั้งของสนามแข่ง จำนวน 1 ชุดข้อมูล

โดยเมื่อนำชุดข้อมูลทั้ง 16 ชุดมาบูรณาการร่วมกัน จะได้ ชุดข้อมูลหลัก (Master Dataset) ที่มีจำนวนตัวอย่างรวมทั้งสิ้น 2,559 ตัวอย่าง สำหรับใช้ในการวิเคราะห์และสร้างตัวแบบต่อไป

1.4.2 ขอบเขตตัวแบบพยากรณ์ (Model Scope)

1) **Random Forest** ใช้สำหรับการจำแนกหรือทำนายผล ด้วยการสร้างกลุ่มของต้นไม้ตัดสินใจหลายต้น (Ensemble Learning) เพื่อเพิ่มความแม่นยำ ลดความลำเอียงของตัวแบบ และลดปัญหา Overfitting
2) **XGBoost (Extreme Gradient Boosting)** ใช้สำหรับการทำนายหรือจำแนกข้อมูลโดยอาศัยการ Boosting แบบเพิ่มประสิทธิภาพ ซึ่งช่วยให้สามารถเรียนรู้ความสัมพันธ์ที่ซับซ้อนของข้อมูลได้ดียิ่งขึ้น และปรับปรุงผลลัพธ์ด้วยการลดความคลาดเคลื่อนแบบลำดับขั้น

1.5 ขั้นตอนการดำเนินงาน

1) รวบรวมและจัดเตรียมข้อมูล

2) วิเคราะห์ข้อมูลเบื้องต้นและจัดกลุ่มสนาม

3) สร้างและประเมินตัวแบบ

4) สรุปและอภิปรายผล

บทที่ 2 เอกสารและงานวิจัยที่เกี่ยวข้อง

2.1 ความรู้เกี่ยวกับการแข่งขันฟอร์มูล่าวัน

2.1.1 การนับคะแนนและการตัดสินการแข่งขันฟอร์มูล่าวัน

การแข่งขันฟอร์มูล่าวัน (Formula 1) ถือเป็นการแข่งขันยานยนต์ทางเรียบระดับสูงสุดที่มีมาตรฐานสากล โดยมีระเบียบข้อบังคับและระบบการตัดสินผลการแข่งขันที่ชัดเจน (Formula 1, 2023) โครงสร้างของการแข่งขันประกอบด้วยทีมผู้ผลิต จำนวน 10 ทีม โดยแต่ละทีมจะส่งนักขับ (Drivers) ลงแข่งขันทีมละ 2 คน รวมจำนวนนักขับทั้งสิ้น 20 คนต่อฤดูกาลการแข่งขันจะดำเนินการตามปฏิทินการแข่งขัน (Race Calendar) ซึ่งจัดขึ้นในสนามที่มีลักษณะทางกายภาพแตกต่างกันกระจายอยู่ทั่วโลก ทั้งในทวีปยุโรป เอเชีย และอเมริกา รูปแบบการแข่งขันในแต่ละสนาม แบ่งออกเป็น รอบคัดเลือกซึ่งมีวัตถุประสงค์เพื่อจัดลำดับตำแหน่งการออกตัวและ รอบการแข่งขันจริง เพื่อตัดสินผู้ชนะและจัดสรรคะแนนสะสม โดยระบบการนับคะแนนจะพิจารณาจากลำดับการเข้าเส้นชัยเป็นหลัก ผู้ชนะอันดับที่ 1 จะได้รับ 25 คะแนน และคะแนนจะลดหลั่นลงมาตามลำดับจนถึงอันดับที่ 10 (ได้รับ 1 คะแนน) นอกจากนี้ ยังมีการให้คะแนนพิเศษสำหรับนักขับที่ทำเวลาต่อรอบได้เร็วที่สุด ภายใต้เงื่อนไขที่กำหนด ในด้านการกำกับดูแลและการตัดสิน คณะกรรมการจัดการแข่งขันมีหน้าที่พิจารณาความถูกต้องตามกฎระเบียบด้านความปลอดภัยและความยุติธรรมโดยตรวจสอบการกระทำผิดกติกาต่าง ๆ เช่น การปะทะกัน การขับขี่ออกนอกขอบเขตสนามหรือการละเมิดข้อกำหนดทางเทคนิค ซึ่งหากตรวจพบความผิดปกติจะมีการลงโทษตามเกณฑ์ที่สหพันธ์ยานยนต์นานาชาติกำหนดไว้

2.1.2 ปัจจัยที่มีผลต่อการแข่งขันฟอร์มูล่าวัน

การแข่งขันฟอร์มูล่าวัน ไม่ใช่เพียงเรื่องของความเร็ว แต่ยังขึ้นอยู่กับปัจจัยหลายประการ ซึ่งแต่ละปัจจัยสามารถกำหนดผลลัพธ์ของการแข่งขันได้ ปัจจัยดังกล่าวประกอบด้วย

1) นักขับ

นักขับถือเป็นองค์ประกอบหลักที่มีความสำคัญยิ่งต่อการแข่งขัน ประสบการณ์และความเชี่ยวชาญของนักขับส่งผลโดยตรงต่อความสามารถในการควบคุมยานยนต์และการตัดสินใจเชิงกลยุทธ์ภายใต้สภาวะความกดดันสูง นอกจากปัจจัยด้านอายุที่สัมพันธ์กับปฏิกิริยาตอบสนองแล้ว สภาพความพร้อมทางร่างกายและจิตวิทยายังเป็นตัวแปรสำคัญที่กำหนดประสิทธิภาพในการขับขี่ งานวิจัยในอดีตบ่งชี้ว่า ทักษะเฉพาะตัว ประวัติผลงาน และพื้นฐานการฝึกซ้อม ล้วนส่งผลต่อรูปแบบการขับขี่และความยืดหยุ่นในการปรับตัวเข้ากับสนามแข่งขันที่แตกต่างกัน อย่างไรก็ตาม ประสิทธิผลของนักขับนั้นไม่สามารถแยกขาดจากสมรรถนะของรถและกลยุทธ์ของทีมได้ โดยต้องอาศัยการทำงานประสานกันอย่างลงตัวจึงจะเกิดผลลัพธ์ที่ดีที่สุด (van Kesteren & Bergkamp, 2022; Rane, 2025; Rockerbie, 2021)

2) ทีมผู้ผลิต

บทบาทของทีมผู้ผลิตถือเป็นปัจจัยที่มีน้ำหนักทางสถิติอย่างมีนัยสำคัญ จากการศึกษาด้วยวิธีวิเคราะห์แบบเบย์ (Bayesian Analysis) ในงานวิจัยของ van Kesteren & Bergkamp (2022) พบว่าความแปรปรวนของผลการแข่งขันกว่าร้อยละ 88 เกิดจากประสิทธิภาพของทีมและเทคโนโลยีของตัวรถ สอดคล้องกับ Rane (2025) ที่วิเคราะห์ผลการแข่งขันในช่วงยุคเครื่องยนต์ไฮบริด (2014–2024) และพบว่าปัจจัยด้านทีมสามารถอธิบายความสำเร็จได้ถึงร้อยละ 64 นอกจากนี้ Rockerbie (2021) ยังยืนยันว่าเทคโนโลยีวิศวกรรมและการบริหารจัดการของทีมมีอิทธิพลเหนือกว่าทักษะนักขับในหลายมิติ ทีมที่มีศักยภาพสูงมักมีความเป็นเลิศในการวางแผนกลยุทธ์ การปรับแต่งสมรรถนะรถ ให้สอดคล้องกับกายภาพของสนาม การบริหารจัดการยาง และการบำรุงรักษา ซึ่งช่วยลดความเสี่ยงจากปัจจัยที่ไม่คาดคิดและส่งเสริมให้นักขับสามารถแสดงศักยภาพได้สูงสุด

3) สนามแข่งขัน

ปัจจัยด้านลักษณะทางกายภาพของสนามแข่งขัน (Circuit Characteristics) ถือเป็นตัวแปรอิสระที่มีความสำคัญยิ่งต่อผลสัมฤทธิ์ในการแข่งขัน เนื่องจากความหลากหลายทางโครงสร้างวิศวกรรมและสภาพแวดล้อมของแต่ละสนาม เช่น ระยะทางต่อรอบ, รูปแบบความซับซ้อนของโค้ง, ระดับความลาด

ชันและลักษณะผิวสนาม ล้วนเป็นตัวกำหนดพฤติกรรมทางพลศาสตร์ของยานยนต์ในทุกช่วงของการขับขี่ ปัจจัยเหล่านี้ส่งผลโดยตรงต่อความเร็วเฉลี่ย ประสิทธิภาพในการควบคุมรถ โอกาสในการเร่งแซง ตลอดจนการกำหนดกลยุทธ์ทางเทคนิคที่สำคัญ เช่น การปรับแต่งสมรรถนะรถ การบริหารจัดการยาง และการวางแผนจังหวะการเข้าจุดพัก จากการศึกษาของ de Groote (2021) ซึ่งวิเคราะห์ลักษณะสนามแข่งขันในยุคการใช้ยาง Pirelli พบว่า สนามที่มีลักษณะทางกายภาพซับซ้อน ประกอบด้วยโค้งต่อเนื่องหรือมีการเปลี่ยนทิศทางด้วยความเร็วสูง เช่น สนามแข่ง ซุซุกะ และ สนามแข่ง เจดดาห์ คอร์นิช จำเป็นต้องอาศัยทักษะการควบคุมขั้นสูงจากนักขับ ควบคู่ไปกับสมรรถนะด้านอากาศพลศาสตร์ของตัวรถเพื่อรักษาเสถียรภาพ การแข่งขันในสนามลักษณะนี้จึงถูกกำหนดด้วยความแม่นยำในการขับขี่และการลดข้อผิดพลาดสำคัญ สอดคล้องกับงานวิจัยของ García Tejada (2023) ซึ่งประยุกต์ใช้วิธีการเรียนรู้ของเครื่องในการวิเคราะห์กลยุทธ์การเข้าจุดพัก พบว่า ปัจจัยด้านสภาพสนาม โดยเฉพาะอัตราการเสื่อมสภาพของยาง และความหยาบของผิวสนามในระดับสูง ดังเช่นใน สนามแข่งนานาชาติบาห์เรน หรือ สนามแข่ง เดอ บาร์เซโลนา-กาตาลุนญ่า มีอิทธิพลอย่างมีนัยสำคัญต่อการกำหนดจำนวนและช่วงเวลาในการเข้าจุดพัก ซึ่งแตกต่างจากสนามที่ยางมีอายุการใช้งานยาวนาน โดยตัวแปรวิกฤตที่ส่งผลต่อการตัดสินใจของทีม ได้แก่ อุณหภูมิผิวสนาม ระดับแรงกดอากาศ ที่เหมาะสมกับรูปแบบโค้ง และความสามารถในการบริหารจัดการยาง กล่าวโดยสรุป ลักษณะทางกายภาพของสนามแข่งขันทำหน้าที่เป็นบริบทแวดล้อมที่กำหนดเงื่อนไขทางเทคนิคและความพร้อมของทั้งทีมและนักขับ การวิเคราะห์คุณลักษณะเฉพาะของแต่ละสนามจึงเป็นองค์ประกอบพื้นฐานที่ขาดไม่ได้ในการประเมินรูปแบบการแข่งขันและการพยากรณ์ผลการแข่งขันฟอร์มูล่าวัน อย่างแม่นยำ

4) สภาพอากาศ

สภาพภูมิอากาศเป็นปัจจัยภายนอกที่มีความผันผวนและส่งผลกระทบต่อการแข่งขันอย่างมีนัยสำคัญ โดยเฉพาะกรณีฝนตกที่ทำให้ค่าสัมประสิทธิ์แรงเสียดทานของพื้นผิวสนามลดลง ส่งผลต่อความเร็วและความปลอดภัยในการขับขี่ ในขณะที่สภาพอากาศร้อนจัดและความชื้นสูงอาจกระทบต่อสมรรถภาพทางกายของนักขับและระบบระบายความร้อนของเครื่องยนต์ ทีมงานจำเป็นต้องมีกลยุทธ์การปรับตัวที่รวดเร็ว เช่น การปรับระดับความสูงของตัวรถ เพื่อป้องกันปรากฏการณ์เหินน้ำ และการเลือกใช้ยางที่เหมาะสมกับอุณหภูมิสนาม (Chiu, 2021; Daly, 2019) ดังกรณีศึกษาจากการแข่งขัน กรังด์ปรีซ์เบลเยียม ปี 2021 ที่สภาพอากาศเลวร้ายส่งผลให้ทัศนวิสัยลดลงจนต้องยุติการแข่งขันชั่วคราว สะท้อนให้เห็นว่าความสามารถในการบริหารจัดการความเสี่ยงจากสภาพอากาศมีความสำคัญต่อความปลอดภัยและผลแพ้ชนะไม่ยิ่งหย่อนไปกว่าปัจจัยด้านเทคนิค (Chiu, 2021)

2.2 การเรียนรู้ของเครื่อง

กระบวนการพัฒนาระบบที่สามารถเรียนรู้จากข้อมูลและปรับปรุงผลการทำงานโดยอัตโนมัติ แบ่งได้เป็น 2 ประเภทหลักที่เกี่ยวข้องกับงานวิจัยนี้ ได้แก่ การเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning) ซึ่งใช้เฉพาะการป้อนข้อมูล ที่ไม่มีป้ายชื่อเข้ามาเรียนรู้ และการเรียนรู้แบบมีผู้สอน (Supervised Learning) ซึ่งใช้ข้อมูลพร้อมป้ายชื่อทั้งการป้อนข้อมูล และ ผลลัพธ์ในการฝึกสอน (Mitchell, 1997; Pandey et al., 2020) ทั้งนี้ ผู้วิจัยได้คัดเลือกและกำหนดขอบเขตการศึกษาโดยมุ่งเน้นการประยุกต์ใช้เทคนิคสำคัญ ได้แก่ Gower Distance และ Hierarchical Clustering สำหรับการจัดกลุ่มและลดมิติข้อมูลในส่วนของ Unsupervised Learning ร่วมกับ Random Forest และ Extreme Gradient Boosting (XGBoost) สำหรับการสร้างตัวแบบพยากรณ์ในส่วนของ Supervised Learning

2.2.1 การเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning)

1) Gower Distance

ระยะทางแบบกาวเวอร์ (Gower Distance) เป็นมาตรวัดความไม่คล้ายคลึง (Dissimilarity Measure) ที่ถูกพัฒนาโดย J. C. Gower ในปี ค.ศ. 1971 เพื่อใช้ในการวิเคราะห์ข้อมูลที่มีลักษณะหลากหลายประเภท ภายในชุดข้อมูลเดียวกัน ซึ่งประกอบด้วยทั้งข้อมูลเชิงปริมาณ ข้อมูลเชิงคุณภาพ ข้อมูลเชิงอันดับ และข้อมูลแบบทวิภาค

โดยทั่วไป วิธีการวัดระยะทาง เช่น Euclidean Distance หรือ Manhattan Distance เหมาะสมกับข้อมูลเชิงตัวเลขเท่านั้น และไม่สามารถนำไปใช้กับข้อมูลเชิงหมวดหมู่ได้โดยตรง ส่งผลให้การวิเคราะห์ข้อมูลที่มีความหลากหลายของตัวแปรเกิดข้อจำกัด ระยะทางแบบกาวเวอร์ จึงถูกพัฒนาขึ้นเพื่อแก้ปัญหาดังกล่าว โดยสามารถรวมตัวแปรทุกประเภทเข้าไว้ในกรอบการคำนวณเดียวกัน

แนวคิดพื้นฐานและสูตรการคำนวณ

Gower (1971) นิยาม Similarity ระหว่างหน่วยข้อมูล iและ jในรูปแบบดั้งเดิมดังนี้

$$d(i,j) = \frac{1}{p}\sum_{k=1}^{p} s_{ijk}$$

โดยที่ i คือ ดัชนีของหน่วยข้อมูลที่หนึ่ง

j คือ ดัชนีของหน่วยข้อมูลที่สอง

k คือ ดัชนีของตัวแปร โดย $\mathrm{k} \in \{1, 2, \ldots, \mathrm{p}\}$

s_{ijk} คือ ค่าความคล้ายคลึง ของตัวแปรที่ k ระหว่างหน่วยข้อมูล i และ j

p คือ จำนวนตัวแปรทั้งหมด

อย่างไรก็ตาม สูตรดังกล่าวยังไม่รองรับการจัดการข้อมูลสูญหาย จึงได้มีการพัฒนาต่อยอดเป็นรูปแบบที่มีค่าน้ำหนัก (Kaufman & Rousseeuw, 1990) ดังนี้

$$d_{ij} = \frac{\sum_{k=1}^{p} w_{ijk}\, d_{ijk}}{\sum_{k=1}^{p} w_{ijk}}$$

โดยที่ d_{ij}คือระยะทางระหว่างหน่วยข้อมูลที่ i

j, pคือจำนวนตัวแปรทั้งหมด, d_{ijk}คือค่าความแตกต่าง (Partial Dissimilarity) ของตัวแปรที่ k, และ w_{ijk}คือค่าน้ำหนักของตัวแปรนั้น

ผลลัพธ์ที่ได้จะเป็นค่าระยะทางในช่วง 0 ถึง 1 โดยค่า 0 หมายถึงหน่วยข้อมูลมีความเหมือนกันทุกตัวแปร และค่า 1 หมายถึงหน่วยข้อมูลมีความแตกต่างกันอย่างสมบูรณ์

การคำนวณ Partial Dissimilarity แต่ละประเภทตัวแปร

ตัวแปรเชิงปริมาณ ใช้การปรับค่าให้อยู่ในช่วง 0 ถึง 1 ด้วยการหารด้วย Range ของตัวแปรนั้นวิธีนี้ทำให้ทุกตัวแปรเชิงปริมาณมีน้ำหนักเท่าเทียมกัน เพื่อป้องกันไม่ให้ตัวแปรที่มีช่วงค่ามากมีอิทธิพลเกินควร

$$d_{ijk} = \frac{|\, x_{ik} - x_{jk} \,|}{R_k}$$

โดยที่ $R_k = \max(x_k) - \min(x_k)$คือช่วงของข้อมูล วิธีนี้ทำให้ทุกตัวแปรเชิงปริมาณมีน้ำหนักเท่าเทียมกัน

ตัวแปรเชิงคุณภาพ ใช้การเปรียบเทียบตรงไปตรงมา (Exact Matching) โดยไม่มีการสมมติลำดับหรือระยะห่างระหว่างหมวดหมู่

$$d_{ijk} = \begin{cases} 0 & \text{ถ้า } x_{ik} = x_{jk} \\ 1 & \text{ถ้า } x_{ik} \neq x_{jk} \end{cases}$$

ตัวแปรเชิงอันดับ (Ordinal Variables) ข้อมูลจะถูกแปลงเป็นค่าอันดับ ก่อน เช่น Low = 1, Medium = 2, High = 3 จากนั้นนำไปปรับมาตรฐาน ให้อยู่ในช่วง 0 ถึง 1 ด้วยสูตร

$$z_{ik} = \frac{r_{ik} - 1}{M_k - 1}$$

โดยที่ r_{ik} คืออันดับของหน่วยข้อมูล i ในตัวแปร k

M_k คือจำนวนระดับทั้งหมดของตัวแปรนั้น จากนั้นคำนวณ dissimilarity เหมือนตัวแปรเชิงปริมาณ

$$d_{ijk} = | z_{ik} - z_{jk} |$$

ตัวแปรแบบทวิภาค กรณีตัวแปรที่มีเพียงสองค่า (0 หรือ 1) สามารถพิจารณาได้ว่าเป็นกรณีพิเศษของตัวแปรเชิงคุณภาพโดยใช้การเปรียบเทียบแบบตรงไปตรงมา เช่นกัน อย่างไรก็ตาม หากเป็น Asymmetric Binary (เช่น การมีอยู่ของลักษณะหายาก) สามารถกำหนดให้ $w_{ijk} = 0$ เมื่อทั้งสองหน่วยมีค่า 0 เพื่อไม่นับความเหมือนแบบ ไม่มีทั้งคู่ เข้าสู่การคำนวณ

การจัดการข้อมูลสูญหาย

หนึ่งในจุดเด่นของ Gower Distance คือสามารถจัดการข้อมูลสูญหายได้โดยไม่จำเป็นต้องลบแถวข้อมูลออก โดยกำหนดค่าน้ำหนักดังนี้

$$w_{ijk} = \begin{cases} 1 & \text{เมื่อมีข้อมูลทั้ง } x_{ik} \text{ และ } x_{jk} \\ 0 & \text{เมื่อข้อมูลสูญหายอย่างน้อยหนึ่งค่า} \end{cases}$$

กลไกนี้ทำให้ตัวแปรที่ขาดข้อมูลถูกแยกออกจากการคำนวณโดยอัตโนมัติ ช่วยลดการสูญเสียข้อมูลและเหมาะสมกับข้อมูลจริงที่มักมีค่าสูญหายอยู่เสมอ

การสร้าง Distance Matrix

หลังจากคำนวณ Gower Distance สำหรับทุกคู่หน่วยข้อมูลแล้ว จะได้เมทริกซ์ระยะทางขนาด $n \times n$ ซึ่งเป็น Symmetric Matrix ที่มีค่าบนแนวทแยงหลักเท่ากับ 0 เมทริกซ์นี้สามารถนำไปใช้เป็นข้อมูลนำเข้าสำหรับอัลกอริทึมการจัดกลุ่มที่ต้องการค่าระยะทาง เช่น Hierarchical Clustering ได้โดยตรง

2) การจัดกลุ่มแบบลำดับชั้น (Hierarchical Clustering)

การจัดกลุ่มแบบลำดับชั้น (Hierarchical Clustering) เป็นเทคนิคการจัดกลุ่มข้อมูล ที่มีวัตถุประสงค์เพื่อจัดหน่วยข้อมูลที่มีความคล้ายคลึงกันให้อยู่ในกลุ่มเดียวกัน โดยสร้างโครงสร้างความสัมพันธ์ในรูปแบบลำดับชั้น (Hierarchy) ซึ่งแสดงผลผ่านแผนภาพต้นไม้ที่เรียกว่า Dendrogram (Kaufman & Rousseeuw, 1990) ข้อได้เปรียบสำคัญของวิธีนี้คือไม่จำเป็นต้องกำหนดจำนวนกลุ่มล่วงหน้า และสามารถวิเคราะห์โครงสร้างของข้อมูลในหลายระดับได้พร้อมกัน

ประเภทของ การจัดกลุ่มแบบลำดับชั้น

การจัดกลุ่มแบบลำดับชั้นแบ่งออกเป็น 2 ประเภทหลัก ดังนี้

Agglomerative Hierarchical Clustering (Bottom-up Approach) เป็นวิธีที่นิยมใช้มากที่สุด โดยเริ่มต้นจากการให้ข้อมูลแต่ละหน่วยเป็นกลุ่มย่อยหนึ่งกลุ่ม จากนั้นรวมกลุ่มที่มีความใกล้เคียงกันมากที่สุดเข้าด้วยกันทีละขั้นตอน จนกระทั่งข้อมูลทั้งหมดถูกรวมเป็นกลุ่มเดียว กระบวนการสามารถสรุปได้ดังนี้ (1) คำนวณระยะทางระหว่างข้อมูลทุกคู่ (2) กำหนดให้ข้อมูลแต่ละหน่วยเป็น 1 กลุ่ม (3) ค้นหาคู่กลุ่มที่ใกล้กันที่สุดแล้วรวมเข้าด้วยกัน (4) คำนวณระยะทางระหว่างกลุ่มใหม่กับกลุ่มที่เหลือ และ (5) ทำซ้ำขั้นตอนที่ 3–4 จนเหลือกลุ่มเดียว

Divisive Hierarchical Clustering (Top-down Approach) เป็นวิธีที่เริ่มจากการรวมข้อมูลทั้งหมดเป็นกลุ่มเดียว แล้วทำการแบ่งออกเป็นกลุ่มย่อยอย่างต่อเนื่อง วิธีนี้มีความซับซ้อนในการคำนวณสูงกว่าแบบ Agglomerative เนื่องจากต้องพิจารณาการแบ่งกลุ่มที่เป็นไปได้ทั้งหมดในแต่ละขั้นตอน จึงไม่เป็นที่นิยมในทางปฏิบัติ

วิธีการคำนวณระยะห่างระหว่างกลุ่ม

ในกระบวนการรวมกลุ่ม จำเป็นต้องกำหนดวิธีการวัดระยะห่างระหว่างกลุ่ม (Linkage Method) ซึ่งมีผลโดยตรงต่อลักษณะและรูปแบบของกลุ่มที่ได้ วิธีหลักที่นิยมใช้มีดังนี้

Single Linkage (Minimum Linkage) กำหนดระยะห่างระหว่างสองกลุ่มจากระยะทางที่น้อยที่สุดระหว่างสมาชิกของทั้งสองกลุ่ม

$$d(A,B) = \min_{i \in A,\, j \in B} d(i,j)$$

วิธีนี้มีแนวโน้มให้กลุ่มที่มีลักษณะยืดยาวหรือต่อเนื่อง (Chain Effect) เหมาะกับข้อมูลที่มีโครงสร้างไม่เป็นรูปทรงชัดเจน แต่มีความไวต่อ Outliers สูง

Complete Linkage (Maximum Linkage) กำหนดระยะห่างระหว่างสองกลุ่มจากระยะทางที่มากที่สุดระหว่างสมาชิกของทั้งสองกลุ่ม

$$d(A,B) = \max_{i \in A,\, j \in B} d(i,j)$$

วิธีนี้ให้กลุ่มที่มีลักษณะกระชับ (Compact) และมีขอบเขตชัดเจน ลดปัญหา Chain Effect ได้ดี แต่อาจไวต่อ Outliers ในบางกรณี

Average Linkage (UPGMA) กำหนดระยะห่างจากค่าเฉลี่ยของระยะทางระหว่างสมาชิกทุกคู่ของทั้งสองกลุ่ม

$$d(A,B) = \frac{1}{|A||B|} \sum_{i \in A} \sum_{j \in B} d(i,j)$$

โดยที่ $|A|$ และ $|B|$ คือจำนวนสมาชิกในกลุ่ม A และ B ตามลำดับ

วิธีนี้ถือเป็นแนวทางที่สมดุลระหว่าง Single และ Complete Linkage ให้ผลลัพธ์ที่มีความเสถียรและลดผลกระทบจาก Outliers

Ward's Method แตกต่างจากวิธีอื่นตรงที่ไม่ได้ใช้ระยะทางระหว่างจุดโดยตรง แต่ใช้การเพิ่มขึ้นของ Total Within-Cluster Sum of Squares (WSS) เป็นเกณฑ์ในการรวมกลุ่ม โดยรวมคู่กลุ่มที่ทำให้ WSS เพิ่มขึ้นน้อยที่สุด

$$\Delta(A,B) = \frac{|\ A\ ||\ B\ |}{|\ A\ | + |\ B\ |} \parallel \bar{x}_A - \bar{x}_B \parallel^2$$

โดยที่ $\bar{x}_A$ และ $\bar{x}_B$ คือ Centroid ของกลุ่ม A และ B ตามลำดับ

วิธีนี้มีแนวโน้มให้กลุ่มที่มีขนาดใกล้เคียงกันและมีความแน่นสูง แต่ต้องการข้อมูลเชิงปริมาณในการคำนวณ Centroid จึงอาจไม่เหมาะกับข้อมูลที่ไม่ใช่เชิงตัวเลข

Centroid Linkage (UPGMC) กำหนดระยะห่างระหว่างสองกลุ่มจากระยะทางระหว่าง Centroid (ค่าเฉลี่ยของตำแหน่งสมาชิก) ของทั้งสองกลุ่ม

$$d(A,B) = \parallel \bar{x}_A - \bar{x}_B \parallel^2$$

วิธีนี้มีความทนทานต่อ Outliers พอสมควร แต่อาจเกิดปรากฏการณ์ Inversion (ระยะห่างกลุ่มใหม่น้อยกว่ากลุ่มเดิม) ซึ่งทำให้ Dendrogram ตีความได้ยาก

การแสดงผลด้วย Dendrogram

ผลลัพธ์ของ การจัดกลุ่มแบบลำดับชั้น แสดงในรูปแบบ Dendrogram ซึ่งเป็นแผนภาพต้นไม้ที่แกนแนวตั้งแสดงค่าระยะทาง ณ จุดที่เกิดการรวมกลุ่ม และแกนแนวนอนแสดงหน่วยข้อมูลแต่ละหน่วย การตัด Dendrogram ที่ระดับความสูงต่าง ๆ จะให้จำนวนกลุ่มที่แตกต่างกัน ทำให้ผู้วิจัยสามารถพิจารณาเลือกจำนวนกลุ่มที่เหมาะสมได้จาก Dendrogram โดยตรง

3 มาตรวัดประสิทธิภาพการจัดกลุ่มด้วย Silhouette Width

หัวใจสำคัญของการวิเคราะห์การจัดกลุ่ม คือการประเมินว่าจำนวนกลุ่ม ที่เลือกนั้นสามารถอธิบายโครงสร้างของข้อมูลได้ดีเพียงใด Rousseeuw (1987) ได้นำเสนอเทคนิค Silhouette Width เพื่อใช้เป็นเครื่องมือเชิงกราฟิกและเชิงปริมาณในการประเมินความเหมาะสมของการจัดกลุ่ม โดยพิจารณาจากความสัมพันธ์ระหว่างความแน่นแฟ้นภายในกลุ่มและความแตกต่างระหว่างกลุ่ม

1) แนวคิดเชิงทฤษฎี

Silhouette Width ทำงานบนพื้นฐานของการเปรียบเทียบระยะทางระหว่างหน่วยข้อมูล (i) กับสมาชิกในกลุ่มเดียวกัน เทียบกับระยะทางไปยังกลุ่มที่ใกล้ที่สุดที่อยู่ถัดไป โดยมีองค์ประกอบสำคัญ 2 ส่วน ดังนี้

ความแน่นแฟ้นภายในกลุ่ม (Intra-cluster Dissimilarity) แทนด้วย (i) คือ ค่าเฉลี่ยของระยะทาง (Dissimilarity) ระหว่างหน่วยข้อมูล (i) กับข้อมูลอื่น ๆ ทั้งหมดที่อยู่ในกลุ่มเดียวกัน หากค่า (i) มีค่าน้อย แสดงว่าหน่วยข้อมูลนั้นมีความคล้ายคลึงกับสมาชิกในกลุ่มสูง

ความแยกตัวระหว่างกลุ่ม (Inter-cluster Dissimilarity): แทนด้วย $b(i)$ คือ ค่าเฉลี่ยของระยะทางที่น้อยที่สุดระหว่างหน่วยข้อมูล (i) กับสมาชิกของกลุ่มอื่นที่อยู่ใกล้ที่สุด (Neighboring Cluster) หากค่า $b(i)$ มีค่ามาก แสดงว่าหน่วยข้อมูลนั้นมีความแตกต่างจากกลุ่มข้างเคียงอย่างชัดเจน

2) สูตรการคำนวณ

ค่าสัมประสิทธิ์ Silhouette s_i สำหรับแต่ละหน่วยข้อมูล (i) คำนวณได้จากสมการดังนี้

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

โดยที่ผลลัพธ์ของ $s(i)$ จะถูกจำกัดให้อยู่ในช่วง -1 ถึง 1 เสมอ ซึ่งสามารถตีความความหมายได้ดังนี้

$s(i) \approx 1$ หน่วยข้อมูลถูกจัดกลุ่มได้อย่างเหมาะสมมาก เนื่องจากระยะทางภายในกลุ่มน้อยกว่าระยะทางระหว่างกลุ่มอย่างชัดเจน

$s(i) \approx 0$ หน่วยข้อมูลวางตัวอยู่บนขอบเขตระหว่างสองกลุ่ม (Decision Boundary) ทำให้ยากต่อการระบุว่าควรอยู่กลุ่มใด

$s(i) < 0$ มีความน่าจะเป็นสูงที่หน่วยข้อมูลนั้นจะถูกจัดกลุ่มผิดพลาด (Misclassified) และควรไปอยู่ในกลุ่มข้างเคียงมากกว่า

3) การพิจารณาจำนวนกลุ่มที่เหมาะสมที่สุด

เพื่อให้ได้ภาพรวมของคุณภาพการจัดกลุ่มทั้งชุดข้อมูล ผู้วิจัยจะใช้ค่าเฉลี่ย Silhouette $\bar{s}_k$ (Average Silhouette Width) ซึ่งคำนวณจากการหาค่าเฉลี่ยของ $s(i)$ ทุกหน่วยข้อมูลในจำนวนกลุ่ม k ใด ๆ

$$\bar{s}_k = \frac{1}{n}\sum_{i=1}^{n} s_i(k)$$

ตามหลักการของ Rousseeuw จำนวนกลุ่ม k ที่เหมาะสมที่สุดสำหรับชุดข้อมูลคือ ค่า k ที่ให้ค่าเฉลี่ย $\bar{s}_k$ สูงที่สุด ซึ่งบ่งชี้ว่าโครงสร้างการจัดกลุ่มในระดับนั้นมีความชัดเจนและมีความผิดพลาดในการแบ่งแยกข้อมูลน้อยที่สุด

2.2.2 การเรียนรู้แบบมีผู้สอน (Supervised Learning)

1. Decision Tree

ต้นไม้การจำแนกประเภท (Classification Trees) เป็นเทคนิคที่ใช้ทำนายค่าตัวแปรเชิงกลุ่มหรือเชิงคุณภาพ โดยการแบ่งกลุ่มข้อมูลออกเป็นหลายๆ กลุ่มไม่ทับซ้อนกัน และกำหนดคลาสที่ทำนายในแต่ละกลุ่มจากประเภทที่พบมากที่สุดข้อมูลฝึกในกลุ่มนั้น การแบ่งกลุ่มทำได้โดยการใช้วิธีการแบ่งแบบรีเคอร์ ซึ่งจะเริ่มจากการแบ่งข้อมูลที่ดีที่สุดในแต่ละขั้นตอน โดยที่ในแต่ละขั้นตอนจะเลือกตัวแปร (feature) และเกณฑ์การแบ่ง (cutpoint) ที่ทำให้ค่าอัตราความไม่บริสุทธิ์ของ node ลดลงมากที่สุดในแต่ละรอบการแบ่ง

ขั้นตอนในการสร้างต้นไม้การจำแนก

1) การแบ่งกลุ่ม (Splitting)

ในขั้นตอนการแบ่งข้อมูล เป้าหมายคือการเลือกตัวแปร X_j และเกณฑ์การแบ่ง s ที่สามารถแบ่งข้อมูลออกเป็นสองกลุ่มโดยเลือก j และ s ที่ทำให้ความไม่บริสุทธิ์ของ node หลังการแบ่งลดลงมากที่สุด ดังนี้

กลุ่มที่ 1: $R_1 = \{X \mid X_j < s\}$

กลุ่มที่ 2: $R_2 = \{X \mid X_j \geq s\}$

เกณฑ์ที่ใช้ในการแบ่งข้อมูล มีหลายตัวเลือกที่นิยมใช้ในการสร้างต้นไม้การจำแนก

อัตราข้อผิดพลาดในการจำแนกประเภท เป็นตัวชี้วัดพื้นฐานที่บอกสัดส่วนของตัวอย่างใน node ที่ไม่ได้อยู่ในคลาสที่พบมากที่สุด กำหนดดังนี้

$$E = 1 - \min_{k}(\hat{p}_{mk})$$

โดย $\hat{p}_{mk}$ คือสัดส่วนของข้อมูลฝึกใน node ที่ m ในคลาสที่ k

Gini index เป็นตัวชี้วัด ความไม่บริสุทธิ์ของ node โดยจะมีค่าน้อยเมื่อ node นั้นมีตัวอย่างส่วนใหญ่เป็นคลาสเดียวกัน (บริสุทธิ์สูง) และมีค่าสูงเมื่อมีหลายคลาสปะปนกัน นิยามได้ดังสมการต่อไปนี้

$$G = \sum_{k=1}^{K} \hat{p}_{mk}\,(1 - \hat{p}_{mk})$$

โดย $\hat{p}_{mk}$ คือสัดส่วนของข้อมูลฝึกใน node ที่ m ในคลาสที่ k

Entropy เป็นตัวชี้วัดที่คล้ายคลึงกับ Gini index แต่จะพิจารณาความไม่แน่นอน (หรือความยุ่งเหยิง) ของข้อมูลใน node ค่าน้อยของ Entropy หมายถึง node ที่บริสุทธิ์ขณะที่ค่าที่สูงจะหมายถึง node ที่มีการกระจายข้อมูลระหว่างหลายคลาส

$$D = -\sum_{k=1}^{K} \hat{p}_{mk} \log\,(\hat{p}_{mk})$$

โดย $\hat{p}_{mk}$ คือสัดส่วนของข้อมูลฝึกใน node ที่ m ในคลาสที่ k

2) การแบ่งแบบ Top-Down และ Greedy

การแบ่งข้อมูลในต้นไม้การถดถอยจะทำโดยวิธี Top-Down ซึ่งเริ่มต้นจากการใช้ข้อมูลทั้งหมดและแบ่งกลุ่มไปทีละขั้นตอน โดยการเลือกตัวแปรและเกณฑ์การแบ่งที่ดีที่สุดในแต่ละขั้นตอน โดยไม่มองล่วงหน้าไปยังการแบ่งในขั้นตอนถัดไป ซึ่งจะช่วยให้การแบ่งเป็นไปได้อย่างรวดเร็วและมีประสิทธิภาพ

3) การคำนวณสัดส่วนของข้อมูลฝึก ($\hat{p}_{mk}$)

คือสัดส่วนของข้อมูลฝึกใน node ที่ m ในคลาสที่ k คำนวณได้ดังสมการ

$$\hat{p}_{mk} = \frac{1}{N_m} \sum_{i \in R_m} I(y_i = k)$$

โดยที่

N_m คือ จำนวนตัวอย่างทั้งหมดใน node m

$I(y_i = k)$ คือ คือฟังก์ชันดัชนี (indicator function) ที่มีค่าเป็น 1 หาก y_i ของตัวอย่าง i อยู่ในคลาส k และเป็น 0 หากไม่อยู่ในคลาส k

4) การตัดต้นไม้ (Tree Pruning)

หลังจากที่สร้างต้นไม้จนมีขนาดใหญ่เต็มที่แล้ว อาจเกิดปัญหา overfitting เนื่องจากต้นไม้มีความซับซ้อนสูงและจับรายละเอียดของข้อมูลฝึกมากเกินไป ดังนั้นการตัดต้นไม้ (pruning) จึงเป็นขั้นตอนสำคัญที่ช่วยลดความซับซ้อนของตัวแบบโดยการตัดสาขาที่ไม่จำเป็นออก เทคนิคที่ใช้โดยทั่วไปคือ Cost-Complexity Pruning ซึ่งกำหนดเป็นฟังก์ชันดังนี้

$$R_\alpha(T) = R(T) + \alpha|T|$$

โดยที่

$R(T)$ คือ ผลรวมระดับความไม่บริสุทธิ์ (impurity) หรือ training error ของ terminal nodes ทั้งหมดในต้นไม้ T

$|T|$ คือ จำนวนของ terminal nodes ในต้นไม้

α คือ พารามิเตอร์ที่ควบคุมความซับซ้อนของต้นไม้

เมื่อ α = 0 ต้นไม้จะไม่มีการตัด (full tree) แต่เมื่อ α เพิ่มขึ้น ต้นไม้จะมีขนาดเล็กลง และจะเลือก subtree ที่เหมาะสมที่สุดจากกระบวนการ pruning

5) การเลือกต้นไม้ที่ดีที่สุด

การใช้ K-fold cross-validation เพื่อเลือกค่าพารามิเตอร์ αที่เหมาะสมที่สุด โดยการแบ่งข้อมูลฝึกฝนออกเป็น Kส่วน ฝึกต้นไม้บนข้อมูลที่ไม่รวม fold ที่ kและเลือก αที่ทำให้ test error ต่ำสุด

แม้ว่า Decision Tree จะเป็นตัวแบบที่เข้าใจง่ายและเรียนรู้ข้อมูลได้ดี แต่ก็มีข้อจำกัดเรื่องของความ overfitting และ instability ที่เกิดจากการสร้างโครงสร้างซับซ้อนเกินไปหรือการเปลี่ยนแปลงเล็กน้อยในข้อมูลฝึกฝนทำให้ตัวแบบไม่เสถียรและไม่สามารถทำนายข้อมูลใหม่ได้ดี อีกทั้งยังมีความแปรปรวน (variance) สูงและความลำเอียง (bias) ต่ำ หากไม่มีการตัดต้นไม้ (pruning) จากปัญหานี้จึงเกิดเทคนิค ensemble learning อย่าง Bagging และ Boosting ที่พัฒนาเพื่อรวมหลายๆ ต้นไม้ ช่วยลดปัญหา overfitting และ instability และเพิ่มความเสถียรในการทำนายข้อมูลใหม่

2. Bagging

Bagging หรือที่รู้จักกันในชื่อ Bootstrap Aggregating เป็นเทคนิคที่ใช้ในการลดความแปรปรวน ของตัวแบบการเรียนรู้ทางสถิติ โดยการสุ่มตัวอย่างซ้ำ (bootstrap) จากชุดข้อมูลฝึกหัดเดียวกันหลายๆ ครั้ง เพื่อสร้างตัวแบบหลายๆ ตัว จากนั้นจะนำผลการทำนายจากแต่ละตัวแบบมาคำนวณค่าเฉลี่ย (สำหรับการทำนายเชิงจำนวน) หรือใช้วิธีการโหวต (สำหรับการจำแนกประเภท) เพื่อให้ได้การทำนายที่มีความแปรปรวนต่ำลง เทคนิคนี้มักนำไปใช้กับต้นไม้การตัดสินใจ ซึ่งมีความแปรปรวนสูง วิธีการของ Bagging เริ่มต้นด้วยชุดข้อมูล $Z_1, Z_2, \dots, Z_n$ที่เป็นข้อมูลอิสระกันทั้งหมดและมีความแปรปรวน σ^2 หากคำนวณค่าเฉลี่ยจากชุดข้อมูลเหล่านี้ ผลลัพธ์จะมีความแปรปรวนเท่ากับ $\frac{\sigma^2}{n}$ซึ่งแสดงให้เห็นว่าการเฉลี่ยผลลัพธ์จากหลายชุดข้อมูลจะช่วยลดความแปรปรวนได้ ดังนั้น การใช้หลายชุดข้อมูลฝึกหัดและเฉลี่ยผลลัพธ์จากแต่ละชุดจะช่วยลดความแปรปรวนและเพิ่มความแม่นยำในการทำนาย สมการจาก Bagging คือ

$$\hat{f}_{avg}(x) = \frac{1}{B}\sum_{b=1}^{B} \hat{f}_b(x)$$

โดยที่

B คือ จำนวนของตัวแบบที่สร้างจากชุดข้อมูลที่สุ่ม

$\hat{f}_b(x)$ คือ การทำนายจากตัวแบบที่ b จากชุดข้อมูลที่สุ่ม

เมื่อใช้ Bagging กับ ต้นไม้การตัดสินใจ หรือต้นไม้การถดถอย จะทำการสร้าง B ต้นไม้การตัดสินใจจากชุดข้อมูลที่สุ่มและไม่ตัดต้นไม้ แต่ละต้นไม้จะมีความแปรปรวนสูงแต่มีอคติต่ำ แต่การเฉลี่ยผลลัพธ์จากหลายๆ ต้นไม้จะช่วยลดความแปรปรวนลงอย่างมาก

การประเมินความผิดพลาดจากการทำนาย Out-of-Bag (OOB) Error Estimation

หนึ่งในข้อดีของ Bagging คือการที่สามารถประเมินความผิดพลาด (error) ได้โดยไม่จำเป็นต้องใช้วิธี cross-validation หรือ validation set โดยการใช้เทคนิค Out-of-Bag (OOB) วิธีการนี้ใช้ประโยชน์จากการสุ่มตัวอย่างข้อมูลจากชุดฝึกหัดหลายชุด ซึ่งทำให้บางตัวอย่างไม่ได้ถูกเลือกในบางตัวแบบที่สร้างขึ้น (โดยปกติแล้วประมาณสองในสามของข้อมูลจะถูกใช้ในการฝึกฝนต้นไม้แต่ละต้น) ตัวอย่างที่ไม่ได้ถูกเลือกจะถูกเรียกว่า OOB observations

วิธีการคำนวณ OOB error สำหรับการทำนายในการถดถอย หรือการจำแนกประเภท คือ

1) ในแต่ละรอบการสร้างต้นไม้จากการสุ่มตัวอย่างข้อมูล จะมีบางตัวอย่างที่ไม่ได้ถูกเลือก (OOBobservations)
2) สำหรับแต่ละตัวอย่าง OOB ในแต่ละต้นไม้ จะใช้ตัวแบบที่สร้างจากต้นไม้นั้นในการทำนายค่า ซึ่งสำหรับการทำนายเชิงจำนวน (regression) จะใช้การเฉลี่ยผลลัพธ์จากต้นไม้หลายๆ ต้น และสำหรับการจำแนกประเภท (classification) จะใช้การโหวตจากต้นไม้หลายๆ ต้น

3) หลังจากได้ผลทำนายแต่ละตัวอย่างจาก OOB แล้ว การคำนวณ OOB error จะทำได้โดยการคำนวณ Mean Squared Error (MSE) สำหรับการถดถอย หรือการคำนวณอัตราความผิดพลาดในการจำแนกประเภท (Misclassification Rate) สำหรับการจำแนกข้อมูล

แม้ว่า Bagging จะช่วยเพิ่มความแม่นยำของการทำนาย แต่การใช้จำนวนต้นไม้หลายๆ ต้นอาจทำให้การตีความตัวแบบยากขึ้น เนื่องจากไม่สามารถแสดงผลลัพธ์จากต้นไม้หลายๆ ต้นในกราฟเดียวกันได้ ทำให้หนึ่งในการเข้าใจผลกระทบของแต่ละตัวแปรในตัวแบบคือ การวัดความสำคัญของตัวแปร โดยที่ตัวแปรที่มีความสำคัญจะช่วยลดค่า Residual Sum of Squares (RSS) ในการแบ่งข้อมูลใน Regression Trees หรือลดค่า impurity เช่น Gini Index หรือ Entropy ใน Classification Trees

3. Boosting

Boosting เป็นเทคนิคหนึ่งที่ใช้ในการปรับปรุงประสิทธิภาพของตัวแบบการทำนายจากต้นไม้การตัดสินใจ โดยวิธีการนี้ถือเป็นกระบวนการเรียนรู้ที่ทำงานในลักษณะ sequential ซึ่งแตกต่างจาก bagging ที่สร้างตัวแบบจากต้นไม้หลายต้นที่มีการฝึกจากข้อมูลที่สุ่มจากการสุ่มตัวอย่าง ออกไป ในการทำงานของ boosting ต้นไม้แต่ละต้นจะถูกสร้างขึ้นตามลำดับ โดยใช้ข้อมูลจากต้นไม้ที่สร้างก่อนหน้าในการปรับปรุงผลลัพธ์ของตัวแบบ ในกระบวนการ boosting จะเริ่มต้นด้วยการตั้งค่าตัวแบบเริ่มต้น$\hat{f}_b(x)$ = 0 และคำนวณ residuals (ค่าผิดพลาด) ของตัวแบบจากชุดข้อมูลฝึกหัด จากนั้นจะสร้างต้นไม้การตัดสินใจขนาดเล็ก (ที่อาจมีจำนวน terminal nodes เพียงไม่กี่จุด) โดยใช้ค่าผิดพลาด (residuals) จากตัวแบบที่สร้างขึ้นก่อนหน้านี้เป็นข้อมูลในการฝึก สำหรับต้นไม้ที่ถูกสร้างขึ้นใหม่จะถูกนำมาปรับปรุงผลลัพธ์ของตัวแบบเดิมโดยการเพิ่มผลการทำนายของต้นไม้ใหม่นี้เข้าไปในตัวแบบเดิมอย่างค่อยเป็นค่อยไป กระบวนการนี้จะช่วยให้ตัวแบบค่อยๆ ปรับปรุงและลดค่าผิดพลาดในส่วนที่ตัวแบบเดิมทำได้ไม่ดี โดยการใช้ shrinkage parameter (พารามิเตอร์ที่ควบคุมอัตราการเรียนรู้) เพื่อชะลอการปรับปรุงเหล่านี้ให้ละเอียดและมีความยืดหยุ่นมากขึ้น

ขั้นตอนการทำงานของ Boosting สำหรับการจำแนก (Classification Trees)

1) เริ่มต้นด้วยการตั้งค่าตัวแบบ $\hat{f}_b(x)$ = 0 และคำนวณค่าผิดพลาด $r_j = y_j$ สำหรับทุกตัวอย่าง i ในชุดข้อมูลฝึกหัด
2) สำหรับ $b = 1,2,\ldots,B$ ทำตามขั้นตอนดังนี้:
    a) สร้างต้นไม้ $\hat{f}_b$ โดยใช้ classification tree ที่มีการแบ่ง d (แต่ละต้นไม้จะมี d+1 terminal nodes) โดยใช้ค่าผิดพลาด r_iเป็นค่าที่ใช้ในการเรียนรู้ (target values) แทนที่จะใช้ค่าจริง y_i
    b) ปรับปรุงตัวแบบ $\hat{f}(x)$ โดยการเพิ่มผลลัพธ์จากต้นไม้ใหม่ที่ย่อส่วนแล้วเข้าไป:

$$\hat{f}(\mathrm{x}) \leftarrow \hat{f}(\mathrm{x}) + \lambda \hat{f}_b(x)$$

    c) ปรับปรุงค่าผิดพลาด (residuals) ใหม่:

$$r_i \leftarrow r_i - \lambda \hat{f}_b(x_i)$$

สำหรับการจำแนกประเภท มักจะถูกคำนวณจาก log-odds หรือ probabilities

3) ผลลัพธ์สุดท้ายของตัวแบบคือการรวมต้นไม้ที่ย่อส่วนทั้งหมด:

$$\hat{f}(\mathrm{x}) = \sum_{b=1}^{B} \lambda \hat{f}_b(x)$$

โดยที่

B คือจำนวนของต้นไม้ที่ใช้ในการฝึก

λ คือ shrinkage parameter ที่ควบคุมอัตราการเรียนรู้ของตัวแบบ

d คือจำนวนการแบ่งในแต่ละต้นไม้ ซึ่งจะควบคุมความซับซ้อนของตัวแบบ

พารามิเตอร์ในการปรับแต่งของ Boosting

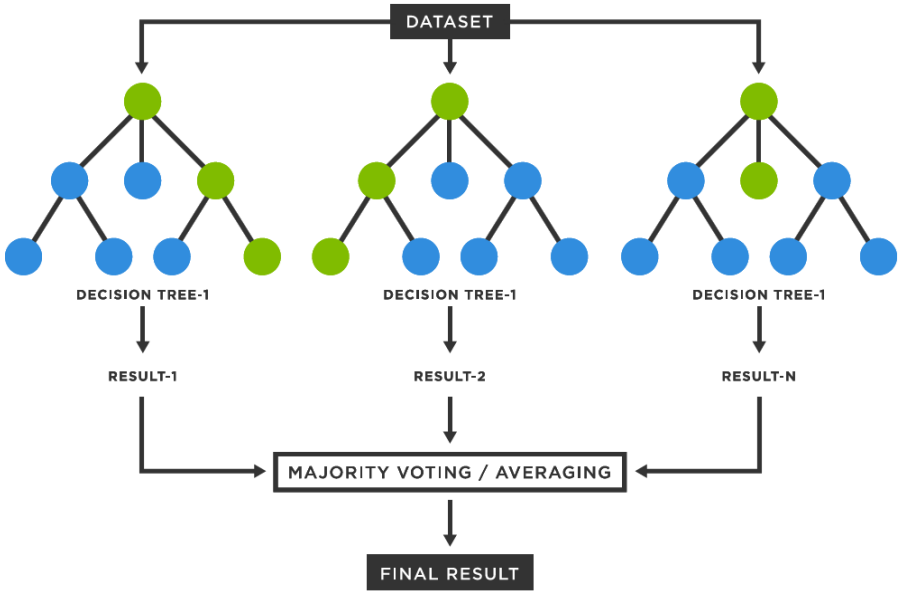
กระบวนการ Boosting มีพารามิเตอร์หลักสามตัวที่ต้องการการปรับแต่งเพื่อให้ได้ผลลัพธ์ที่ดีที่สุด

1) จำนวนของต้นไม้ (B) คือจำนวนของต้นไม้ที่ใช้ในการฝึกฝนตัวแบบ โดยทั่วไปแล้วจำนวนต้นไม้ที่มากเกินไปอาจทำให้ตัวแบบ overfit ข้อมูลได้ ดังนั้นการเลือกค่า B ควรทำโดยการใช้ cross-validation เพื่อหาค่าที่ดีที่สุด
2) Shrinkage parameter คือค่าควบคุมอัตราการเรียนรู้ของตัวแบบ โดยทั่วไปแล้วจะมีค่าเล็ก (เช่น 0.01 หรือ 0.001) เพื่อให้กระบวนการเรียนรู้เป็นไปอย่างช้าๆ และสามารถหลีกเลี่ยงการ overfitting ได้
3) จำนวนการแบ่งในแต่ละต้นไม้ d ค่านี้จะควบคุมความซับซ้อนของแต่ละต้นไม้ โดยทั่วไปจะใช้ $d = 1$ ซึ่งหมายถึงต้นไม้เป็น stump (ต้นไม้ที่มีเพียงการแบ่งหนึ่งครั้ง) ในกรณีนี้ตัวแบบที่ได้จะเป็น additive model ซึ่งหมายถึงแต่ละคำตอบจะประกอบด้วยเพียงตัวแปรเดียวจากต้นไม้แต่ละต้นที่ใช้ในการสร้าง

แม้ว่าจะมีการปรับปรุงตัวแบบในแต่ละรอบ แต่การที่มีการเพิ่มต้นไม้หลายๆ ต้นอาจทำให้ผลลัพธ์ของตัวแบบกลายเป็น black-box ได้เช่นเดียวกับ Boosting เพราะแม้กระทั่งการพิจารณาความสำคัญของตัวแปรใน Boosting ก็อาจเป็นเรื่องยากขึ้น โดยเฉพาะเมื่อตัวแบบมีต้นไม้จำนวนมาก

4. Random Forest (RF)

Random Forest เป็นเทคนิค Bagging ที่รวม decision trees หลายต้นเข้าด้วยกันเพื่อลดความแปรปรวน (variance) และเพิ่มความแม่นยำ (Breiman, 2001) Random Forests เป็นเทคนิคการเรียนรู้ของเครื่องที่พัฒนามาจาก Bagged Trees โดยมีแนวคิดหลักคือการลดความสัมพันธ์ระหว่างต้นไม้หลายต้น (decorrelation) เพื่อให้ผลเฉลี่ยของต้นไม้หลายต้นมีความเสถียรและแม่นยำมากขึ้น Random Forests ใช้การสร้างต้นไม้หลายต้นจากตัวอย่าง bootstrapped ของข้อมูลการฝึก เช่นเดียวกับ Bagging แต่แตกต่างตรงที่ในการแบ่งแต่ละครั้ง ต้นไม้จะถูกจำกัดให้พิจารณาตัวแปรเพียงบางส่วนหรือ subset หนึ่งจากทั้งหมด ซึ่งโดยทั่วไปเลือกประมาณรากที่สองของจำนวนตัวแปรทั้งหมด เทคนิคนี้ช่วยให้ตัวแปรที่ไม่เด่นมากมีโอกาสถูกเลือก และลดความโดดเด่นของตัวแปรที่มีอิทธิพลสูง ทำให้ต้นไม้แต่ละต้นแตกต่างกันมากขึ้น การจำกัดตัวแปรที่ใช้ในการแบ่งเป็นกุญแจสำคัญที่ทำให้ Random Forests ลดความแปรปรวนของตัวแบบได้ดีกว่า Bagging โดยเฉพาะในชุดข้อมูลที่ตัวแปรมีความสัมพันธ์กันสูง Random Forests สามารถปรับจำนวนต้นไม้และจำนวนตัวแปรที่ใช้ในการแบ่งเพื่อหาค่าพารามิเตอร์ที่เหมาะสมที่สุด โดยไม่ต้องกังวลเรื่อง overfitting เพราะการเพิ่มจำนวนต้นไม้ไม่ได้ทำให้ตัวแบบซับซ้อนเกินไป การทำงานของ Random Forest แสดงได้ดังภาพที่ 2.1 ซึ่งจะทำการสุ่มข้อมูลจากชุดข้อมูลต้นฉบับเพื่อสร้างต้นไม้การตัดสินใจหลายต้น และนำผลการทำนายจากต้นไม้ทั้งหมดมาสรุปด้วยค่าเฉลี่ยสำหรับงานพยากรณ์เชิงตัวเลข และด้วยการลงคะแนนเสียงส่วนใหญ่สำหรับงานจัดประเภท



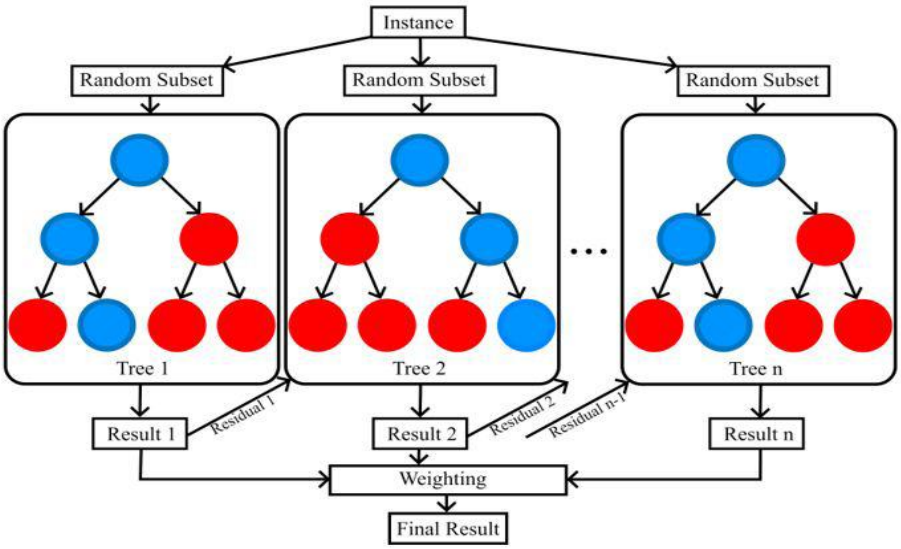
ภาพที่ 2.1 แผนภาพการทำงานของตัวแบบ Random Forest

หมายเหตุ ดัดแปลงจาก Random forest [แผนภาพ], โดย D. Gunay, 2566, Medium. https://medium.com/@denizgunay/random-forest-af5bde5d7e1e

5. Extreme Gradient Boosting (XGBoost)

XGBoost เป็นอัลกอริทึมในตระกูล Boosting ที่พัฒนาให้ทำงานได้รวดเร็วและมีประสิทธิภาพสูง ใช้กันอย่างแพร่หลายทั้งในงานแข่งขันด้าน Machine Learning และงานวิจัยเชิงปฏิบัติการ (Chen & Guestrin, 2016) XGBoost (eXtreme Gradient Boosting) เป็นไลบรารีแบบเปิดที่ใช้ gradient boosted decision trees เพื่อสร้างตัวแบบทำนายที่แข็งแรงและแม่นยำ โดยมีจุดเด่นเรื่องความเร็ว ความสามารถในการจัดการข้อมูลขนาดใหญ่ และการทำงานแบบกระจาย (distributed computing) พัฒนาโดย Tianqi Chen จาก University of Washington หลักการของ XGBoost คือการรวมต้นไม้ตัดสินใจหลายต้นเข้าด้วยกันดังภาพที่ 2.2 โดยต้นไม้แต่ละต้นปรับปรุงจากข้อผิดพลาดของต้นไม้ก่อนหน้า การตัดสินใจของต้นไม้เดี่ยวมักเกิด overfitting ได้ง่าย ดังนั้นเทคนิค ensemble อย่าง boosting จึงถูกนำมาใช้ Weak learners จะถูกฝึกแบบต่อเนื่องเพื่อแก้ไขข้อผิดพลาดของต้นไม้ก่อนหน้า Gradient boosted decision trees ใช้ gradient descent เพื่อลดค่าความสูญเสีย (loss) โดยคำนวณ residual ของแต่ละต้นไม้และรวมเข้ากับต้นไม้ถัดไป ทำให้ตัวแบบเรียนรู้จากข้อผิดพลาดและปรับปรุงผลลัพธ์ XGBoost มีคุณสมบัติเด่นหลายประการ เช่น การคำนวณแบบขนานและกระจาย การใช้ cache-aware prefetching เพื่อลดเวลาในการประมวลผล การ

ทำ regularization ในตัว และจัดการค่าที่หายไป (missing values) ด้วยอัลกอริทึมแบบ sparsity-aware ทำให้สามารถจัดการกับข้อมูลขนาดใหญ่และซับซ้อนได้อย่างมีประสิทธิภาพ การใช้งาน XGBoost เริ่มจากการเตรียมข้อมูลและฝึกตัวแบบด้วย DMatrix ซึ่งเป็นโครงสร้างข้อมูลภายในที่ช่วยประหยัดหน่วยความจำและเพิ่มความเร็ว จากนั้นเลือก objective function ตามลักษณะงาน เช่น multi-class classification, binary classification หรือ regression เช่น การใช้ mean squared error หรือ mean absolute error เพื่อประเมินความแม่นยำของตัวแบบ หลังจากนั้นประเมินประสิทธิภาพด้วย metrics เช่น accuracy, precision, recall, F1-score สำหรับงาน classification หรือ RMSE, MAE สำหรับงาน regression การปรับแต่ง hyperparameters เป็นอีกขั้นตอนสำคัญ เช่น learning rate (eta), n_estimators, gamma และ max_depth ซึ่งช่วยควบคุมความเร็วในการเรียนรู้ ความซับซ้อนของตัวแบบ และความเสี่ยงของ overfitting การปรับแต่งให้เหมาะสมสามารถช่วยให้ XGBoost ให้ผลลัพธ์ที่แม่นยำทั้งสำหรับงาน classification และ regression



ภาพที่ 2.2 แผนภาพการทำงานของตัวแบบ XGBoost

หมายเหตุ จาก Simplified structure of XGBoost [แผนภาพ], โดย B. Öztornaci, 2566, ResearchGate. https://www.researchgate.net/figure/Simplified-structure-of-XGBoost_fig5_381857634

6. ประสิทธิภาพของตัวแบบ (Model Performance)

การประเมินประสิทธิภาพของตัวแบบในงานจำแนกประเภท โดยเฉพาะในกรณีที่มีหลายคลาส (Multiclass Classification) จำเป็นต้องคำนึงถึงการวัดค่าต่าง ๆ ที่ใช้ในการประเมิน อย่าง Accuracy, Precision, Recall, และ F1-Score เพื่อวิเคราะห์ว่าตัวแบบทำงานได้ดีหรือไม่ในแต่ละคลาส รวมถึงการตรวจสอบข้อผิดพลาดในกระบวนการทำนาย

1) Accuracy คือสัดส่วนของจำนวนตัวอย่างที่ตัวแบบทำนายถูกต้องทั้งหมดจากจำนวนตัวอย่างทั้งหมดในชุดข้อมูล

$$Accuracy_i = \frac{\sum_i TP_i}{Total\ samples}$$

2) Presicion คืออัตราส่วนของตัวอย่างที่ถูกทำนายว่าเป็นคลาส iและจริง ๆ แล้วเป็นคลาส iเมื่อเทียบกับจำนวนตัวอย่างที่ทำนายว่าเป็นคลาส i ทั้งหมด

$$Precision_i = \frac{TP_i}{TP_i + FP_i}$$

3) Recall คืออัตราส่วนของจำนวนตัวอย่างที่จริง ๆ แล้วเป็นคลาส i และตัวแบบทำนายว่าเป็นคลาส i เมื่อเทียบกับจำนวนตัวอย่างที่จริง ๆ แล้วเป็นคลาส i

$$Recall_i = \frac{TP_i}{TP_i + FN_i}$$

4) F1-Score คือค่าที่ใช้ในการรวม Precision และ Recall เข้าด้วยกัน เป็นค่าที่ช่วยในการปรับสมดุลระหว่าง Precision และ Recall โดยการหาค่าเฉลี่ยที่เป็นสมดุลของทั้งสอง

$$F1_i = \frac{2 \times Precision_i \times Recall_i}{Precision_i + Recall_i}$$

โดยที่

TP_i คือ True Positives ของคลาส i หรือจำนวนที่ทำนายเป็นคลาส i แต่ที่จริงเป็น และจริง ๆ แล้วเป็นคลาส i

FP_i คือ False Positives ของคลาส i จำนวนที่ทำนายเป็นคลาส i แต่จริง ๆ แล้วเป็นคลาสอื่น (คลาส j โดยที่ $j \neq i$)

FN_i คือ False Negatives ของคลาส i จำนวนตัวอย่างที่จริง ๆ แล้วเป็นคลาส i แต่ตัวแบบทำนายผิดเป็นคลาสอื่น

TN_i คือ True Negatives ของคลาส i จำนวนตัวอย่างที่ไม่ใช่คลาส i และและตัวแบบก็ไม่ทำนายเป็นคลาส i

5) Confusion Matrix ตารางที่แสดงผลลัพธ์การทำนายในแต่ละคลาสที่รวมจำนวน True Positives, False Positives, True Negatives, และ False Negatives ไว้ในตารางเดียว

2.2.3 การตรวจสอบความถูกต้องของตัวแบบสำหรับข้อมูลอนุกรมเวลา (Time Series Cross-Validation)

การประเมินประสิทธิภาพของตัวแบบในงาน Machine Learning โดยทั่วไปนิยมใช้วิธี Cross-Validation เช่น k-fold cross-validation ซึ่งตั้งอยู่บนสมมติฐานว่าข้อมูลมีความเป็นอิสระและแจกแจงเหมือนกัน (independent and identically distributed: i.i.d.) อย่างไรก็ตาม ข้อมูลอนุกรมเวลา (time series data) มีลักษณะพึ่งพากันตามลำดับเวลา (temporal dependence) ทำให้สมมติฐานดังกล่าวไม่เป็นจริง ดังนั้นจึงมีการพัฒนาแนวทาง Time Series Cross-Validation เพื่อให้เหมาะสมกับข้อมูลลักษณะนี้ โดยรักษาลำดับเวลาของข้อมูลและหลีกเลี่ยงการนำข้อมูลในอนาคตไปใช้ในการฝึกตัวแบบ ซึ่งอาจก่อให้เกิดปัญหา data leakage และทำให้ผลการประเมินมีความเอนเอียง (biased estimation) (Kuhn & Johnson, 2013)

แนวคิดของ Time Series Cross-Validation

Time Series Cross-Validation เป็นวิธีการแบ่งข้อมูลออกเป็นชุดฝึก (training set) และชุดทดสอบ (validation/test set) โดยคำนึงถึงลำดับเวลาเป็นสำคัญ กล่าวคือ ข้อมูลในอดีตจะถูกใช้ในการฝึกตัวแบบ ขณะที่ข้อมูลในอนาคตจะถูกใช้ในการทดสอบเท่านั้น แนวคิดดังกล่าวช่วยลดความเสี่ยงของ look-ahead bias และทำให้ผลการประเมินสะท้อนประสิทธิภาพของตัวแบบในสถานการณ์จริงได้ดียิ่งขึ้น (Hyndman & Athanasopoulos, 2021)

รูปแบบของ Time Series Cross-Validation

รูปแบบที่นิยมใช้ในการประเมินตัวแบบสำหรับข้อมูลอนุกรมเวลา ได้แก่

1.Expanding Window Approachเป็นวิธีที่เริ่มจากชุดข้อมูลฝึกขนาดเล็ก และเพิ่มข้อมูลในอดีตเข้าไปทีละช่วงเวลา โดยใช้ข้อมูลถัดไปเป็นชุดทดสอบ วิธีนี้สะท้อนสถานการณ์ที่ข้อมูลมีการสะสมเพิ่มขึ้นอย่างต่อเนื่อง

2.Rolling Window Approach เป็นวิธีที่กำหนดขนาดของชุดข้อมูลฝึกให้คงที่ และเลื่อนช่วงเวลาไปข้างหน้า วิธีนี้เหมาะกับข้อมูลที่มีการเปลี่ยนแปลงโครงสร้างตามเวลา (non-stationary data)

3.Walk-forward Validation เป็นการทำซ้ำกระบวนการฝึกและทดสอบหลายรอบ โดยเลื่อนช่วงข้อมูลไปข้างหน้าในแต่ละรอบ ซึ่งเป็นวิธีที่นิยมใช้ในงานพยากรณ์อนุกรมเวลา

การประยุกต์ใช้ในงานวิจัยนี้

ในงานวิจัยนี้ ซึ่งมีการวิเคราะห์ข้อมูลการแข่งขันฟอร์มูล่าวันที่มีลักษณะตามลำดับเวลา เช่น ผลการแข่งขันในแต่ละฤดูกาลและข้อมูลสมรรถนะของสนาม ผู้วิจัยเลือกใช้ Time Series Cross-Validation เพื่อให้การประเมินตัวแบบมีความสอดคล้องกับสถานการณ์จริง โดยใช้ข้อมูลในอดีตเพื่อพยากรณ์ผลลัพธ์ในอนาคต และหลีกเลี่ยงการใช้ข้อมูลในอนาคตในการฝึกตัวแบบ

กรณีที่ค่าประสิทธิภาพของชุดทดสอบสูงกว่าชุดฝึก

โดยทั่วไป ตัวแบบทาง Machine Learning มักมีค่าประสิทธิภาพบนชุดข้อมูลฝึก (training set) สูงกว่าชุดข้อมูลทดสอบ (test set) อย่างไรก็ตาม ในบางกรณีอาจพบว่าค่าประสิทธิภาพบนชุดทดสอบสูงกว่าชุดฝึก ซึ่งสามารถอธิบายได้จากหลายปัจจัย ดังนี้

1. ความแตกต่างของการแจกแจงข้อมูล (Distribution Shift) หากชุดข้อมูลทดสอบมีลักษณะที่ง่ายต่อการทำนายมากกว่า อาจทำให้ค่าประสิทธิภาพของชุดทดสอบสูงกว่าได้ (Hastie et al., 2009)

2. ความแปรปรวนจากการสุ่มตัวอย่าง (Sampling Variability) ในกรณีที่ข้อมูลมีขนาดจำกัด การแบ่งข้อมูลอาจทำให้เกิดความแปรปรวนสูง ส่งผลให้ค่าประสิทธิภาพมีความไม่แน่นอน (James et al., 2021)

3. อิทธิพลของเทคนิค Regularization ฟังก์ชันความสูญเสียในชุดข้อมูลฝึกที่รวมค่าปรับโทษ (penalty term) อาจทำให้ค่าประสิทธิภาพในชุดฝึกต่ำกว่าชุดทดสอบได้

4. ความเอนเอียงจากการสุ่มแบ่งข้อมูล (Sampling Bias) หากชุดข้อมูลทดสอบประกอบด้วยตัวอย่างที่มีลักษณะง่าย อาจทำให้ผลการประเมินสูงกว่าความเป็นจริง

5. ความผิดพลาดของข้อมูล (Noise และ Label Error) ความแตกต่างของระดับ noise หรือความผิดพลาดของป้ายกำกับระหว่างชุดข้อมูลฝึกและชุดทดสอบอาจส่งผลต่อค่าประสิทธิภาพอย่างมีนัยสำคัญ

การตีความในบริบทของงานวิจัยนี้

สำหรับงานวิจัยนี้ ซึ่งใช้ข้อมูลการแข่งขันฟอร์มูล่าวันที่มีการเปลี่ยนแปลงตามฤดูกาล อาจเกิดกรณีที่ค่าประสิทธิภาพของชุดทดสอบสูงกว่าชุดฝึกได้ เนื่องจากความแตกต่างของลักษณะสนามหรือสภาพการแข่งขันในแต่ละช่วงเวลา ดังนั้น ผู้วิจัยจึงเลือกใช้ Time Series Cross-Validation ร่วมกับการประเมินผลหลายรูปแบบ เพื่อให้ผลลัพธ์ที่ได้มีความน่าเชื่อถือและสะท้อนประสิทธิภาพของตัวแบบได้อย่างเหมาะสม

2.3 การแปลผลตัวแบบ

2.3.1 Shapley Additive Explanations (SHAP)

Shapley Additive Explanations (SHAP)เป็นเครื่องมือสำหรับวิเคราะห์ผลลัพธ์ของตัวแบบการเรียนรู้ของเครื่อง ที่พัฒนาภายใต้แนวคิด Explainable AI (XAI) หรือการทำให้ตัวแบบปัญญาประดิษฐ์สามารถตีความได้ SHAP ใช้หลักการ Shapley Value จากทฤษฎีเกม เพื่ออธิบายและตีความผลลัพธ์ของตัวแบบ โดยเฉพาะในงานที่เกี่ยวข้องกับ XAI (Lundberg & Lee, 2017; ทินรัตน์ อารมย์สุข, 2565) SHAP พัฒนาโดย Lundberg และ Lee (2017) ช่วยสร้างความโปร่งใสในการตัดสินใจของตัวแบบ และช่วยในการทำความเข้าใจว่าคุณลักษณะ แต่ละตัวมีผลอย่างไรต่อการทำนาย ของตัวแบบนั้น ๆ SHAP จึงเป็นเครื่องมือที่มีประโยชน์ในการอธิบายการทำงานของตัวแบบที่ซับซ้อน เช่น การตัดสินใจของ Deep Learning, Gradient Boosting หรือ Random Forests นอกจากนี้ SHAP ยังถูกนำมาใช้ในการทำ Feature Selection โดยใช้คุณสมบัติของ Feature Importance ที่ช่วยในการประเมินความสำคัญของคุณลักษณะในตัวแบบต่าง ๆ ได้อย่างมีประสิทธิภาพ

หลักการทั่วไปของ Shapley Value

หลักการของ Shapley Value มาจากทฤษฎีเกมที่ถูกนำมาใช้เพื่อการกระจายผลตอบแทนในเกมแบบร่วมมือ (Cooperative Game Theory) โดยที่

ผู้เล่น (Player) คือคุณลักษณะ (features) ในข้อมูล

เกม (Game) คือตัวแบบที่ทำนายการ (prediction model) โดยมีการรวบรวมตัวของคุณลักษณะหลายตัว

ผลตอบแทน (Payout) คือการทำนายผลหรือการตัดสินใจที่ได้จากตัวแบบ

หลักการของ Shapley Value คือการหาวิธีการกระจายผลตอบแทนที่เป็นธรรมระหว่างผู้เล่น (ในที่นี้คือคุณลักษณะ) โดยคำนึงถึงบทบาทและความสำคัญของแต่ละผู้เล่นในทุกๆ การรวมตัวกันของผู้เล่นต่างๆ. กล่าวอีกนัยหนึ่ง, Shapley Value คือวิธีการประเมินว่าแต่ละคุณลักษณะมีผลต่อการทำนายผลลัพธ์ของตัวแบบอย่างไร ในทางปฏิบัติ Shapley Value ของแต่ละคุณลักษณะจะแสดงถึงผลกระทบที่มันมีต่อการทำนายในบริบทของตัวแบบที่ใช้ข้อมูลทั้งหมด โดยแต่ละค่า Shapley จะคำนวณจากการที่คุณลักษณะตัวนั้นมีส่วนร่วมในตัวแบบภายใต้การรวมกันที่แตกต่างกันของคุณลักษณะทั้งหมด

หลักการทั่วไปของการประมาณค่า Shapley Value

การคำนวณ Shapley Value
สำหรับแต่ละคุณลักษณะนั้นสามารถทำได้โดยการคำนวณค่าโดยการใช้ Monte Carlo Sampling หรือการสุ่มตัวอย่างแบบสุ่มจากชุดข้อมูลเพื่อหาค่าประมาณของ Shapley Value โดยการใช้หลักการต่อไปนี้

$$\hat{\phi}_j = \frac{1}{M}\sum_{m=1}^{M}\left(\hat{f}(x_{+j}^{m}) - \hat{f}(x_{-j}^{m})\right)$$

โดยที่

j = ลำดับของคุณลักษณะ (Feature) ที่ต้องการหาค่า Shapley

x = ข้อมูลที่สนใจ

M = จำนวนรอบทั้งหมดในการทำซ้ำ ใน Monte Carlo Sampling

m = ลำดับของรอบในการทำซ้ำ

$\hat{f}(x_{+j}^{m})$ = ผลลัพธ์ของการทำนายโดยใช้คุณลักษณะj ในการทำนายข้อมูลตัวอย่างที่ m

$\hat{f}(x_{-j}^{m})$ = ผลลัพธ์ของการทำนายโดยไม่ใช้คุณลักษณะjในการทำนายข้อมูลตัวอย่างที่ m

กระบวนการในการประมาณค่า Shapley Value

1) เริ่มต้นกำหนดให้ x เป็นข้อมูลที่ต้องการทำนาย j เป็นคุณลักษณะที่ต้องการคำนวณค่า Shapley
2) ใช้การสุ่มตัวอย่างแบบ Monte Carlo ในการสร้างตัวอย่างข้อมูลที่มีและไม่มีคุณลักษณะ j
3) คำนวณผลลัพธ์ ในแต่ละรอบการทำซ้ำ m ครั้ง คำนวณค่าผลลัพธ์จากตัวแบบโดยใช้คุณลักษณะ j และไม่ใช้คุณลักษณะ j และคำนวณผลต่างระหว่างค่าผลลัพธ์ทั้งสอง
4) คำนวณค่าเฉลี่ยของผลต่างจากการทำซ้ำทั้งหมดเพื่อหาค่า Shapley Value สำหรับคุณลักษณะ j

2.4 งานวิจัยที่เกี่ยวข้องกับการแข่งขันฟอร์มูล่าวัน

การแข่งขันฟอร์มูล่าวัน (Formula 1: F1) เป็นกิจกรรมกีฬายานยนต์ที่ซับซ้อน ซึ่งได้รับผลกระทบจากปัจจัยหลากหลายทั้งด้านสมรรถนะของนักขับ ยานพาหนะ กลยุทธ์ทีม และสภาพแวดล้อมในวันแข่ง งานวิจัยในอดีตได้ใช้เทคนิค Machine Learning เพื่อวิเคราะห์และทำนายผลการแข่งขัน รวมถึงศึกษาปัจจัยที่ส่งผลต่อสมรรถนะและพฤติกรรมของนักขับในสนามแข่งขันต่าง ๆ

El Haber et al. (2021) ได้นำเสนอการประยุกต์ใช้ Random Forest ร่วมกับ SHAP เพื่อทำนายผู้ชนะการแข่งขัน Formula 1 โดยใช้ข้อมูลประวัติการแข่งขันที่ครอบคลุมตัวแปรเกี่ยวกับสมรรถนะของนักขับและสภาพการแข่งขัน ผลการศึกษาชี้ให้เห็นว่าตัวแบบดังกล่าวสามารถบรรลุความแม่นยำสูงในการทำนายผลการแข่งขัน พร้อมทั้งเพิ่มความสามารถในการอธิบายตัวแปรสำคัญที่ส่งผลต่อผลลัพธ์ ช่วยให้ทีมผู้ผลิตสามารถนำข้อมูลไปใช้ประกอบการวางกลยุทธ์และตัดสินใจได้อย่างมีประสิทธิภาพ นอกจากนี้ ผู้วิจัยยังมีแผนที่จะพัฒนาตัวแบบด้วยการบูรณาการข้อมูลแบบทันที เช่น ข้อมูลโทรมาตร (Telemetry) และสภาพอากาศ เพื่อเพิ่มความแม่นยำและความยืดหยุ่นของตัวแบบในสถานการณ์จริง (El Haber et al., 2021)

Zhao (2024) ได้ใช้ Deep Neural Network (DNN) ในการทำนายเวลาต่อรอบที่เร็วที่สุดในรอบ Qualifying ของการแข่งขันฟอร์มูล่าวัน โดยโครงข่ายประสาทเทียมถูกออกแบบมาเพื่อเรียนรู้ลักษณะเฉพาะของนักขับแต่ละคนและสนามแข่งขันต่าง ๆ ผลการศึกษาแสดงให้เห็นว่า DNN มีประสิทธิภาพและความสามารถในการปรับตัวที่เหนือกว่าวิธีการทางสถิติแบบดั้งเดิม เช่น การถดถอยเชิงเส้น อย่างไรก็ตาม ตัวแบบดังกล่าวยังมีข้อจำกัดในเรื่องการรวมข้อมูลปัจจัยภายนอก เช่น สภาพอากาศและสถานะของนักขับ ซึ่งมีผลต่อสมรรถนะการขับขี่และผลการแข่งขัน งานวิจัยนี้จึงเสนอแนวทางการพัฒนาเพื่อบูรณาการข้อมูล

เพิ่มเติมและสนับสนุนการประเมินสมรรถนะนักขับ รวมถึงการวางแผนกลยุทธ์ที่มีความแม่นยำมากขึ้นในอนาคต (Zhao, 2024)

Jesper de Groote (2021) ได้ศึกษาเชิงปริมาณเกี่ยวกับพฤติกรรมการแซงในฟอร์มูล่าวัน ช่วงยุค Pirelli ระหว่างปี 2011 ถึง 2018 โดยใช้ตัวแบบ Poisson วิเคราะห์ข้อมูลระดับนักขับ พบว่าการลดลงของการแซงเกิดจากหลายปัจจัย ได้แก่ การเปลี่ยนแปลงด้านอากาศพลศาสตร์ของรถยนต์ซึ่งทำให้การแซงทำได้ยากขึ้น รวมถึงการลดขนาดสนามแข่งขันและกลยุทธ์การแข่งขันที่มีความสม่ำเสมอขึ้น นอกจากนี้ แม้ว่าปัจจัยสนามแข่งขันจะไม่ส่งผลต่อความเปลี่ยนแปลงของจำนวนการแซงในแต่ละฤดูกาลอย่างชัดเจน แต่ความแตกต่างระหว่างสนามแข่งขันยังคงมีนัยสำคัญ โดยสนามแข่งที่ออกแบบได้ดี เช่น สนามแข่งอิสตันบูล พาร์ก (Istanbul Park) มีอัตราการแซงสูงกว่าสนามโมนาโก (Monaco) ถึงเกือบ 8 เท่า งานวิจัยนี้ชี้ให้เห็นถึงความสำคัญของการออกแบบสนามแข่งขันที่เหมาะสมในการส่งเสริมการแซงและการแข่งขันที่มีความน่าตื่นเต้น (de Groote, 2021)

Choi (2025) ได้ทำการศึกษาความสัมพันธ์ระหว่าง ลักษณะของสนามแข่งฟอร์มูล่าวัน กับสมรรถนะของทีมผู้ผลิตโดยใช้วิธีการจัดกลุ่มสนามตามคุณลักษณะเชิงกายภาพและทางวิศวกรรม ได้แก่ สนามความเร็วสูง สนามเทคนิค และสนามสมดุลเพื่อวิเคราะห์ว่าทีมใดได้เปรียบหรือเสียเปรียบในสนามแต่ละประเภท การจัดกลุ่มดังกล่าวอ้างอิงจากข้อมูลเชิงปริมาณ เช่น ความเร็วเฉลี่ยของสนาม จำนวนโค้ง ความยาวทางตรง และการเปลี่ยนระดับความสูง ซึ่งเป็นตัวกำหนดรูปแบบความต้องการของรถในด้านอากาศพลศาสตร์ แรงกด และพละกำลังของเครื่องยนต์ ผลการวิเคราะห์พบว่า ความเหมาะสมระหว่างการออกแบบรถกับลักษณะสนาม เป็นปัจจัยสำคัญที่ทำให้เกิดช่องว่างของผลงานระหว่างทีมต่าง ๆ ในแต่ละรายการแข่งขัน โดยทีมที่มี ประสิทธิภาพด้านอากาศพลศาสตร์และพละกำลังเครื่องยนต์สูง เช่น ทีมเรดบูล เรซซิ่ง (Red Bull Racing) สามารถทำผลงานเหนือกว่าอย่างชัดเจนในสนามความเร็วสูง เช่น สนามแข่งนานาชาติบาห์เรน, สนามแข่งมอนซา และ สนามแข่งเซอร์กิตเดอสปา-ฟรองโกชองส์ ในขณะที่ทีมที่มีแรงกดสูงและการควบคุมรถที่ดี เช่น ทีมแม็คลาเรน (McLaren) และ ทีมแอสตัน มาร์ติน (Aston Martin) ทำผลงานดีกว่าในสนามเทคนิคอย่าง สนามแข่ง เดอ โมนาโก และ สนามแข่งมารีน่าเบย์สตรีท นอกจากนี้ สนามประเภทสมดุล ซึ่งต้องใช้ทั้งความเร็วและแรงกด ทำให้ทีมที่มีรถสมดุล เช่น ทีม เมอร์เซเดส-เบนซ์ (Mercedes) มีความได้เปรียบมากกว่า (Choi, 2025) ชี้ให้เห็นว่าโครงสร้างทางวิศวกรรมของรถแข่งในแต่ละทีมมีผลต่อการสร้าง “ข้อได้เปรียบเชิงกลยุทธ์” บนสนามที่แตกต่างกัน และความสัมพันธ์ระหว่างสนามกับสมรรถนะของรถเป็นปัจจัยสำคัญที่อธิบายช่องว่างผลงานระหว่างทีมชั้นนำและทีมระดับกลางตลอดฤดูกาล (Choi, 2025)

งานวิจัยของทินรัตน์ อารมย์สุข (2565) ได้ศึกษาการตีความตัวแบบการเรียนรู้ของเครื่องด้วย SHAP (Shapley Additive Explanations) เพื่อแสดงกระบวนการสร้างความสามารถในการอธิบายตัวแบบสำหรับปัญหาการคัดแยก และการถดถอย โดยใช้กรณีศึกษาการคัดแยกผู้ป่วย COVID-19 และการทำนายค่ารักษาพยาบาล งานวิจัยนี้ใช้ตัวแบบหลากหลาย เช่น Logistic Regression, Decision Tree, Random Forest, SVMs, XGBoost และ Multi-layer Perceptron (MLP) สำหรับปัญหาการคัดแยก และ Linear Regression, Random Forest Regressor, XGBoost Regressor สำหรับปัญหาการถดถอย โดยตัวแบบ XGBoost ถูกนำมาใช้ร่วมกับ SHAP เพื่อสร้าง “Glass-Box” Model ที่สามารถอธิบายการตัดสินใจของตัวแบบได้อย่างชัดเจน ผลการวิจัยพบว่า SHAP สามารถช่วยคัดเลือกคุณสมบัติที่สำคัญได้อย่างมีประสิทธิภาพ ลดต้นทุนการคำนวณในขณะที่ยังรักษาค่าความแม่นยำของตัวแบบไว้ได้สูง อีกทั้งช่วยเพิ่มความเข้าใจในพฤติกรรมของตัวแบบและการเลือกใช้คุณสมบัติที่สำคัญที่สุดสำหรับการทำนายได้อย่างมีประสิทธิภาพ (ทินรัตน์ อารมย์สุข, 2565)

บทที่ 3 การดำเนินงานวิจัย

การศึกษาวิจัยนี้จัดทำเพื่อวิเคราะห์ปัจจัยที่ส่งผลต่อการได้คะแนนนักขับฟอร์มูล่าวัน โดยอาศัยเทคนิคการเรียนรู้ของเครื่อง (Machine Learning) สามารถแบ่งเนื้อหาออกเป็นหัวข้อย่อยดังต่อไปนี้

3.1 การรวบรวมข้อมูล

ในการศึกษาครั้งนี้ ผู้วิจัยได้รวบรวมข้อมูลทุติยภูมิ จากแหล่งข้อมูลที่เกี่ยวข้องกับการแข่งขันรถฟอร์มูล่าวัน ครอบคลุมระยะเวลาตั้งแต่ปี ค.ศ. 2019–2024 ซึ่งเมื่อรวบรวมเสร็จสิ้นจะได้ชุดข้อมูลหลัก (Master Dataset) ที่มีจำนวนตัวอย่างรวมทั้งสิ้น 2,559 ตัวอย่าง (Observations) โดยประกอบด้วยข้อมูลย่อยจำนวน 16 ชุดข้อมูล จาก 3 แหล่งข้อมูลหลัก ดังนี้

1) **Ergast API**

แหล่งข้อมูลสถิติผลการแข่งขันฟอร์มูล่าวันแต่เนื่องจากข้อจำกัดในการเข้าถึงข้อมูลจาก Ergast API ในช่วงเวลาที่ดำเนินการวิจัย ผู้วิจัยจึงใช้ชุดข้อมูลสำรองจากแพลตฟอร์ม Kaggle (ชื่อชุดข้อมูล: Formula 1 World Championship 1950–2020) ซึ่งเผยแพร่โดย Rohan Rao (ชื่อผู้ใช้: Vopani) โดยชุดข้อมูลดังกล่าวเป็นการรวบรวมข้อมูลจาก Ergast API ไว้ล่วงหน้า และมีโครงสร้างข้อมูลที่สอดคล้องกับแหล่งข้อมูลเดิม ประกอบด้วยข้อมูลการแข่งขัน คะแนนสะสม รายชื่อนักขับ ทีมผู้ผลิต และสนามแข่งขัน โดยผู้วิจัยได้คัดเลือกเฉพาะข้อมูลในช่วงปี ค.ศ. 2019–2024 เพื่อใช้ในการศึกษา จำนวน 14 ชุดข้อมูล ประกอบด้วยข้อมูล ได้แก่ pit_stops, qualifying, races, results, seasons, sprint_results, status, circuits, constructor_results, constructor_standings, constructors, driver_standings, drivers และ lap_times ตั้งแต่ปี 2019–2024

2) **Pirelli Motorsport**

แหล่งข้อมูลทางวิศวกรรมของสนามแข่งขัน จำนวน 1 ชุดข้อมูล ซึ่งครอบคลุมสนามทั้งหมด 31 สนาม โดยประกอบด้วยตัวแปรสำคัญ เช่น ระยะทางต่อรอบ, จำนวนโค้ง และค่าระดับคุณลักษณะของสนาม ซึ่งข้อมูลชุดนี้เป็นส่วนสำคัญที่จะนำไปใช้ในการวิเคราะห์เพื่อจำแนกและจัดกลุ่มลักษณะของสนามแข่งขัน ตามวัตถุประสงค์ของงานวิจัย

3) **Open-Meteo API**

แหล่งข้อมูลสภาพอากาศรายชั่วโมง จำนวน 1 ชุดข้อมูล ได้แก่ อุณหภูมิ, ความเร็วลม และปริมาณน้ำฝน ณ ช่วงเวลาการแข่งขัน เพื่อใช้เป็นตัวแปรอิสระในการวิเคราะห์ผลกระทบของสภาพอากาศที่มีต่อผลการแข่งขัน

ในการรวบรวมข้อมูล ผู้วิจัยใช้จัดเก็บข้อมูลให้อยู่ในรูปแบบไฟล์ .csv โดยข้อมูลจากทั้ง 3 แหล่งจะถูกบูรณาการเป็น Dataframe เข้าด้วยกันผ่านตัวแปรเชื่อมโยงหลัก คือ รหัสการแข่งขัน เพื่อสร้างเป็นฐานข้อมูลกลางที่มีความครบถ้วนสมบูรณ์ ก่อนนำไปวิเคราะห์ผลในลำดับถัดไปโดยใช้โปรแกรม Rstudio

3.2 การเตรียมข้อมูล

เมื่อรวบรวมข้อมูลครบถ้วนแล้ว ขั้นตอนต่อมาคือการเตรียมข้อมูล เพื่อให้ข้อมูลพร้อมสำหรับการวิเคราะห์และสร้างตัวแบบ กระบวนการนี้ประกอบด้วยขั้นตอนสำคัญดังนี้

1) การทำความสะอาดข้อมูล ตรวจสอบและจัดการกับค่าที่หายไป และค่าผิดปกติ

2) การจัดรูปแบบข้อมูล แปลงข้อมูลให้อยู่ในรูปแบบที่เหมาะสม เช่น วันที่, ชื่อสนาม, ชื่อนักขับ และแปลงคะแนนของการแข่งขันฟอร์มูล่าวันของนักขับในแต่ละสนามออกเป็น 2 กลุ่ม โดยอิงจากระบบการให้คะแนนอย่างเป็นทางการของการแข่งขันฟอร์มูล่าวัน (Formula 1, 2023) ดังนี้

กลุ่มที่ได้คะแนน คือกลุ่มนักขับที่สามารถทำคะแนนสะสมได้ในการแข่งขัน ได้แก่ นักขับที่เข้าเส้นชัยในอันดับที่ 1–10 ของแต่ละสนาม

กลุ่มที่ไม่ได้คะแนน คือกลุ่มนักขับที่ไม่สามารถทำคะแนนสะสมได้ในการแข่งขัน ได้แก่ นักขับที่เข้าเส้นชัยในอันดับที่ 11–20 ของแต่ละสนาม

ในการกำหนดตัวแปรตามกลุ่มนักขับ ผู้วิจัยได้รวมนักขับที่ไม่จบการแข่งขัน (Did Not Finish: DNF) ไว้ในกลุ่มที่ไม่ได้คะแนน เนื่องจากตามระเบียบการแข่งขันกลุ่มนี้จะไม่ได้รับคะแนนสะสม ซึ่งช่วยให้ตัวแบบสามารถเรียนรู้ความเสี่ยงทางกายภาพของสนามที่มีอัตราการแข่งไม่จบสูงได้ดียิ่งขึ้น

3) การเข้ารหัสตัวแปรหมวดหมู่ สำหรับตัวแปรเชิงหมวดหมู่ที่มีจำนวนระดับมาก เช่น ชื่อทีมผู้ผลิตและเชื้อชาติของนักขับ ผู้วิจัยกำหนด threshold ขั้นต่ำที่ 10 ครั้งในชุดฝึก หากหมวดหมู่ใดปรากฏน้อยกว่า 10 ครั้งจะถูกรวมเข้าเป็นกลุ่ม "Other" เพื่อลดปัญหา sparse categories จากนั้นแปลงตัวแปรหมวดหมู่ทั้งหมดด้วย One-Hot Encoding (dummyVars) โดยใช้ข้อมูลจากชุดฝึกเป็นฐานในการกำหนด levels เพื่อป้องกันการรั่วไหลของข้อมูล (Data Leakage)

3.3 ตัวแปรที่ใช้ในงานวิจัย

ในการวิเคราะห์งานวิจัยนี้แบ่งตัวแปรออกเป็น **2** กลุ่มหลัก ได้แก่

กลุ่มที่ 1 กลุ่มตัวแปรสำหรับการจัดกลุ่มสนามแข่งขัน

เพื่อจัดกลุ่มสนามแข่งขันตามลักษณะและพฤติกรรมที่คล้ายคลึงกัน ในแต่ละฤดูกาลได้เลือกใช้ตัวแปรที่สะท้อนคุณลักษณะของสนาม ดังนี้

1) คุณลักษณะทางกายภาพของสนาม

ตารางที่ 3.1 ตารางคุณลักษณะทางกายภาพของสนาม

ชื่อตัวแปร	คำอธิบาย	ประเภทของตัวแปร
Number of Turns (จำนวนโค้ง)	จำนวนโค้งหรือมุมเลี้ยวทั้งหมดในสนามแข่งรถ	ตัวแปรเชิงปริมาณ
Race Distance (ระยะทางต่อรอบ)	ระยะทางที่รถจะต้องวิ่งใน 1 รอบ ของสนามหน่วยกิโลเมตร	ตัวแปรเชิงปริมาณ
Circuit Length (ระยะทางรวมของการแข่งขัน)	ระยะทางทั้งหมดที่รถต้องวิ่งในการแข่งขันทั้งหมด	ตัวแปรเชิงปริมาณ
Number of Laps (จำนวนรอบ)	จำนวนรอบที่ผู้ขับต้องวิ่งจนครบการแข่งขัน	ตัวแปรเชิงปริมาณ

2) คุณลักษณะทางเทคนิคของสนาม

ตารางที่ 3.2 ตารางคุณลักษณะทางเทคนิคของสนาม

ชื่อตัวแปร	คำอธิบาย	ประเภทของตัวแปร
Tire Stress Level (การสึกหรอของยาง)	ค่าระดับความเครียดหรือความสึกหรอของสนามที่กระทำกับยางรถ ระดับ (1-5)	ตัวแปรเชิงคุณภาพ
Latera Level (แรงเหวี่ยงด้านข้าง)	ค่าระดับแรงด้านข้างที่เกิดขึ้นกับรถเมื่อเข้าโค้ง ระดับ (1-5)	ตัวแปรเชิงคุณภาพ
Downforce Level (ความต้องการแรงกดอากาศ)	แรงกดจากอากาศที่กดรถลงกับพื้น ระดับ (1-5)	ตัวแปรเชิงคุณภาพ
Asphalt Grip (การยึดเกาะของพื้นสนาม)	ความสามารถของพื้นสนามในการยึดเกาะยางรถ ระดับ (1-5)	ตัวแปรเชิงคุณภาพ
Asphalt Abrasion (การขูดผิวพื้นสนาม)	ความหยาบหรือความสึกหรอของผิวสนามที่มีต่อยางรถ ระดับ (1-5)	ตัวแปรเชิงคุณภาพ

กลุ่มที่ 2 กลุ่มตัวแปรสำหรับการพยากรณ์ผลการแข่งขัน

ตัวแปรตาม (Y) กลุ่มคะแนนที่นักขับได้รับจากการแข่งขัน

ตารางที่ 3.3 ตารางตัวแปรตาม(y)

ชื่อตัวแปร	คำอธิบาย	ประเภทของตัวแปร
Score_group (กลุ่มนักขับ)	ตัวแปรที่จัดกลุ่มนักขับตามคะแนนที่ได้รับในแต่ละสนาม (กลุ่มที่ได้คะแนน = อันดับ 1-10 กลุ่มที่ไม่ได้คะแนน = อันดับ 11-20)	ตัวแปรเชิงคุณภาพ

ตัวแปรอิสระ(X) ข้อมูลก่อนการแข่งขันจริง ที่ใช้เป็นปัจจัยในการทำนาย ที่ใช้ในตัวแบบมีดังนี้

1) ข้อมูลพื้นฐานของนักขับและทีม

ตารางที่ 3.4 ตารางข้อมูลพื้นฐานของนักขับและทีม

ชื่อตัวแปร	คำอธิบาย	ประเภทของตัวแปร
ConstructorRef (ชื่อที่มผู้สร้าง)	ทีมผู้ผลิต เช่น “Ferrari” “McLaren”	ตัวแปรเชิงคุณภาพ
Age (อายุนักขับ)	อายุของนักขับ	ตัวแปรเชิงปริมาณ
Nationality (สัญชาติ)	สัญชาติของนักขับ เช่น “British” “German”	ตัวแปรเชิงคุณภาพ

2) ข้อมูลประสบการณ์และผลงาน

ตารางที่ 3.5 ตารางข้อมูลประสบการณ์และผลงาน

ชื่อตัวแปร	คำอธิบาย	ประเภทของตัวแปร
Driver_Podium (จำนวนโพเดียมของนักขับ)	จำนวนสนามที่นักขับเคยขึ้นโพเดียม(ได้อันดับ1-3)	ตัวแปรเชิงปริมาณ
Constructor_Wins (จำนวนชนะของทีมผู้ผลิต)	จำนวนสนามที่ทีมผู้ผลิตเคยขึ้นโพเดียม(ได้อันดับ1-3)	ตัวแปรเชิงปริมาณ
Driver_Experience (ประสบการณ์ของนักขับ)	จำนวนสนามที่นักขับเคยลงแข่ง	ตัวแปรเชิงปริมาณ
Driver_Constructor_Exp (จำนวนประสบการณ์ของนักขับในทีม)	จำนวนสนามที่นักขับและทีมผู้ผลิตเคยร่วมงานกัน	ตัวแปรเชิงปริมาณ

Prev_Total_Points (คะแนนสะสมทั้งหมดของนักขับ)	คะแนนสะสมก่อนเข้าสู่สนามปัจจุบัน	ตัวแปรเชิงปริมาณ

3) ข้อมูลสนามในรูปแบบกลุ่ม

ตารางที่ 3.6 ตารางข้อมูลสนามในรูปแบบกลุ่ม

ชื่อตัวแปร	คำอธิบาย	ประเภทของตัวแปร
Circuit Cluster (การจัดกลุ่มสนาม)	ตัวแปรกลุ่มของสนามจากกระบวนการจัดกลุ่ม	ตัวแปรเชิงคุณภาพ

4) ข้อมูลการแข่งขัน

ตารางที่ 3.7 ตารางข้อมูลการแข่งขัน

ชื่อตัวแปร	**คำอธิบาย**	**ประเภทของตัวแปร**
Grid (อันดับการออกตัว)	อันดับออกตัวของนักขับในสนามนั้น	ตัวแปรเชิงปริมาณ
Constructor_DNF_Score (คะแนนการไม่จบการแข่งขันของทีมผู้ผลิต)	ค่าคะแนนเฉลี่ยของการไม่จบการแข่งขันของทีมผู้ผลิต	ตัวแปรเชิงปริมาณ

5) ข้อมูลสภาพอากาศและบริบทการแข่งขัน

ตารางที่ 3.8 ตารางข้อมูลสภาพอากาศและบริบทการแข่งขัน

ชื่อตัวแปร	คำอธิบาย	ประเภทของตัวแปร
Avg_temperature (ค่าเฉลี่ยอุณหภูมิ)	ค่าเฉลี่ยอุณหภูมิ (°C) ตลอดช่วงเวลาการแข่งขันในแต่ละสนาม	ตัวแปรเชิงปริมาณ
Avg_rain (ค่าเฉลี่ยปริมาณฝน)	ค่าเฉลี่ยปริมาณฝน (mm) ระหว่างการแข่งขันในแต่ละสนาม ใช้สะท้อนความเปียกของสนาม	ตัวแปรเชิงปริมาณ
Avg_wind_speed (ค่าเฉลี่ยความเร็วลม)	ค่าเฉลี่ยความเร็วลม (km/h) ระหว่างการแข่งขันในแต่ละสนาม	ตัวแปรเชิงปริมาณ
Round (ลำดับของสนาม)	ลำดับของสนามที่จัดการแข่งของฤดูกาลนั้นๆ	ตัวแปรเชิงปริมาณ

3.4 การวิเคราะห์ข้อมูลเบื้องต้น

ก่อนเข้าสู่กระบวนการสร้างตัวแบบ จะทำการวิเคราะห์ข้อมูลเชิงสำรวจ และการจัดกลุ่มสนามแข่งขัน เพื่อทำความเข้าใจข้อมูลเบื้องต้นและสร้างคุณลักษณะเพิ่มเติมให้กับตัวแบบ

3.4.1 การวิเคราะห์ข้อมูลเชิงสำรวจ (Exploratory Data Analysis: EDA)

การวิเคราะห์ EDA มุ่งเน้นไปที่การทำความเข้าใจโครงสร้างและความสัมพันธ์ระหว่างตัวแปร โดยดำเนินการวิเคราะห์การกระจายตัวของข้อมูล (Distribution Analysis) ตรวจสอบการแจกแจงของตัวแปรอิสระและตัวแปรตาม เช่น อันดับการออกตัว, อายุนักขับ, ประสบการณ์ของนักขับและกลุ่มนักขับ โดยใช้แผนภูมิแท่งความถี่ (Histogram) และแผนภาพแท่ง (Bar Chart) เพื่อพิจารณาความสมดุลของข้อมูล (Data Balance) และลักษณะความเบ้ของตัวแปรต่างๆ ซึ่งจะช่วยในการตัดสินใจเลือกใช้อัลกอริทึมที่เหมาะสมอย่าง Random Forest และ XGBoost ที่มีความทนทานต่อข้อมูลที่ไม่ได้มีการแจกแจงแบบปกติ

3.4.2 การจัดกลุ่มสนามแข่งขัน (Circuit Clustering)

เพื่อทำความเข้าใจลักษณะของสนามแข่งขันในแต่ละแห่งและลดความซับซ้อนของชุดข้อมูล ผู้วิจัยได้ดำเนินการจัดกลุ่มรายการแข่งขันตามคุณลักษณะทางกายภาพและเทคนิคของสนาม โดยอาศัยเทคนิคการจัดกลุ่มแบบลำดับชั้น ซึ่งมีขั้นตอนการดำเนินงานดังนี้

1) การคัดเลือกตัวแปรและการคำนวณระยะห่างด้วยวิธีเกาเวอร์

ผู้วิจัยคัดเลือกตัวแปรลักษณะสนามแข่งขันจำนวน 9 ตัวแปร ได้แก่ จำนวนโค้ง, ระยะทางต่อรอบ, ระยะทางรวมของการแข่งขัน, จำนวนรอบ, การสึกหรอของยาง, แรงเหวี่ยงด้านข้าง, ความต้องการแรงกดอากาศ, การยึดเกาะของพื้นสนาม และการขูดผิวพื้นสนาม เนื่องจากตัวแปรเหล่านี้มีทั้งข้อมูลเชิงปริมาณและเชิงอันดับ ผู้วิจัยจึงเลือกใช้วิธีวัดระยะห่างแบบ Gower Distance ซึ่งเป็นมาตรวัดที่เหมาะสมกับข้อมูลผสม โดยจะทำการคำนวณความแตกต่างระหว่างคู่ข้อมูลเพื่อสร้างเมทริกซ์ระยะห่าง (Distance Matrix) ที่มีค่าระหว่าง 0 (คล้ายคลึงกันมาก) ถึง 1 (แตกต่างกันมาก)

2) การจัดกลุ่มด้วยวิธีลำดับชั้น (Hierarchical Clustering: Complete Linkage)

นำเมทริกซ์ระยะห่างที่ได้มาจัดกลุ่มด้วยอัลกอริทึม Hierarchical Clustering แบบรวมกลุ่ม (Agglomerative) โดยใช้เกณฑ์การรวมกลุ่มแบบ Complete Linkage (พิจารณาระยะห่างที่ไกลที่สุดระหว่างสมาชิกของสองกลุ่ม) วิธีการนี้ช่วยให้กลุ่มที่ถูกจัดออกมามีความอัดแน่น (Compact) และแต่ละกลุ่มแยกออกจากกันอย่างชัดเจน

3) การพิจารณาและกำหนดจำนวนกลุ่ม (Tree Cutting)

ผลลัพธ์จากการจัดกลุ่มจะถูกนำเสนอในรูปแบบของแผนภาพต้นไม้ (Dendrogram) ผู้วิจัยได้พิจารณาระดับความสูง (Height) บนแผนภาพร่วมกับค่าเฉลี่ยความกว้างของซิลลูเอท (Average Silhouette Width) เพื่อตัดต้นไม้และแบ่งข้อมูลออกเป็น 5 กลุ่ม โดยข้อมูลกลุ่มที่ได้จะถูกแปลงเป็นตัวแปรใหม่ชื่อ Circuit_Cluster เพื่อนำไปใช้เป็นตัวแปรอิสระในการสร้างตัวแบบพยากรณ์ต่อไป

3.5 การสร้างตัวแบบ

หลังจากเตรียมข้อมูลและคุณลักษณะต่าง ๆ ครบถ้วนแล้ว ขั้นตอนถัดมาคือการสร้างตัวแบบเพื่อทำนายการได้คะแนนของนักขับ โดยใช้วิธีการเรียนรู้ของเครื่องหลายรูปแบบเพื่อเปรียบเทียบประสิทธิภาพ ได้แก่

1) Random Forest Classifier ตัวแบบเชิงกลุ่มต้นไม้ (Ensemble Tree) ที่สุ่มเลือกตัวแปรและข้อมูลย่อยเพื่อสร้างต้นไม้หลายต้น แล้วหาผลลัพธ์ด้วยการโหวตเสียงข้างมากเหมาะกับข้อมูลที่มีความซับซ้อนและไม่เป็นเชิงเส้น

2) XGBoost (Extreme Gradient Boosting) อัลกอริทึมแบบเกรเดียนท์บูสต์ที่มีประสิทธิภาพสูง โดยสร้างต้นไม้ตัดสินใจต่อเนื่องเพื่อลดข้อผิดพลาดในแต่ละรอบ

ในการปรับค่าพารามิเตอร์และประเมินประสิทธิภาพของตัวแบบ ผู้วิจัยได้เลือกใช้เทคนิค Time Series Cross-Validation (Expanding Window) จำนวน 4 รอบ (4-Fold) เพื่อรักษาลำดับเวลาและป้องกันปัญหาการรั่วไหลของข้อมูล (Temporal Data Leakage) โดยกำหนดโครงสร้างดังนี้

รอบที่ 1 ฝึกฝนด้วยข้อมูลปี 2019 จำนวน 420 รายการ

ทดสอบประสิทธิภาพด้วยปี 2020 จำนวน 340 รายการ

รอบที่ 2 ฝึกฝนด้วยข้อมูลปี 2019–2020 จำนวน 760 รายการ

ทดสอบประสิทธิภาพด้วยปี 2021 จำนวน 440 รายการ

รอบที่ 3 ฝึกฝนด้วยข้อมูลปี 2019–2021 จำนวน 1,200 รายการ

ทดสอบประสิทธิภาพด้วยปี 2022 จำนวน 440 รายการ

รอบที่ 4 ฝึกฝนด้วยข้อมูลปี 2019–2022 จำนวน 1,640 รายการ

ทดสอบประสิทธิภาพด้วยปี 2023 จำนวน 440 รายการ

วิธีการนี้ช่วยให้ตัวแปรอิสระที่มีลักษณะสะสมตามเวลา (เช่น จำนวนโพเดียมสะสม หรือคะแนนสะสมก่อนหน้า) คงความถูกต้องตามสถานการณ์จริง โดยข้อมูลในปี 2024 (479 รายการ) จะถูกแยกไว้เป็นชุดข้อมูลทดสอบ (Test Set) ในขั้นตอนสุดท้าย

วิธีการนี้เลือกใช้แทน Random Cross-Validation เนื่องจากข้อมูลมีลำดับเวลา และตัวแปรอิสระหลายตัว เช่น จำนวนโพเดียมของนักขับ, จำนวนชนะของทีมผู้ผลิต และคะแนนสะสมทั้งหมดของนักขับคำนวณจากการสะสมข้อมูลตามลำดับเวลา หากใช้ Random Split ข้อมูลจากอนาคตจะรั่วไหลเข้าสู่ชุดฝึก (Temporal Data Leakage) ทำให้ประสิทธิภาพที่ประเมินได้สูงเกินจริง การใช้ Expanding Window จึงเป็นวิธีที่เหมาะสมที่สุดสำหรับข้อมูลประเภทนี้

3.5.1 การปรับแต่งพารามิเตอร์ของตัวแบบ (Hyperparameter Tuning)

เพื่อเพิ่มประสิทธิภาพในการพยากรณ์ ผู้วิจัยได้ดำเนินการปรับแต่งพารามิเตอร์ของตัวแบบ (Hyperparameter Tuning) โดยใช้เทคนิค Grid Search ร่วมกับกระบวนการ Time Series Cross-Validation เพื่อค้นหาค่าพารามิเตอร์ที่เหมาะสมที่สุดของแต่ละอัลกอริทึม ภายใต้เกณฑ์การประเมินผลด้วยค่า Area Under the ROC Curve (AUC) โดยตัวแบบที่ให้ค่า AUC สูงที่สุดจะถูกเลือกเป็นตัวแบบที่ดีที่สุดเพื่อนำไปประเมินผลกับชุดข้อมูลทดสอบในปี 2024

การปรับแต่งพารามิเตอร์สำหรับ Random Forest

ตัวแบบ Random Forest ผู้วิจัยมุ่งเน้นการปรับแต่งพารามิเตอร์ mtry ซึ่งเป็นจำนวนตัวแปรอิสระที่ถูกสุ่มมาใช้ในการพิจารณาแบ่งโหนดในแต่ละครั้ง โดยค่าของ mtry มีผลต่อสมดุลระหว่าง Bias และ Variance ของตัวแบบ กล่าวคือ ค่าที่ต่ำจะช่วยเพิ่มความหลากหลายของต้นไม้ แต่มีแนวโน้มเกิด Bias สูง ขณะที่ค่าที่สูงจะทำให้ต้นไม้มีลักษณะคล้ายกันมากขึ้น ส่งผลให้ Variance เพิ่มขึ้นในการศึกษานี้ โดยรายละเอียดของค่าที่ใช้ในการทดลองแสดงในตารางที่ 3.9

ตารางที่ 3.9 ตารางปรับแต่งพารามิเตอร์สำหรับ Random Forest

พารามิเตอร์	**คำอธิบาย**	**ค่าที่ใช้ในการทดลอง (Search Space)**
mtry	จำนวนตัวแปรที่สุ่มพิจารณาในแต่ละการแบ่งโหนด	$2, \sqrt{p}, \frac{p}{3}, \frac{p}{2}, p-2$
ntree	จำนวนต้นไม้ในตัวแบบ	500

การปรับแต่งพารามิเตอร์สำหรับ XGBoost

เนื่องจาก XGBoost เป็นอัลกอริทึมที่มีความยืดหยุ่นและซับซ้อนสูง ผู้วิจัยจึงกำหนดการปรับแต่งพารามิเตอร์ในหลายมิติ เพื่อควบคุมความสามารถในการเรียนรู้และลดปัญหา Overfitting โดยมีรายละเอียดดังนี้

nrounds: จำนวนรอบของการ Boosting ซึ่งมีผลต่อจำนวนต้นไม้ในตัวแบบ โดยค่าที่สูงเกินไปอาจทำให้เกิด Overfitting ในขณะที่ค่าที่ต่ำเกินไปอาจทำให้เกิด Underfitting โดยกำหนดช่วงค่าที่ 100, 200 และ 300

max_depth: ความลึกสูงสุดของต้นไม้แต่ละต้น ซึ่งควบคุมความซับซ้อนของตัวแบบ โดยกำหนดค่าเป็น 3 และ 5

eta (learning rate): อัตราการเรียนรู้ของตัวแบบ โดยค่าที่ต่ำจะช่วยให้ตัวแบบเรียนรู้ได้อย่างค่อยเป็นค่อยไปและมีความสามารถในการ generalize ที่ดีขึ้น โดยกำหนดค่าเป็น 0.05 และ 0.10

gamma: ค่าขั้นต่ำของการลด loss ที่จำเป็นสำหรับการแบ่งโหนด โดยกำหนดค่าเป็น 0 เพื่อควบคุมจำนวนการแตกโหนดและลดเวลาในการคำนวณ

colsample_bytree: สัดส่วนของตัวแปรที่ถูกสุ่มมาใช้ในการสร้างต้นไม้แต่ละต้น ซึ่งช่วยเพิ่มความหลากหลายของตัวแบบ โดยกำหนดค่าเป็น 0.7 และ 0.9

min_child_weight: ค่าขั้นต่ำของน้ำหนักข้อมูลใน leaf node ซึ่งช่วยควบคุมความซับซ้อนของตัวแบบ โดยกำหนดค่าเป็น 1 และ 5

subsample: สัดส่วนของข้อมูลตัวอย่างที่ถูกสุ่มมาใช้ในการฝึกในแต่ละรอบ โดยกำหนดค่าเป็น 0.8 เพื่อลดการเกิด Overfitting และลดภาระการคำนวณ

รายละเอียดค่าพารามิเตอร์แสดงในตารางที่ 3.10

ตารางที่ 3.10 ตารางปรับแต่งพารามิเตอร์สำหรับ XGBoost

พารามิเตอร์	**คำอธิบาย**	**ค่าที่ใช้ในการทดลอง (Search Space)**
nrounds	จำนวนรอบของการ Boosting	100, 200, 300
max_depth	ความลึกสูงสุดของต้นไม้	3, 5
eta	อัตราการเรียนรู้ (Learning Rate)	0.05, 0.10

gamma	ค่าขั้นต่ำของการลด loss สำหรับการแบ่งโหนด	0
colsample_bytree	สัดส่วนของตัวแปรที่ใช้ในแต่ละต้นไม้	0.7, 0.9
min_child_weight	น้ำหนักขั้นต่ำของข้อมูลใน leaf node	1, 5
subsample	สัดส่วนของข้อมูลที่ใช้ในแต่ละรอบ	0.8

3.6 การเปรียบเทียบประสิทธิภาพของตัวแบบ

เนื่องจากการวิจัยนี้เป็นการพยากรณ์แบบจำแนกประเภทแบบสองกลุ่ม (Binary Classification) โดยแบ่งผลลัพธ์เป็น กลุ่มที่ได้คะแนน(อันดับ 1–10) และ กลุ่มที่ไม่ได้ได้คะแนน(อันดับ 11–20) ผู้วิจัยจึงประเมินและเปรียบเทียบประสิทธิภาพของตัวแบบโดยอาศัยตัวชี้วัดดังต่อไปนี้

1) ค่า AUC-ROC (Area Under the ROC Curve) ใช้เป็นตัวชี้วัดหลักในการเปรียบเทียบและคัดเลือกตัวแบบระหว่าง Fold ใน Time Series Cross-Validation เนื่องจากสะท้อนความสามารถในการจำแนกทั้งสองกลุ่มโดยรวม โดยไม่ขึ้นอยู่กับ decision threshold

2) ค่าความแม่นยำ (Accuracy) คือสัดส่วนของการพยากรณ์ได้ถูกต้องทั้งหมดต่อจำนวนข้อมูลทดสอบทั้งหมด โดยสะท้อนภาพรวมของความถูกต้องของตัวแบบ

3) ค่า Precision คือสัดส่วนของตัวอย่างที่ถูกพยากรณ์ว่าเป็นกลุ่มทำคะแนน แล้วถูกต้องจริง แสดงถึงความแม่นยำของการทำนายเชิงบวก

4) ค่า Recall คือสัดส่วนของตัวอย่างในกลุ่มทำคะแนนจริงที่ถูกตรวจจับได้อย่างถูกต้อง สะท้อนความสามารถในการค้นหากลุ่มเป้าหมาย

5) ค่า F1-score คือค่าที่ใช้วัดความสมดุลของการพยากรณ์ โดยคำนวณจากค่า Precision และ Recall เพื่อสะท้อนภาพรวมของความแม่นยำและความครบถ้วนในการทำนาย

ทั้งนี้ AUC-ROC จาก Time Series Cross-Validation ใช้สำหรับเปรียบเทียบและคัดเลือกตัวแบบในขั้นตอน model selection ส่วนตัวชี้วัดที่เหลือ (Accuracy, Precision, Recall และ F1-score) ใช้สำหรับประเมินประสิทธิภาพสุดท้ายบนชุดทดสอบปี 2024 เพื่อให้ได้ภาพรวมที่สมบูรณ์ของสมรรถนะตัวแบบ

3.7 การแปลผลและการวิเคราะห์ปฏิสัมพันธ์ของตัวแปร

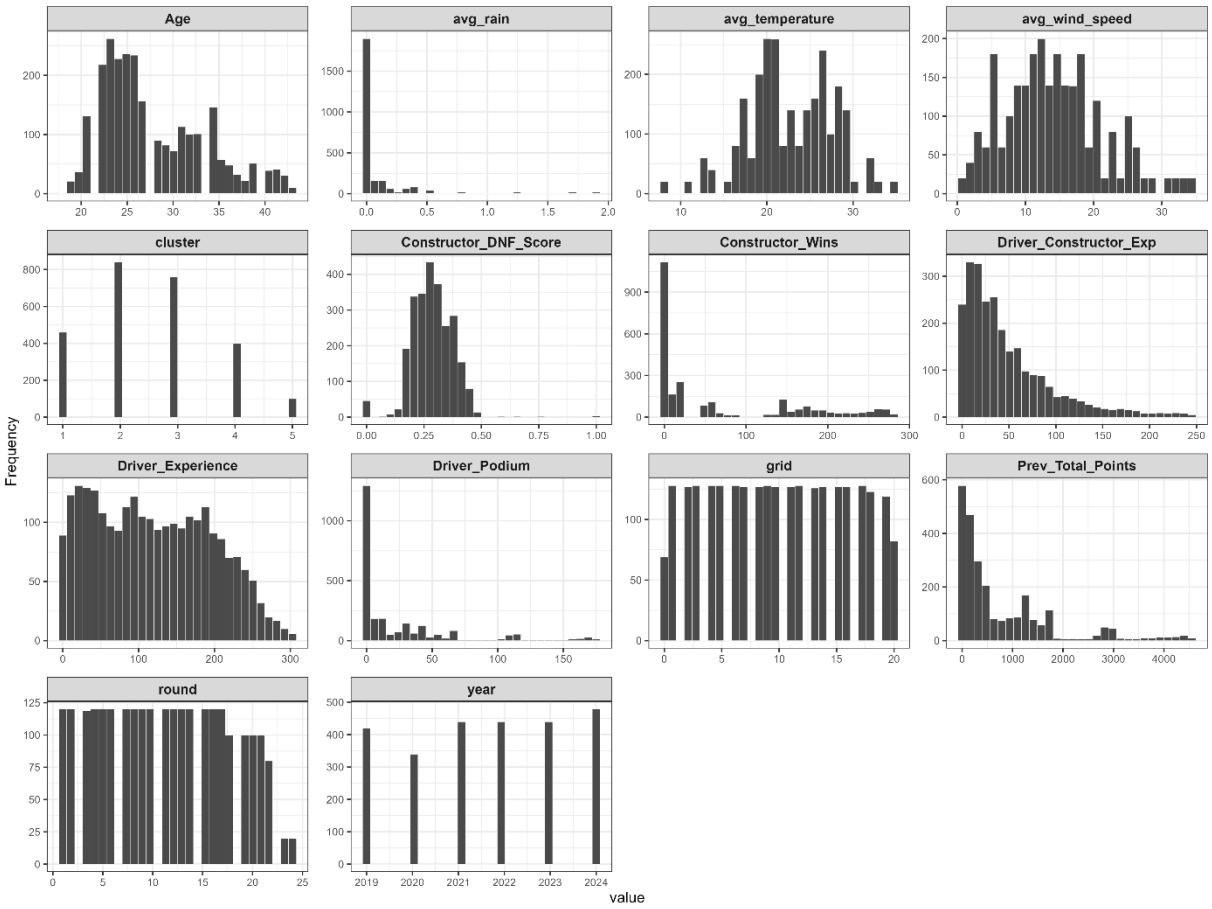
หลังจากได้ตัวแบบที่มีประสิทธิภาพสูงสุดแล้ว จะใช้เทคนิค Explainable AI (XAI) โดยเลือกใช้แนวทางของ SHAP (SHapley Additive exPlanations) ซึ่งเป็นมาตรวัดที่มีพื้นฐานมาจากทฤษฎีเกมเพื่อนำมาอธิบายการทำงานของตัวแบบพยากรณ์ให้มีความโปร่งใสและสามารถตีความได้ในเชิงประจักษ์ โดยกระบวนการเริ่มต้นจากการวิเคราะห์อิทธิพลของตัวแปรในภาพรวมเพื่อจัดลำดับความสำคัญว่าปัจจัยใดในชุดข้อมูลส่งผลกระทบต่อค่าการพยากรณ์มากที่สุด ซึ่งครอบคลุมทั้งข้อมูลด้านสมรรถนะของนักขับ ความแข็งแกร่งของทีมผู้ผลิต สภาพอากาศ และคุณลักษณะเฉพาะของกลุ่มสนามที่ได้จากการวิเคราะห์การจัดกลุ่ม โดยผลการวิเคราะห์จะถูกนำเสนอในรูปแบบ SHAP summary plot ทั้งแบบ bar plot และ beeswarm plot เพื่อแสดงลำดับความสำคัญของตัวแปร และการกระจายของค่า SHAP value ของแต่ละตัวแปรที่มีผลต่อค่าการพยากรณ์ของตัวแบบ

บทที่ 4 ผลการดำเนินงานวิจัยและการวิเคราะห์ข้อมูล

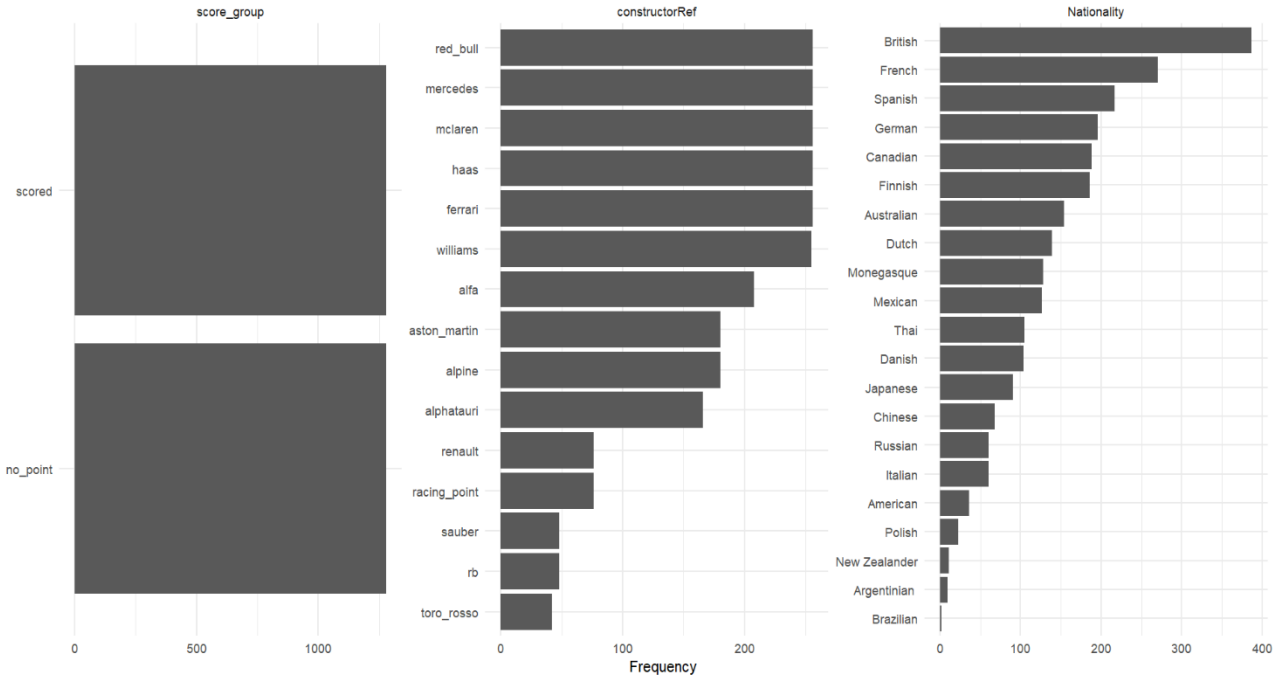
4.1 ผลการวิเคราะห์ข้อมูลเชิงสำรวจ

จากการวิเคราะห์ปัจจัยที่มีผลต่อผลการแข่งขันฟอร์มูล่าวัน ในช่วงปี 2019 ถึง 2024 จากกลุ่มตัวอย่างทั้งสิ้น 2,559 รายการ พบว่าข้อมูลพื้นฐานด้านตัวบุคคลและทีมแข่งขันมีค่าเฉลี่ยอายุของนักขับอยู่ที่ 27.81 ปี (อยู่ในช่วง 18–43 ปี) โดยนักขับมีประสบการณ์ในการแข่งขันเฉลี่ย 119.3 สนาม และมีความคุ้นเคยกับทีมต้นสังกัดปัจจุบันเฉลี่ย 48.74 สนาม ในส่วนของสถิติความสำเร็จสะสม พบว่านักขับมีจำนวนการขึ้นโพเดียมเฉลี่ย 24.69 ครั้ง ขณะที่ทีมผู้ทีมผู้ผลิต (Constructor) มีสถิติการชนะเฉลี่ยอยู่ที่ 67.8 ครั้ง อย่างไรก็ตาม ข้อมูลดังกล่าวมีการกระจายตัวค่อนข้างสูงตั้งแต่ 0 ถึง 281 ครั้งซึ่งสะท้อนให้เห็นถึงความเหลื่อมล้ำทางสมรรถนะอย่างชัดเจนระหว่างทีมระดับแถวหน้าและทีมอื่นในอุตสาหกรรมสำหรับปัจจัยด้านสภาพแวดล้อมและเทคนิค พบว่าในแต่ละรอบของการแข่งขัน (Round 1–24) อันดับการออกตัว (Grid) มีการกระจายตัวตั้งแต่ลำดับที่ 1 ถึง 20 โดยมีค่าคะแนนความเสี่ยงในการแข่งไม่จบของทีมผู้ผลิต (Constructor DNF Score) เฉลี่ยอยู่ที่ 0.2876 ในด้านสภาวะแวดล้อมทางกายภาพ อุณหภูมิเฉลี่ยในการแข่งขันอยู่ที่ 22.73 องศาเซลเซียส มีความเร็วลมเฉลี่ย 14.20 กม./ชม. และโดยส่วนใหญ่เป็นการแข่งขันในสภาวะที่ไม่มีฝนเป็นหลัก (ค่าเฉลี่ย Rain = 0.08)

นอกจากนี้ เมื่อพิจารณาการกระจายตัวของข้อมูลผ่านแผนภูมิแท่งความถี่และแผนภูมิแท่ง พบว่าตัวแปรเชิงปริมาณส่วนใหญ่ เช่น จำนวนการชนะของทีมผู้ผลิต และคะแนนสะสมของนักขับ มีลักษณะการกระจายตัวแบบเบ้ขวาอย่างชัดเจน ซึ่งตอกย้ำว่ามีนักขับและทีมเพียงส่วนน้อยเท่านั้นที่มีสถิติความสำเร็จอยู่ในระดับสูงมากเมื่อเทียบกับค่าเฉลี่ยของกลุ่ม ในขณะที่ตัวแปรเชิงคุณภาพ เช่น สัญชาติของนักขับ ทีมผู้ผลิต และกลุ่มนักขับ มีการกระจายตัวที่หลากหลายและครอบคลุม ดังปรากฏรายละเอียดลักษณะการกระจายตัวของตัวแปรเชิงปริมาณและเชิงคุณภาพในภาพที่ 4.1 และ 4.2 ตามลำดับ ซึ่งข้อมูลทั้งหมดนี้จะถูกนำไปใช้ในการทดสอบสมมติฐานในลำดับถัดไป



ภาพที่ 4.1 แผนภาพแสดงโครงสร้างข้อมูลตัวแปรเชิงปริมาณและเชิงลำดับ ซึ่งประกอบด้วยตัวแปรจำนวน 14 ตัว โดยข้อมูลเป็นตัวแปรเชิงปริมาณและเชิงลำดับที่ใช้ในการวิเคราะห์ตัวแบบ

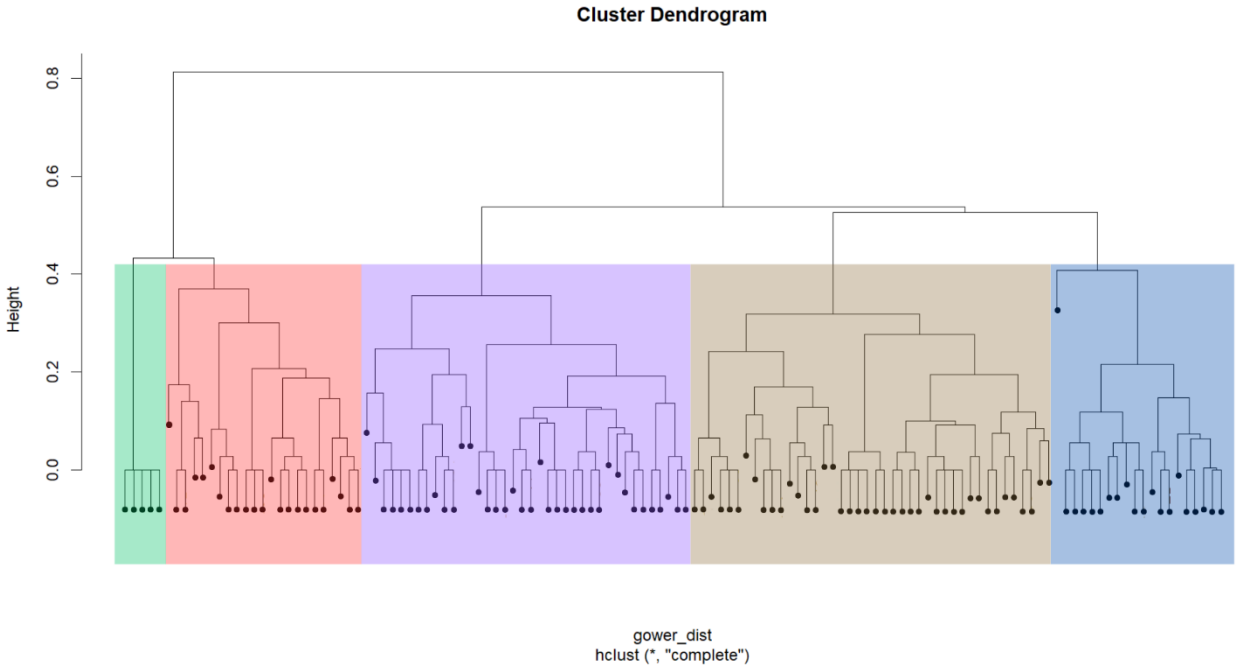


ภาพที่ 4.2 แผนภาพแสดงโครงสร้างข้อมูลตัวแปรเชิงกลุ่ม

4.2 ผลการจัดกลุ่มสนามแข่งขัน

4.2.1 การพิจารณาจำนวนกลุ่มที่เหมาะสม

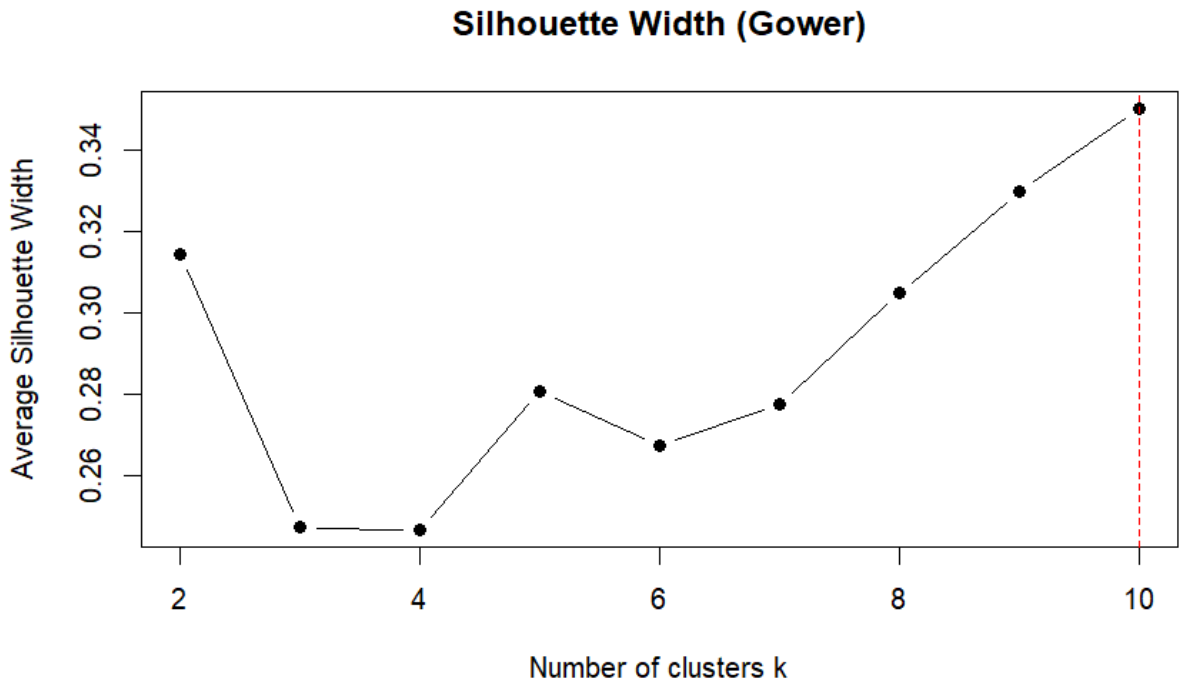
ผู้วิจัยได้นำตัวแปรลักษณะสนาม 9 ตัวแปรมาคำนวณระยะห่างด้วย Gower Distance และจัดกลุ่มด้วย Hierarchical Clustering แบบ Complete Linkage โดยผลลัพธ์ที่ได้แสดงในภาพที่ 4.3



ภาพที่ 4.3 แผนภาพเดนโดรแกรมแสดงการจัดกลุ่มรายการแข่งขันด้วยวิธี Hierarchical Clustering (Complete Linkage)

จากภาพที่ 4.3 แกนแนวตั้ง (Height) แสดงระยะห่างของ Gower Distance ระหว่างกลุ่ม โดยพบว่ามีการแยกกลุ่มที่ชัดเจนที่ระดับ Height ประมาณ 0.4–0.5 ซึ่งสนามแข่งขันโมนาโก (Monaco) แยกตัวออกมาเป็นกลุ่มพิเศษอย่างชัดเจนที่สุด สะท้อนว่าสนามโมนาโกมีลักษณะแตกต่างจากสนามอื่นอย่างมีนัยสำคัญ ทั้งนี้ แต่ละจุดบนแกนแนวนอนแทนรายการแข่งขัน 1 รายการ ซึ่งประกอบด้วยชื่อสนามแข่งขันและปีที่จัดการแข่งขัน รวมทั้งสิ้น 128 รายการ จากสนามแข่งขัน 31 สนาม ในช่วงปี ค.ศ. 2019–2024 โดยสนามที่มีการจัดแข่งขันในหลายฤดูกาลจะปรากฏเป็นหลายจุดบนแผนภาพ

เพื่อประกอบการตัดสินใจเลือกจำนวนกลุ่ม ผู้วิจัยได้พิจารณากราฟ Silhouette Width ดังแสดงในภาพที่ 4.4

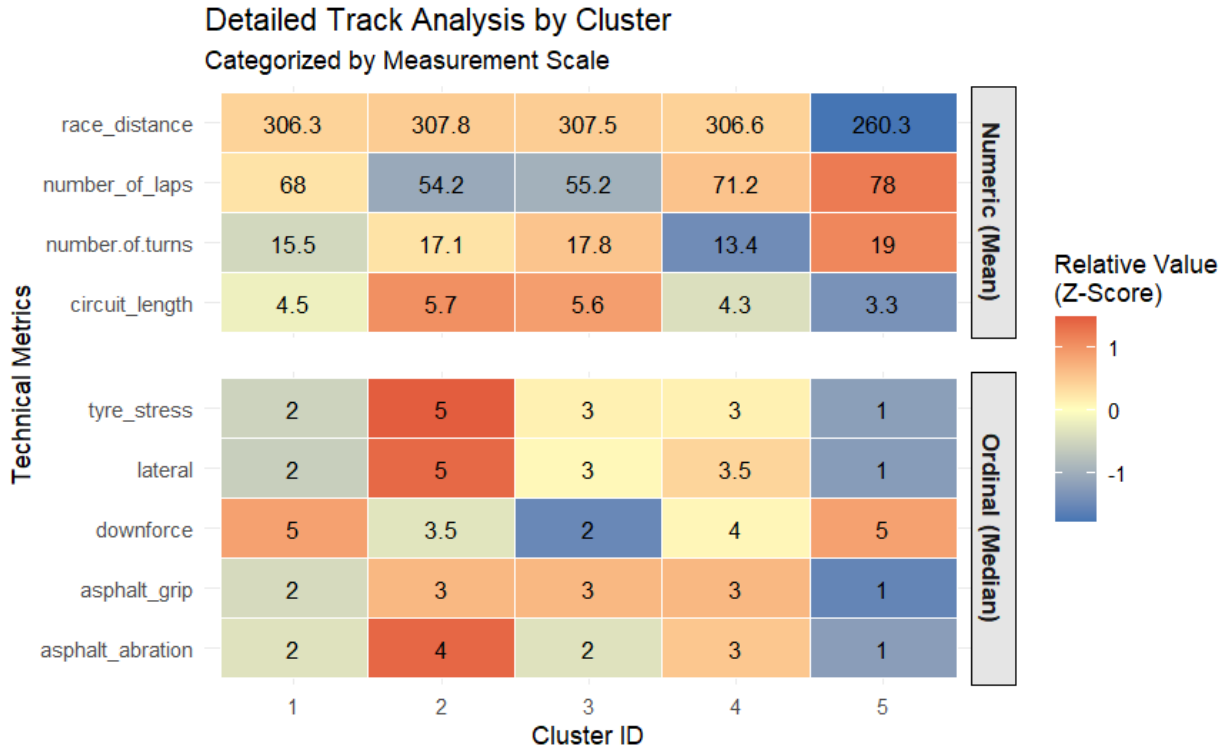


ภาพที่ 4.4 กราฟ Silhouette Width แสดงการพิจารณาจำนวนกลุ่มที่เหมาะสม

จากภาพที่ 4.4 ค่า Average Silhouette Width แม้ว่าค่าทางสถิติจะแสดงแนวโน้มที่สูงขึ้นเมื่อจำนวนกลุ่ม เพิ่มขึ้นไปถึง k=10 อย่างไรก็ตาม ผู้วิจัยวิเคราะห์ว่าการเลือกจำนวนกลุ่มที่มากเกินไป อาจส่งผลให้แต่ละกลุ่มมีจำนวนรายการข้อมูลน้อยเกินไป จนตัวแบบพยากรณ์เกิดปัญหาการเรียนรู้ที่จำเพาะเจาะจงกับชุดข้อมูลฝึกฝนมากเกินไป (Overfitting) และส่งผลให้ตัวแบบขาดความสามารถในการปรับใช้หรือพยากรณ์ผลลัพธ์ในสนามแข่งขันใหม่ ๆ ในอนาคตได้อย่างมีประสิทธิภาพ ดังนั้น ผู้วิจัยจึงตัดสินใจเลือกแบ่งกลุ่มที่ k=5 เนื่องจากเป็นจุดที่สร้างสมดุล ระหว่างความละเอียดทางสถิติและความสมเหตุสมผลเชิงบริบทของการแข่งขันฟอร์มูล่าวัน การเลือกที่ k=5 ไม่เพียงแต่ช่วยลดความซับซ้อนของตัวแบบ แต่ยังให้การแบ่งกลุ่มที่มีความหมายชัดเจนในเชิงวิศวกรรมสนามและพฤติกรรมการแข่งขัน ซึ่งเอื้อต่อการนำผลการวิเคราะห์อิทธิพลของปัจจัย (SHAP Value) ไปตีความเพื่อใช้ประโยชน์ในเชิงกลยุทธ์ได้อย่างเป็นรูปธรรมมากกว่าการแบ่งกลุ่มที่ละเอียดจนเกินไป

4.2.2 ลักษณะเด่นของแต่ละกลุ่ม

เพื่อทำความเข้าใจลักษณะเฉพาะของแต่ละกลุ่มสนาม ผู้วิจัยได้สรุปค่าเฉลี่ยและค่ามัธยฐานของตัวแปรลักษณะสนามในแต่ละกลุ่มแสดงในภาพที่ 4.5



ภาพที่ 4.5 Heatmap แสดงค่าเฉลี่ยและค่ามัธยฐานลักษณะสนามแข่งขันในแต่ละกลุ่ม

จากภาพที่ 4.5 แสดงค่าเฉลี่ยของตัวแปรเชิงปริมาณ และค่ามัธยฐานของตัวแปรเชิงอันดับ ในแต่ละกลุ่มสนาม โดยระดับสีในแผนภาพสะท้อนถึงการเปรียบเทียบกับค่าเฉลี่ยรวมของทุกสนาม ซึ่ง แถบสีแดงแสดงถึงลักษณะที่มีค่าสูงกว่าค่าเฉลี่ยรวม และ แถบสีน้ำเงินแสดงถึงลักษณะที่มีค่าต่ำกว่าค่าเฉลี่ยรวม ทั้งนี้สามารถสรุปลักษณะเด่นของแต่ละกลุ่มสนามได้ดังนี้

กลุ่มที่ 1 จำนวน 23 สนาม

เป็นกลุ่มสนามที่มีความยาวปานกลาง และมีจำนวนโค้งในระดับปานกลาง โดยมีความต้องการแรงกดอากาศ ในระดับสูง ขณะที่ปัจจัยอื่น ๆ เช่น การสึกหรอของยาง, แรงเหวี่ยงด้านข้าง และการขูดผิวพื้นสนามอยู่ในระดับต่ำกว่าค่าเฉลี่ย สะท้อนถึงลักษณะสนามที่เน้นสมดุลระหว่างความเร็วและการยึดเกาะ

กลุ่มที่ 2 จำนวน 42 สนาม

กลุ่มนี้ประกอบด้วยสนามที่มีความยาวมากและจำนวนรอบค่อนข้างน้อย โดยมีจำนวนโค้งในระดับปานกลาง อย่างไรก็ตาม พบว่าการสึกหรอของยาง, แรงเหวี่ยงด้านข้าง และการขูดผิวพื้นสนาม อยู่ในระดับสูงมาก แสดงถึงลักษณะสนามที่ส่งผลต่อการสึกหรอของยางอย่างรุนแรง ในขณะที่ค่าความต้องการแรงกดอากาศ และการยึดเกาะของพื้นสนาม อยู่ในระดับปานกลาง

กลุ่มที่ 3 จำนวน 38 สนาม

เป็นกลุ่มสนามที่มีความยาวมากและจำนวนรอบน้อย แต่มีจำนวนโค้งค่อนข้างสูง โดยความต้องการแรงกดอากาศอยู่ในระดับต่ำมาก ขณะที่ปัจจัยอื่นอยู่ในระดับปานกลาง และมีค่าการขูดผิวพื้นสนามค่อนข้างต่ำ สะท้อนถึงสนามที่เน้นความเร็วทางตรงมากกว่าการยึดเกาะในโค้ง

กลุ่มที่ 4 จำนวน 20 สนาม

กลุ่มนี้เป็นสนามที่มีความยาวปานกลาง และมีจำนวนโค้งน้อยมาก โดยมีค่าความต้องการแรงกดอากาศค่อนข้างสูง ในขณะที่ตัวแปรอื่น ๆ อยู่ในระดับปานกลาง ลักษณะดังกล่าวบ่งชี้ว่าสนามในกลุ่มนี้อาจต้องการเสถียรภาพของรถในช่วงความเร็วสูง แม้จำนวนโค้งจะไม่มาก

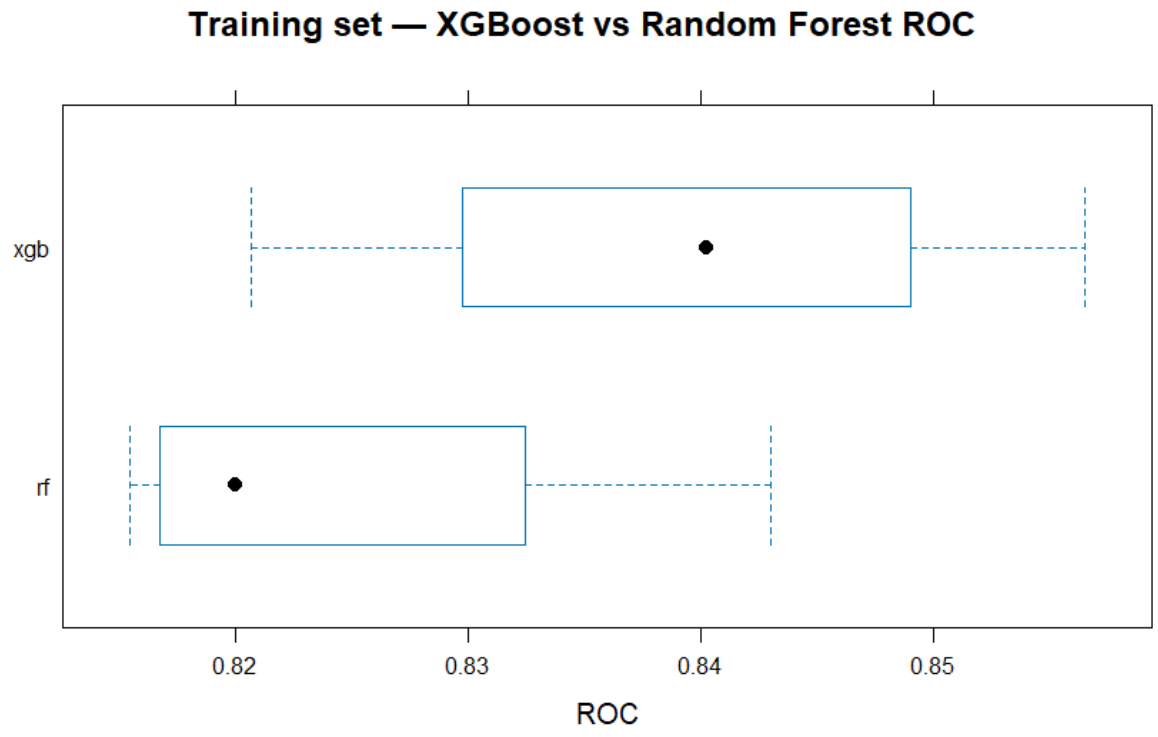
กลุ่มที่ 5 จำนวน 5 สนาม

เป็นกลุ่มสนามโมนาโกที่มีลักษณะเฉพาะชัดเจนซึ่งมีความยาวสั้นมากและมีจำนวนโค้งสูงมาก โดยมีความต้องการแรงกดอากาศสูงมาก ในทางตรงกันข้ามค่า การสึกหรอของยาง, แรงเหวี่ยงด้านข้าง, การยึดเกาะของพื้นสนาม และการขูดผิวพื้นสนาม อยู่ในระดับต่ำทั้งหมด สะท้อนถึงลักษณะสนามที่แคบ ความเร็วต่ำ และเน้นการควบคุมรถมากกว่าความเร็ว

4.3 การเปรียบเทียบตัวแบบ

ในการคัดเลือกตัวแบบพยากรณ์ที่มีประสิทธิภาพสูงสุด ผู้วิจัยได้ดำเนินการสร้างตัวแบบการเรียนรู้ของเครื่อง 2 อัลกอริทึมหลัก ได้แก่ Random Forest และ XGBoost โดยใช้ชุดข้อมูลฝึกฝน (Training Set) ระหว่างปี ค.ศ. 2019–2023 กระบวนการสร้างตัวแบบได้ผ่านการปรับแต่งค่าพารามิเตอร์ (Hyperparameter Tuning) ด้วยเทคนิค Grid Search ร่วมกับการประเมินผลด้วยวิธีตรวจสอบความถูกต้องไขว้แบบอนุกรมเวลา (Time Series Cross-Validation) จำนวน 4 รอบ (4-Fold) เพื่อให้ตัวแบบเรียนรู้ตามลำดับเวลาและป้องกันปัญหาข้อมูลรั่วไหล (Data Leakage)

ภายหลังจากการฝึกฝนและได้ค่าพารามิเตอร์ที่ดีที่สุดของทั้งสองอัลกอริทึม ผู้วิจัยจึงได้ทำการเปรียบเทียบประสิทธิภาพของตัวแบบ XGBoost และ Random Forest บนชุดข้อมูลฝึกฝน โดยใช้ค่าเฉลี่ยพื้นที่ใต้กราฟ (CV ROC-AUC) เป็นเกณฑ์ในการประเมินเบื้องต้น เพื่อคัดเลือกตัวแบบที่มีความเสถียรและแม่นยำที่สุด สำหรับนำไปใช้เป็นตัวแบบหลักในการศึกษาอิทธิพลของปัจจัยในลำดับถัดไป ดังแสดงผลการเปรียบเทียบในภาพที่ 4.6



ภาพที่ 4.6 กราฟ Boxplot เปรียบเทียบค่า ROC ระหว่าง XGBoost และ Random Forest

จากภาพที่ 4.6 พบว่าตัวแบบ XGBoost (XGB) ให้ค่า ROC-AUC เฉลี่ยสูงกว่า Random Forest (RF) อย่างชัดเจน โดย XGBoost มีค่า ROC-AUC เฉลี่ยประมาณ 0.840 และมีช่วงการกระจายของค่า (IQR) ที่

กว้างกว่า ซึ่งสะท้อนถึงความสามารถของตัวแบบในการเรียนรู้รูปแบบความสัมพันธ์ที่มีความซับซ้อนของข้อมูลได้ดีกว่า ในขณะที่ Random Forest มีค่า ROC-AUC เฉลี่ยประมาณ 0.820 และมีค่า IQR ที่แคบกว่า อย่างไรก็ตามค่าดังกล่าวอยู่ในระดับที่ต่ำกว่า XGBoost อย่างสม่ำเสมอ ดังนั้น ผู้วิจัยจึงเลือกใช้ XGBoost เป็นตัวแบบหลักในการศึกษาปัจจัย เนื่องจากมีประสิทธิภาพในการพยากรณ์ที่สูงกว่าเมื่อพิจารณาจากค่า ROC-AUC โดยรวม

ผลการทดสอบประสิทธิภาพบนชุดข้อมูลทดสอบ (Test Set Evaluation)

นำตัวแบบที่ผ่านการฝึกฝนมาทดสอบกับชุดข้อมูลทดสอบ (Test Set) โดยผลลัพธ์แสดงผ่าน Confusion Matrix และเกณฑ์วัดประสิทธิภาพต่าง ๆ (ดังตารางที่ 4.1 และ 4.2)

ตารางที่ 4.1 Confusion Matrix ของตัวแบบ XGBoost บนชุดข้อมูลทดสอบ

	Actual: No Point	**Actual: Scored**
Prediction: No Point	178	30
Prediction: Scored	61	210

จากตารางที่ 4.1 พบว่าตัวแบบมีความสามารถในการจำแนกผู้ที่ทำคะแนน (Scored) ได้อย่างแม่นยำ โดยมีค่า Recall สูงถึง 0.875 และเมื่อพิจารณาในภาพรวมผ่านเกณฑ์วัดประสิทธิภาพอื่น ๆ พบว่าตัวแบบให้ค่า Accuracy ที่ 0.81 และ F1-Score ที่ 0.8219 (ดังแสดงในตารางที่ 4.2)

ตารางที่ 4.2 ประสิทธิภาพของตัวแบบ XGBoost บนชุดข้อมูลทดสอบ

AUC	**Accuracy**	**Precision**	**Recall**	**F1-Score**
0.883	0.810	0.775	0.875	0.822

นอกจากนี้ เมื่อเปรียบเทียบค่าความถูกต้องของพื้นที่ใต้กราฟ (Area Under the Curve: AUC) ระหว่างขั้นตอนการฝึกฝนและขั้นตอนการทดสอบ พบประเด็นที่น่าสนใจ(ดังแสดงในตารางที่ 4.3)

ตารางที่ 4.3 การเปรียบเทียบค่า ROC-AUC ระหว่างชุดฝึกฝนและชุดทดสอบ

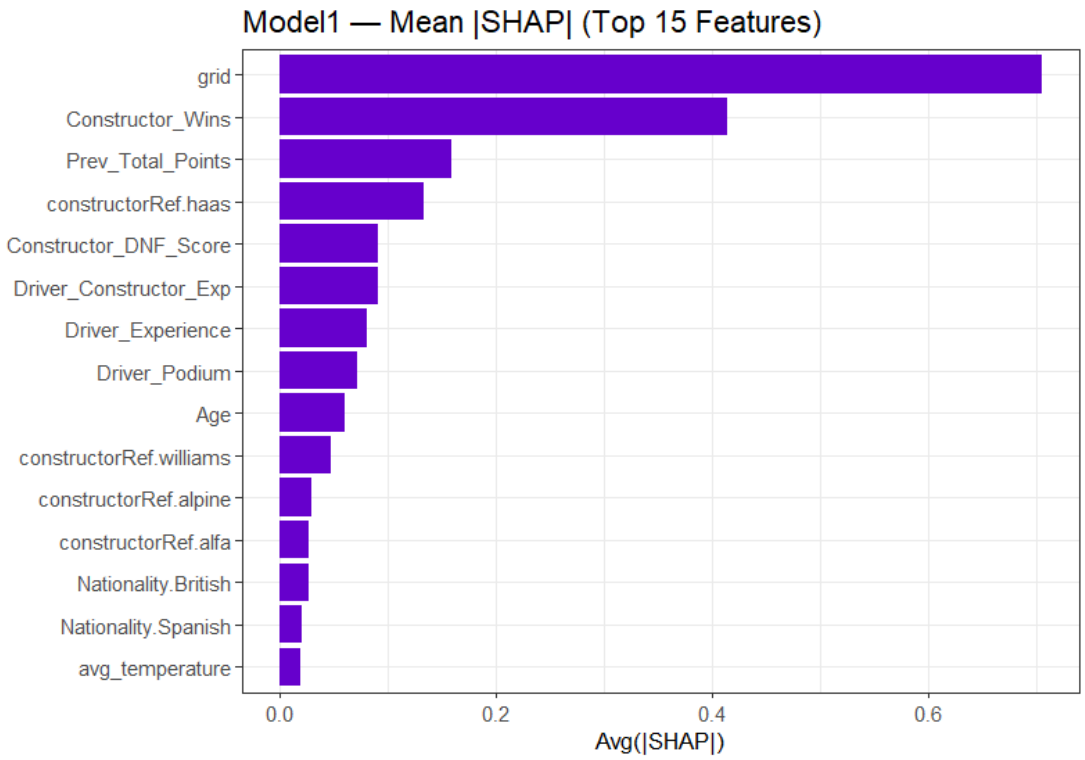
Train CV AUC	Test AUC	ส่วนต่าง (Gap)
0.8394	0.8828	-0.0434

จากตารางที่ 4.3 พบว่าค่า Test AUC (0.8828) มีประสิทธิภาพสูงกว่าค่า Train CV AUC (0.8394) ซึ่งแม้โดยปกติมักจะปรากฏในทิศทางตรงกันข้าม แต่ปรากฏการณ์นี้สามารถอธิบายได้ตามหลักการประเมินผลแบบ Time Series Cross-Validation ซึ่งมีความเข้มงวดสูงในการเรียนรู้ข้อมูลตามลำดับเวลา (Hyndman & Athanasopoulos, 2018) ส่งผลให้ค่าเฉลี่ยจากการฝึกฝนเป็นค่าพยากรณ์ที่ระมัดระวัง (Conservative estimate) นอกจากนี้ ผู้วิจัยวิเคราะห์ว่าความแตกต่างดังกล่าวเกิดจากลักษณะของการกระจายตัวของข้อมูล (Data Distribution) โดยชุดข้อมูลในปีที่ใช้สำหรับการทดสอบมีรูปแบบความสัมพันธ์ที่ชัดเจนและมีตัวแปรลบกวน (Noise) น้อยกว่าช่วงปีที่ใช้ฝึกฝน สอดคล้องกับแนวคิดของ Hastie et al. (2009) ที่ระบุว่าความคลาดเคลื่อนในการพยากรณ์สามารถผันแปรตามความซับซ้อนของกลุ่มตัวอย่าง (Sample complexity) ส่งผลให้ตัวแบบสามารถระบุรูปแบบความสัมพันธ์และทำนายผลลัพธ์ในชุดทดสอบได้แม่นยำยิ่งขึ้น

4.4 การวิเคราะห์ปัจจัยสำคัญของตัวแบบ

4.4.1 ความสำคัญของปัจจัยในภาพรวม

เพื่อวิเคราะห์ตัวแปรที่มีอิทธิพลต่อการพยากรณ์มากที่สุด ผู้วิจัยได้วิเคราะห์ค่า Mean |SHAP| ของทุกตัวแปรในตัวแบบ ดังแสดงในภาพที่ 4.7

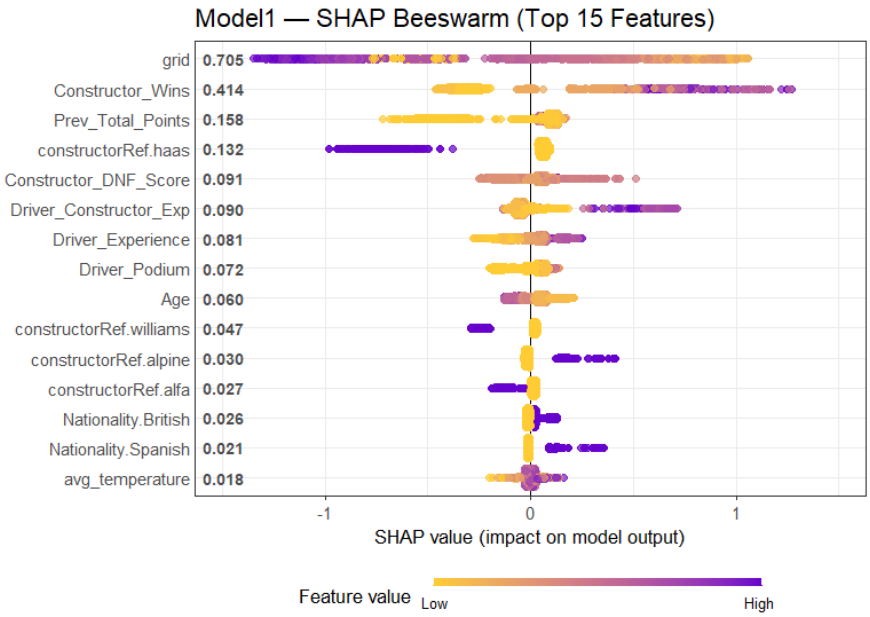


ภาพที่ 4.7 กราฟ SHAP Bar Plot แสดงค่า Mean | SHAP | ของ 15 ตัวแปรสำคัญสูงสุดในตัวแบบ

จากภาพที่ 4.7 แสดงให้เห็นว่า ตำแหน่งในการออกตัว เป็นปัจจัยที่มีอิทธิพลต่อตัวแบบพยากรณ์สูงที่สุดอย่างมีนัยสำคัญ โดยมีค่าเฉลี่ย SHAP สูงถึง 0.705 ซึ่งมากกว่าตัวแปรจำนวนชนะของทีมผู้ผลิต (Constructor Wins) (0.414) ที่อยู่ในอันดับรองลงมาเกือบ 2 เท่า และ คะแนนสะสมทั้งหมดของนักขับ (Prev Total Points)(0.158) และ ทีมฮาส(ConstructorRef Hass) (0.132) มีอิทธิพลต่อผลลัพธ์มากกว่าปัจจัยด้านสภาพแวดล้อม โดยพบว่าตัวแปรกลุ่มลักษณะสนาม 1–5 และ สภาพอากาศ มีค่าอิทธิพลอยู่ในระดับต่ำที่สุดและถูกจัดอยู่ในกลุ่มท้ายของการจัดลำดับ ข้อค้นพบนี้สะท้อนว่าตำแหน่งการออกตัวและประสิทธิภาพของทีมผู้ผลิตเป็นตัวแปรหลักในการกำหนดทิศทางของตัวแบบพยากรณ์

4.4.2 ทิศทางและขนาดของแต่ละปัจจัย

นอกเหนือจากการพิจารณาขนาดของอิทธิพล ผู้วิจัยได้ทำการวิเคราะห์ทิศทางของผลกระทบ (Directionality of Influence) ของแต่ละตัวแปรเพิ่มเติม ผ่านแผนภาพ SHAP Beeswarm ในภาพที่ 4.8 เพื่อจำแนกความสัมพันธ์ระหว่างค่าข้อมูลนำเข้าและผลลัพธ์ของตัวแบบพยากรณ์



ภาพที่ 4.8 กราฟ SHAP Beeswarm แสดงทิศทางและขนาดผลกระทบของ 15 ตัวแปรสำคัญสูงสุดในตัวแบบ

จากการวิเคราะห์ทิศทางความสัมพันธ์ผ่านแผนภาพ SHAP Beeswarm ในภาพที่ 4.8 ซึ่งแสดงค่า SHAP Value บนแกนนอน (ค่าบวกหมายถึงเพิ่มโอกาสทำคะแนน ค่าลบหมายถึงลดโอกาสทำคะแนน) และการไล่ระดับสีตามค่าของตัวแปรจากสีเหลือง (ค่าต่ำ) ไปยังสีม่วง (ค่าสูง) สามารถอธิบายความสัมพันธ์ของ

ปัจจัยที่มีอิทธิพลสูงต่อตัวแบบได้ดังนี้

ตัวแปร ตำแหน่งออกตัว(Grid) แสดงให้เห็นถึงความสัมพันธ์เชิงลบที่มีนัยสำคัญสูงสุด โดยพบว่าเมื่อค่า Grid อยู่ในระดับต่ำหรือการเริ่มแข่งขันจากแถวหน้า (แถบสีเหลือง) จะส่งผลต่อค่า SHAP ในเชิงบวกอย่างโดดเด่น (สูงสุดถึง ±1.0) ในขณะที่การออกตัวในลำดับท้ายหรือค่าตำแหน่งออกตัวสูง (แถบสีม่วง) จะส่งผลในทางตรงกันข้ามอย่างชัดเจน ซึ่งยืนยันว่าตำแหน่งเริ่มต้นเป็นปัจจัยชี้ขาดสำคัญที่สุดในการพยากรณ์โอกาสการทำคะแนน

ในส่วนของตัวแปรด้านสมรรถนะและศักยภาพของทีมผู้ผลิต พบว่า จำนวนชนะของทีมผู้ผลิต (Constructor Wins) มีความสัมพันธ์เชิงบวกกับผลลัพธ์อย่างชัดเจน โดยกลุ่มข้อมูลที่มีสถิติการชนะสูง (แถบสีม่วง) จะส่งผลกระทบเชิงบวกต่อโอกาสในการพยากรณ์ สอดคล้องกับสมมติฐานที่ว่าทีมผู้ผลิตที่มีประวัติความสำเร็จสะสมย่อมมีทรัพยากรและขีดความสามารถทางวิศวกรรมที่สูงกว่า

นอกจากนี้ เมื่อพิจารณาตัวแปรกลุ่มทีมผู้ผลิตรายเฉพาะ เช่น ทีมฮาส(ConstructorRef Haas) กลับพบรูปแบบอิทธิพลในเชิงลบอย่างสม่ำเสมอในทุกจุดข้อมูล สะท้อนให้เห็นว่าปัจจัยด้านสังกัดทีมผู้ผลิตที่มีผลงานเฉลี่ยต่ำกว่าเกณฑ์มาตรฐานในช่วงปี 2019–2024 เป็นตัวแปรที่ลดทอนโอกาสในการทำคะแนนอย่างต่อเนื่องในทุกสถานการณ์การแข่งขันสรุปได้ว่า อิทธิพลหลักที่ตัวแบบใช้ในการตัดสินใจพยากรณ์ผลลัพธ์เกิดจากการปฏิสัมพันธ์กันระหว่าง ความได้เปรียบทางตำแหน่ง และ ขีดความสามารถทางเทคนิคของทีมผู้ผลิต ซึ่งเป็นปัจจัยที่มีค่าน้ำหนักสูงกว่าปัจจัยทางด้านสภาพแวดล้อมหรือสนามแข่งขันอย่างเห็นได้ชัด

4.5 การกำหนดรูปแบบตัวแบบพยากรณ์สำหรับการเปรียบเทียบ

เพื่อให้เห็นภาพรวมของความแตกต่างในแต่ละชุดข้อมูลที่นำมาพัฒนาตัวแบบพยากรณ์ ผู้วิจัยได้กำหนดและพัฒนาตัวแบบพยากรณ์โดยใช้อัลกอริทึม XGBoost เป็นหลัก ซึ่งแบ่งออกเป็น 7 รูปแบบ (M1–M7) เพื่อใช้ในการเปรียบเทียบประสิทธิภาพและวิเคราะห์อิทธิพลของกลุ่มตัวแปรต่าง ๆ ดังนี้

ตัวแบบ M1 (มีข้อมูลทั้งหมด) เป็นตัวแบบหลักที่ใช้ตัวแปรอิสระครบทุกกลุ่ม โดยใช้ตัวแปรกลุ่มสนาม แทนตัวแปรลักษณะสนามดิบเพื่อลดมิติของข้อมูล

ตัวแบบ M2 (มีข้อมูลทั้งหมดแต่ไม่จัดกลุ่มสนาม) เป็นตัวแบบที่ใช้ตัวแปรอิสระครบทุกกลุ่มเช่นเดียวกับตัวแบบ M1 แต่ใช้ตัวแปรลักษณะทางกายภาพและเทคนิคของสนามแบบดิบ (Raw Circuit Features) ทั้ง 9 ตัวแปร

ตัวแบบ M3 (มีข้อมูลทั้งหมดแต่ตัดปัจจัยหลัก 5 อันดับออก) เป็นตัวแบบที่พัฒนาจากตัวแบบ M1 แต่ทำการตัดตัวแปรที่มีค่าอิทธิพลสูงสุด 5 อันดับแรกออก เพื่อทดสอบความสามารถในการพยากรณ์ของตัวแปรสนามและอากาศในสภาวะที่ไม่มีปัจจัยหลัก

ตัวแบบ M4 (มีข้อมูลทั้งหมดแต่ไม่จัดกลุ่มสนามตัดปัจจัยหลัก 5 อันดับออก) เป็นตัวแบบที่พัฒนาจากตัวแบบ M2 โดยทำการตัดตัวแปรที่มีค่าอิทธิพลสูงสุด 5 อันดับแรกออก เพื่อเปรียบเทียบบทบาทของตัวแปรลักษณะสนามดิบในสภาวะที่ไม่มีปัจจัยหลัก

ตัวแบบ M5 (ตัดข้อมูลการจัดกลุ่มสนามออก) เป็นตัวแบบที่ทำการตัดเฉพาะตัวแปรกลุ่มสนามออก เพื่อประเมินระดับความสำคัญของข้อมูลสนามที่มีต่อความแม่นยำ

ตัวแบบ M6 (ตัดข้อมูลสภาพอากาศออก) เป็นตัวแบบที่ทำการตัดเฉพาะตัวแปรด้านสภาพอากาศออก เพื่อวิเคราะห์ผลกระทบของสภาวะแวดล้อมต่อตัวแบบพยากรณ์

ตัวแบบ M7 (ตัดข้อมูลการจัดกลุ่มและข้อมูลสภาพอากาศออก) เป็นตัวแบบฐาน ที่ใช้เฉพาะปัจจัยด้านสมรรถนะของนักขับและทีมผู้ผลิตเท่านั้น โดยตัดทั้งตัวแปรกลุ่มสนามและสภาพอากาศออก

โดยสามารถสรุปการเลือกใช้กลุ่มตัวแปรในแต่ละตัวแบบได้ดังตารางที่ 4.4

ตารางที่ 4.4 ตารางสรุปการเลือกใช้กลุ่มตัวแปรในตัวแบบพยากรณ์แต่ละรูปแบบ (M1–M7)

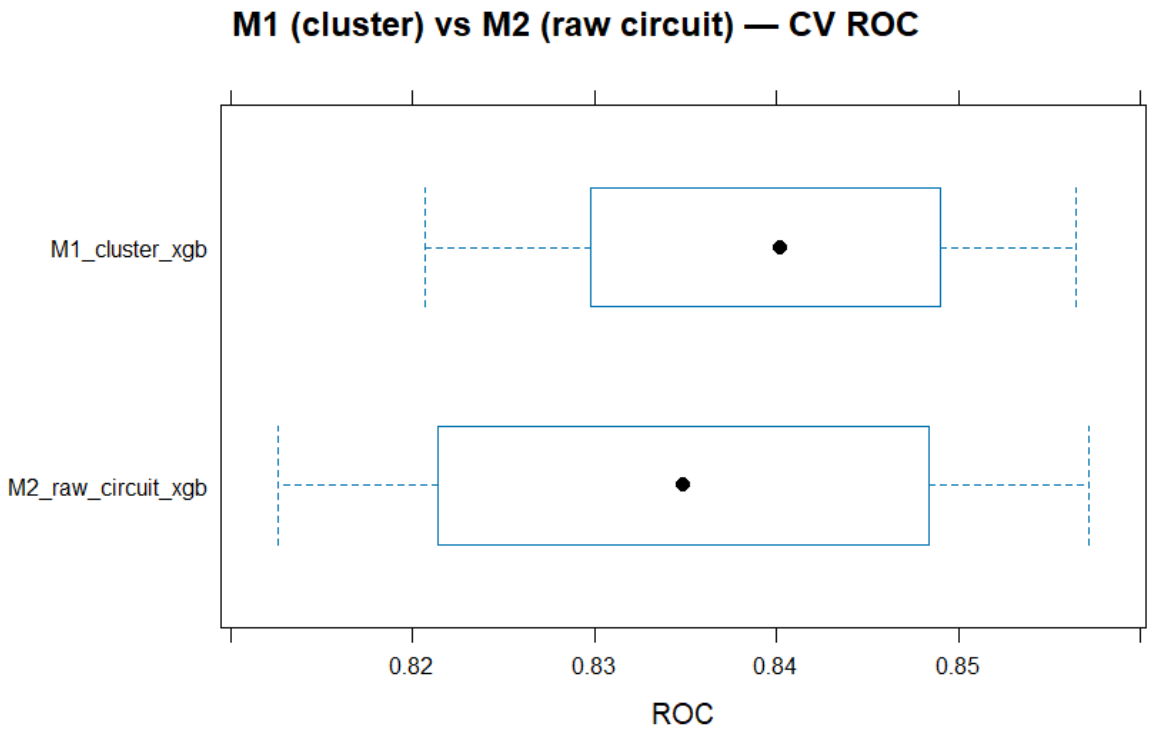
ชื่อตัวแบบ	ปัจจัยหลัก 5 อันดับ	กลุ่มสนาม	ลักษณะสนามดิบ	สภาพอากาศ
M1	✓	✓	✗	✓
M2	✓	✗	✓	✓
M3	✗	✓	✗	✓
M4	✗	✗	✓	✓
M5	✓	✗	✗	✓
M6	✓	✓	✗	✗
M7	✓	✗	✗	✗

หมายเหตุ ปัจจัยหลัก 5 อันดับแรกที่ถูกตัดออกใน M3 และ M4 ได้แก่ อันดับการออกตัว, จำนวนชนะของทีมผู้ผลิต, คะแนนสะสมทั้งหมดของนักขับ,ทีมฮาส และคะแนนการไม่จบการแข่งขันของทีมผู้ผลิต

4.5.1 การเปรียบเทียบตัวแบบ M1 กับ ตัวแบบ M2

การจัดกลุ่มสนามด้วย Hierarchical Clustering ที่ดำเนินการในบทที่ 4 ตอนต้น นำมาซึ่งคำถามสำคัญว่า การแทนที่ลักษณะสนามดิบทั้ง 9 ตัวแปรด้วยตัวแปรกลุ่มสนามเพียง 1 ตัวนั้น ส่งผลกระทบต่อความแม่นยำในการพยากรณ์อย่างไร เพื่อตอบคำถามนี้ ผู้วิจัยจึงเปรียบเทียบตัวแบบ M1 ซึ่งใช้ตัวแปรกลุ่มสนาม กับตัวแบบ M2 ซึ่งใช้ตัวแปรลักษณะสนามดิบครบทุกตัว โดยควบคุมให้ปัจจัยอื่นทุกกลุ่มมีความเหมือนกัน ผลลัพธ์ที่ได้จะชี้ให้เห็นว่าการลดมิติข้อมูลสนามสามารถรักษาประสิทธิภาพของตัวแบบไว้ได้หรือไม่

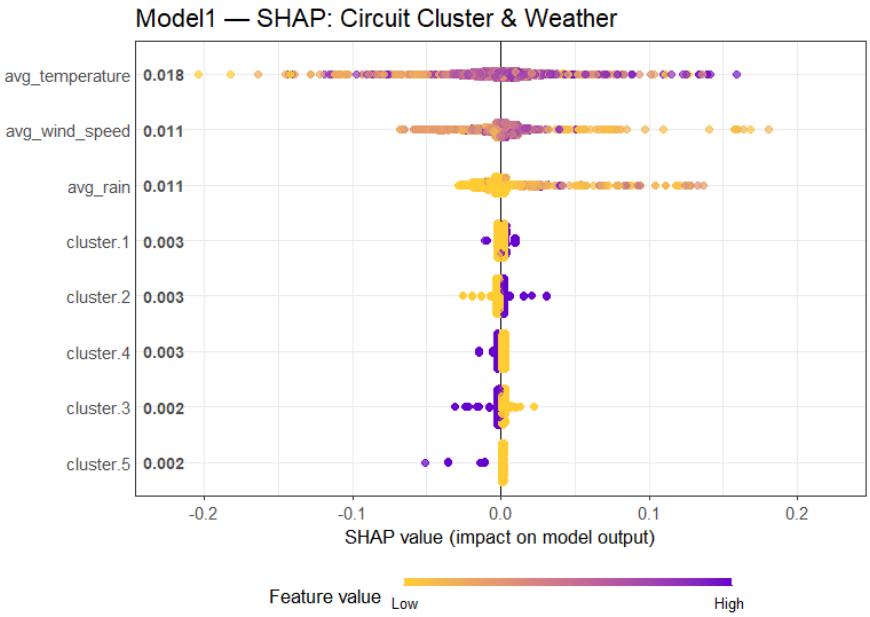
เปรียบเทียบประสิทธิภาพของตัวแบบที่ใช้ตัวแปรกลุ่มสนามเป็นตัวแบบ M1 กับตัวแบบที่ใช้ตัวแปรลักษณะสนามดิบจำนวน 9 ตัวแปรเป็นตัวแบบ M2 โดยประเมินผลบนชุดข้อมูลฝึก



ภาพที่ 4.9 กราฟ Boxplot เปรียบเทียบค่า CV ROC ระหว่างตัวแบบ M1 และตัวแบบ M2

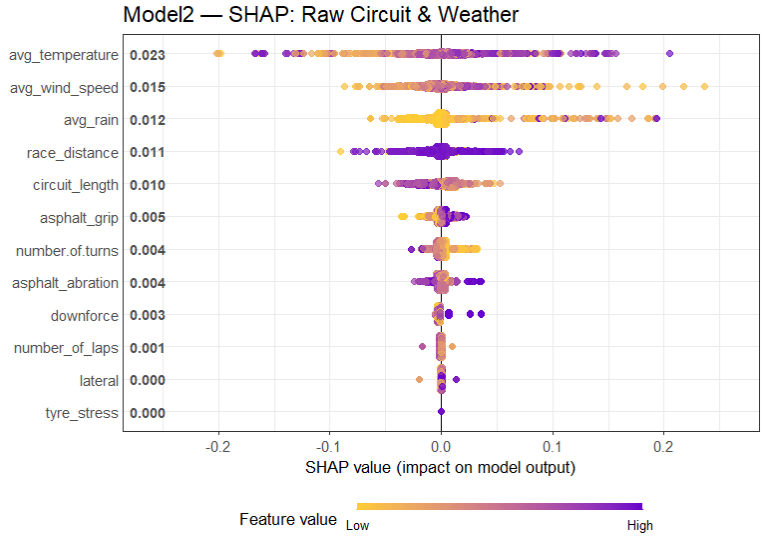
จากภาพที่ 4.9 พบว่าตัวแบบ M1 มีค่า ROC เฉลี่ยสูงกว่าเล็กน้อย (0.8394 เทียบกับ 0.8349) และมี IQR ที่แคบกว่า ซึ่งสะท้อนถึงความเสถียรในการพยากรณ์ที่มากกว่าเพียงเล็กน้อย อย่างไรก็ตาม ค่าประสิทธิภาพที่ได้นั้นไม่มีความแตกต่างกันอย่างมีนัยสำคัญ โดยการใช้ตัวแปรการจัดกลุ่มสนามเพียง 1 ตัวแทนตัวแปรลักษณะสนามเดิมทั้ง 9 ตัว ช่วยลดความซับซ้อนของตัวแบบได้ในขณะที่ยังคงรักษาระดับ

ประสิทธิภาพการพยากรณ์ไว้ได้ใกล้เคียงกับเดิมเพื่อทำความเข้าใจว่าตัวแปรสนามและสภาพอากาศมีบทบาทอย่างไรในแต่ละตัวแบบ ผู้วิจัยจึงวิเคราะห์ SHAP เฉพาะกลุ่มตัวแปรดังกล่าว ดังแสดงในภาพที่ 4.10 และ 4.11



ภาพที่ 4.10 กราฟ SHAP Beeswarm แสดงอิทธิพลของตัวแปรกลุ่มสนามและสภาพอากาศในตัวแบบ M1

จากภาพที่ 4.10 พบว่าในกลุ่มตัวแปรด้านลักษณะสนามและสภาพอากาศของตัวแบบ M1 ตัวแปรที่มีอิทธิพลสูงสุดต่อผลลัพธ์ของตัวแบบ ได้แก่ ค่าเฉลี่ยอุณหภูมิซึ่งมีค่า SHAP เท่ากับ 0.018 โดยพบว่าอุณหภูมิที่สูงมีแนวโน้มส่งผลเชิงบวกต่อค่าการพยากรณ์ของตัวแบบในระดับเล็กน้อย รองลงมาคือค่าเฉลี่ยความเร็วลมซึ่งมีค่า SHAP เท่ากับ 0.011 ขณะที่ตัวแปรการจัดกลุ่มทั้ง 5 กลุ่มมีค่า SHAP อยู่ในช่วงต่ำ (0.002–0.003) และมีการกระจุกตัวใกล้ศูนย์ สะท้อนให้เห็นว่า เมื่อมีการนำตัวแปรหลักอื่นเข้าสู่ตัวแบบแล้ว ตัวแปรที่แสดงถึงกลุ่มของสนามมีอิทธิพลต่อผลลัพธ์ของตัวแบบในระดับค่อนข้างต่ำ



ภาพที่ 4.11 กราฟ SHAP Beeswarm แสดงอิทธิพลของตัวแปรลักษณะสนามดิบและสภาพอากาศในตัวแบบ M2

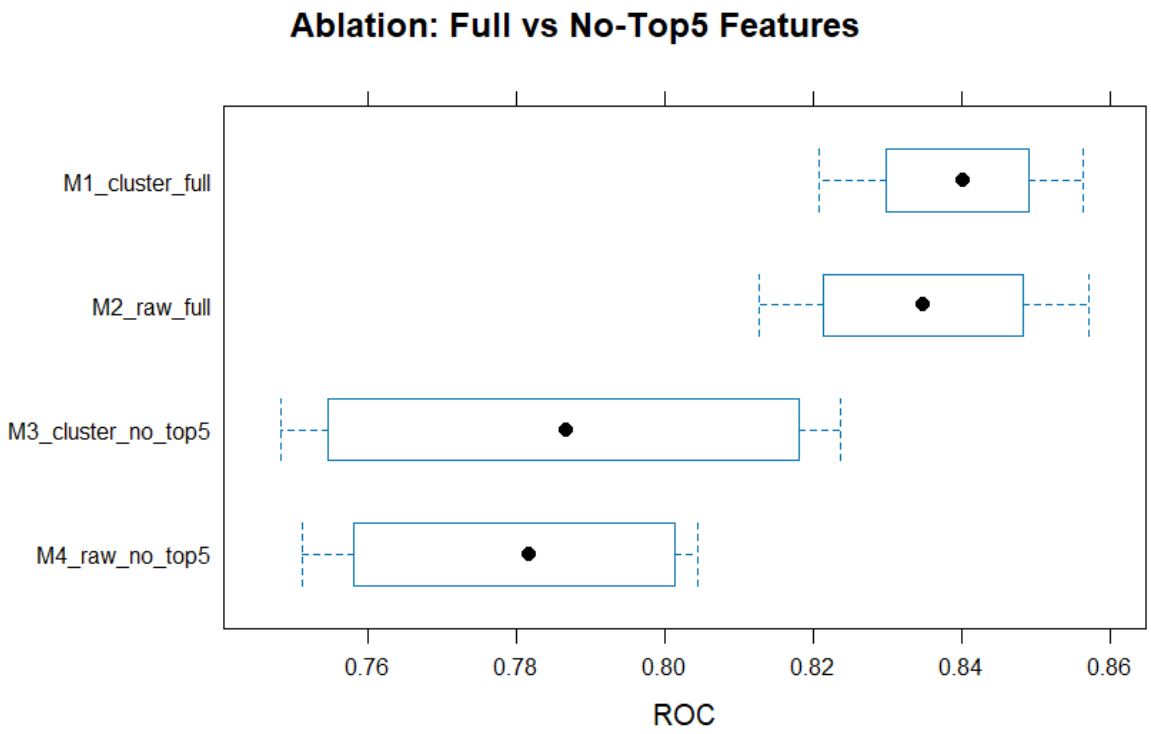
จากภาพที่ 4.11 พบว่า ในตัวแบบ M2 ตัวแปรด้านสภาพอากาศยังคงมีอิทธิพลสูงสุดในกลุ่มตัวแปรนี้ โดยตัวแปร ค่าเฉลี่ยอุณหภูมิมีค่า SHAP เท่ากับ 0.023 และ ค่าเฉลี่ยความเร็วลมมีค่า SHAP เท่ากับ 0.015 ซึ่งมีการกระจายตัวของค่า SHAP กว้างกว่าในตัวแบบ M1 แสดงให้เห็นถึงความแปรปรวนของอิทธิพลที่เพิ่มขึ้น นอกจากนี้ ตัวแปรเชิงกายภาพของสนาม ได้แก่ ระยะทางรวมของการแข่งขัน(0.012) และ ระยะทางต่อรอบ(0.011) มีระดับอิทธิพลใกล้เคียงกับตัวแปรสภาพอากาศดังกล่าว ในขณะที่ตัวแปรเชิงเทคนิคของสนาม เช่น การสึกหรอของยาง และ ความต้องการแรงกดอากาศมีค่า SHAP ใกล้ศูนย์ สะท้อนให้เห็นว่าตัวแปรในลักษณะเชิงเทคนิคมีอิทธิพลต่อผลลัพธ์ของตัวแบบน้อยกว่าตัวแปรเชิงกายภาพของสนาม เช่น ระยะทางรวมของการแข่งขันและระยะทางต่อรอบ

4.5.2 ผลลัพธ์เมื่อตัดปัจจัยอิทธิพลสูงออก

จากผลการวิเคราะห์ค่า SHAP ในหัวข้อก่อนหน้า พบว่าตัวแปรด้านตำแหน่งออกตัว และสมรรถนะของทีมผู้ผลิตมีอิทธิพลสูงเป็นอันดับต้นๆ ซึ่งอาจทำให้อิทธิพลของตัวแปรสนามและสภาพอากาศถูกบดบัง เพื่อตรวจสอบว่าตัวแปรกลุ่มสนามและอากาศมีคุณค่าอยู่จริงหรือเป็นเพียงตัวแปรรอง ผู้วิจัยจึงสร้างตัวแบบ M3 และตัวแบบ M4 โดยตัดตัวแปรที่มีอิทธิพลสูงสุด 5 อันดับแรกออก แล้วสังเกตว่าตัวแปรรองจะก้าวขึ้นมามีบทบาทอย่างไร

เนื่องจากตำแหน่งออกตัว และสมรรถนะของทีมผู้ผลิตมีอิทธิพลสูงมาก ผู้วิจัยจึงทำการทดสอบแบบลดทอนปัจจัยผ่านตัวแบบ M3 และตัวแบบ M4 เพื่อวิเคราะห์ว่าปัจจัยรองจะก้าวขึ้นมามีบทบาทอย่างไรเมื่อไม่มีปัจจัยหลักเพื่อทดสอบว่าตัวแปรสนามและสภาพอากาศยังคงมีคุณค่าต่อ

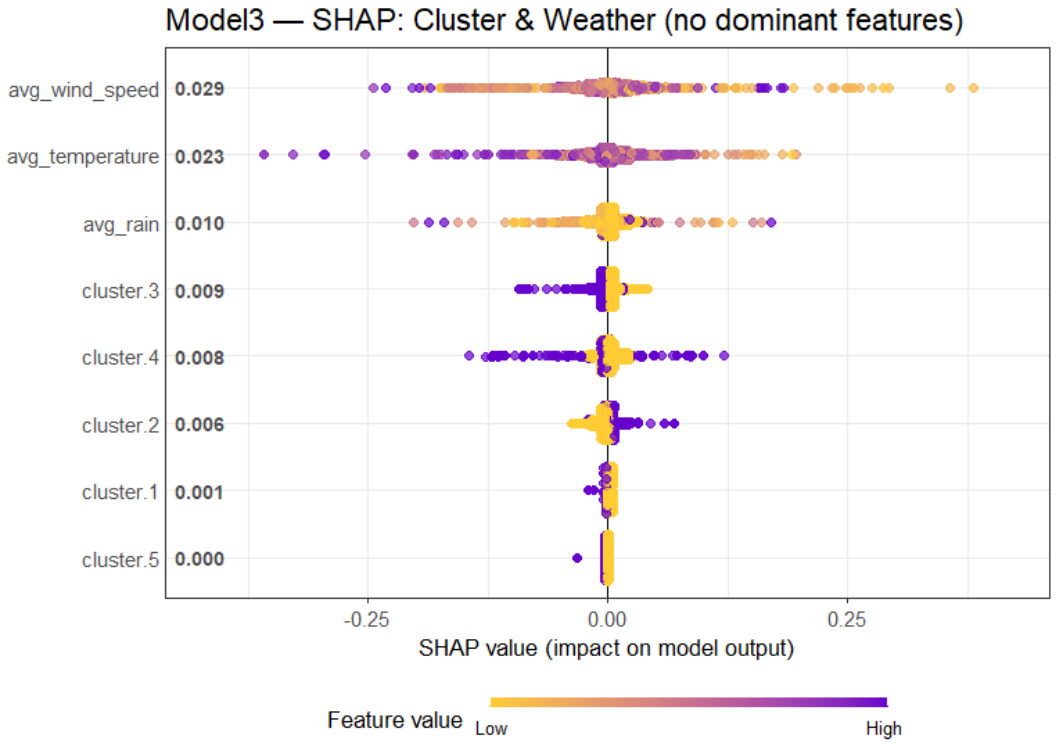
ตัวแบบหรือไม่ในกรณีที่ไม่มีปัจจัยหลัก ผู้วิจัยสร้างตัวแบบ M3 และตัวแบบ M4 โดยตัดตัวแปรที่มีอิทธิพลสูงสุด 5 อันดับแรกออก ผลการเปรียบเทียบแสดงในภาพที่ 4.12



ภาพที่ 4.12 กราฟ Boxplot เปรียบเทียบค่า CV ROC ของตัวแบบ M1–M4

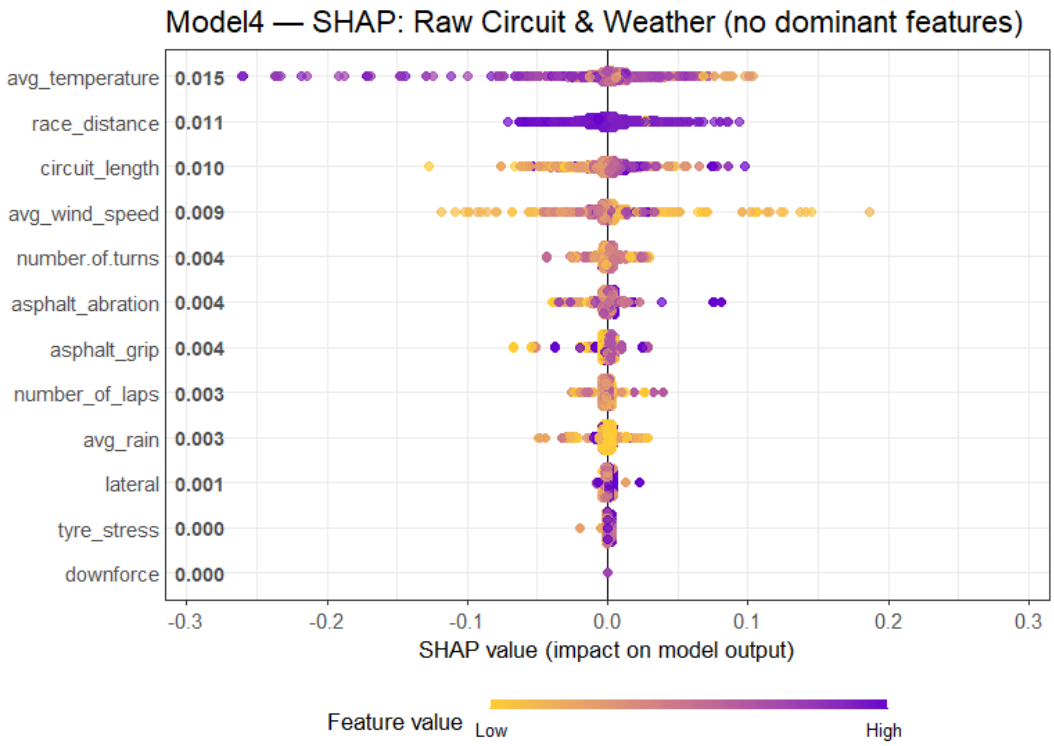
จากภาพที่ 4.12 พบว่า ตัวแบบ M1 และ M2 มีช่วงควอไทล์ระหว่าง (Interquartile Range: IQR) อยู่ในช่วง 0.82–0.86 ในขณะที่ตัวแบบ M3 และ M4 มีช่วง IQR ที่กว้างกว่าและอยู่ในระดับที่ต่ำกว่าอย่างชัดเจน โดยอยู่ประมาณ 0.76–0.81 ผลดังกล่าวสะท้อนให้เห็นว่า เมื่อมีการตัดปัจจัยหลักออกจากตัวแบบ จะส่งผลให้ประสิทธิภาพในการพยากรณ์ลดลง พร้อมทั้งเพิ่มความไม่แน่นอนของผลลัพธ์ นอกจากนี้ ยังเป็นการยืนยันว่าปัจจัยด้านตำแหน่งออกตัว และจำนวนชนะของทีมผู้ผลิต เป็นปัจจัยสำคัญหลักที่มีอิทธิพลต่อผลการแข่งขัน

เพื่อทำความเข้าใจว่าเมื่อไม่มีปัจจัยหลัก ตัวแปรใดขึ้นมามีบทบาทแทน ผู้วิจัยวิเคราะห์ SHAP ของตัวแบบ M3 และ M4 เฉพาะกลุ่มตัวแปรสนามและสภาพอากาศ ดังแสดงในภาพที่ 4.13 และ 4.14



ภาพที่ 4.13 กราฟ SHAP Beeswarm แสดงอิทธิพลของตัวแปรกลุ่มสนามและสภาพอากาศในตัวแบบ M3

จากภาพที่ 4.13 พบว่า เมื่อตัวแบบไม่มีการรวมปัจจัยหลัก ตัวแปรด้านสภาพอากาศมีอิทธิพลต่อผลลัพธ์เพิ่มขึ้นอย่างชัดเจน โดย ค่าเฉลี่ยความเร็วลมมีค่า SHAP เท่ากับ 0.029 และ ค่าเฉลี่ยอุณหภูมิมีค่า SHAP เท่ากับ 0.023 ซึ่งมีการกระจายตัวของค่า SHAP ในวงกว้าง และส่งผลทั้งในเชิงบวกและเชิงลบต่อโอกาสในการทำคะแนน นอกจากนี้ ตัวแปรการจัดกลุ่มสนาม มีระดับความสำคัญสัมพัทธ์ (relative importance) เพิ่มสูงขึ้นอย่างมีนัยสำคัญ โดยเฉพาะกลุ่มสนามที่ 3 (0.009) และกลุ่มสนามที่ 4 (0.008) ที่แสดงค่า SHAP ได้เด่นชัดมากกว่าในตัวแบบ M1 ผลการวิเคราะห์ดังกล่าวยืนยันว่า ตัวแปรที่สะท้อนลักษณะของกลุ่มสนามมีข้อมูลที่เกี่ยวข้องกับผลการแข่งขันอยู่จริง แต่ในกรณีของตัวแบบที่รวมปัจจัยหลัก ตัวแปรดังกล่าวถูกลดทอนอิทธิพลลงเนื่องจากอิทธิพลที่สูงกว่าของปัจจัยหลักในตัวแบบ



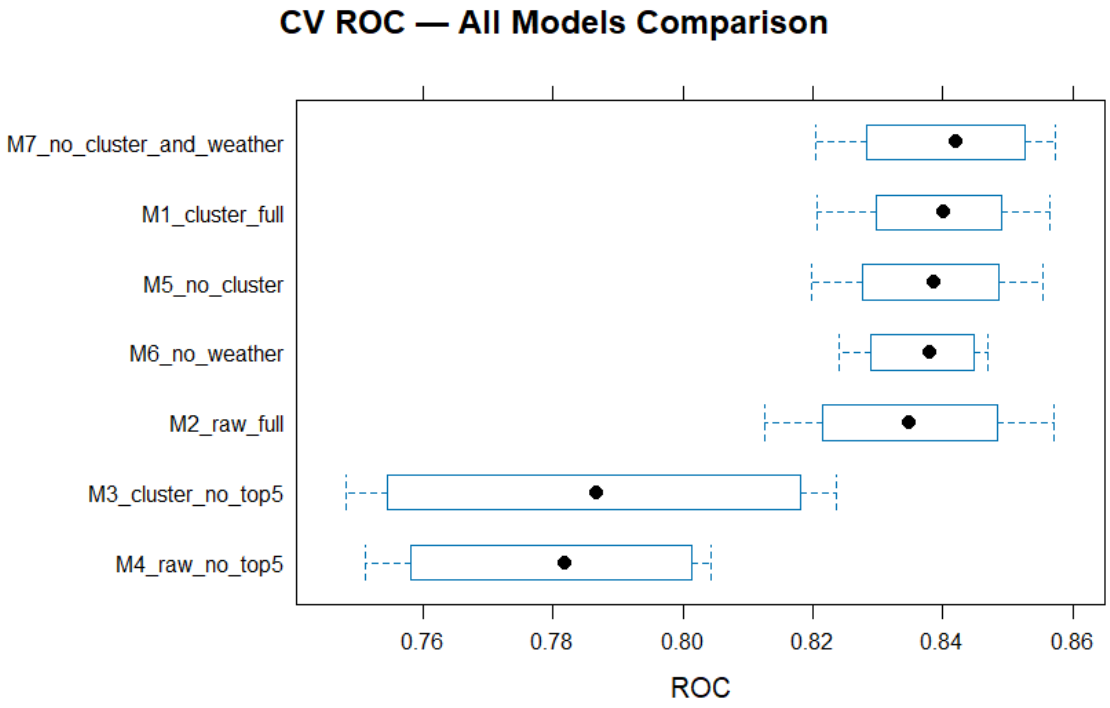
ภาพที่ 4.14 SHAP Beeswarm แสดงอิทธิพลของตัวแปรลักษณะสนามดิบและสภาพอากาศในตัวแบบ M4

จากภาพที่ 4.14 ในตัวแบบ M4 ซึ่งมีการปรับเปลี่ยนโดยใช้ตัวแปรสนามดิบแทนการใช้ค่าเฉลี่ยแบบกลุ่ม พบว่า ค่าเฉลี่ยอุณหภูมิยังคงเป็นปัจจัยที่มีค่าอิทธิพลสูงสุด (0.015) อย่างไรก็ตาม ผลการวิเคราะห์ชี้ให้เห็นการเปลี่ยนแปลงที่มีนัยสำคัญในลำดับรองลงมา ได้แก่ ระยะทางต่อรอบ(0.011) และระยะทางรวมของการแข่งขัน(0.009) ซึ่งมีค่าอิทธิพลเพิ่มขึ้นอย่างชัดเจนเมื่อเปรียบเทียบกับตัวแบบ M2 ปรากฏการณ์นี้สะท้อนให้เห็นว่า ในสภาวะที่ไม่มีปัจจัยหลักเชิงโครงสร้างเข้ามาควบคุม ปัจจัยด้านระยะทางและขนาดของสนามแข่งจะเริ่มมีบทบาทสำคัญมากขึ้นในการพยากรณ์ผลลัพธ์ ในทางตรงกันข้าม ตัวแปรด้านเทคนิคอัน ได้แก่ การสึกหรอของยาง, แรงเหวี่ยงด้านข้าง และความต้องการแรงกดอากาศ กลับมีค่าอิทธิพลอยู่ในระดับต่ำมากอย่างคงที่ในทุกสถานการณ์จำลอง ซึ่งแสดงให้เห็นว่าปัจจัยเหล่านี้ส่งผลต่อความแม่นยำของตัวแบบน้อยกว่าปัจจัยทางกายภาพของสนามและสภาพภูมิอากาศ

4.5.3 บทบาทของตัวแปรการจัดกลุ่มสนาม และสภาพอากาศ

หากผลจากการตัดปัจจัยอิทธิพลสูงออกยืนยันว่าตัวแปรสนามและอากาศมีอิทธิพลเมื่อไม่มีปัจจัยหลัก คำถามถัดไปคือ ในสถานการณ์จริงที่ปัจจัยหลักอยู่ในตัวแบบด้วย ตัวแปรเหล่านี้ยังช่วยยกระดับความแม่นยำได้อีกหรือไม่ และมากน้อยเพียงใด ผู้วิจัยจึงออกแบบตัวแบบ M5 (ตัดข้อมูลการจัดกลุ่มสนาม), ตัวแบบ M6 (ตัดข้อมูลสภาพอากาศ) และตัวแบบ M7 (ตัดข้อมูลทั้ง Clusterและสภาพอากาศ) เพื่อวัดผลกระทบของตัวแปรแต่ละกลุ่มโดยตรง

เพื่อให้ทราบถึงความสำคัญและระดับผลกระทบของตัวแปรด้านกลุ่มสนามและสภาพอากาศที่มีต่อตัวแบบ ผู้วิจัยจึงได้ดำเนินการเปรียบเทียบประสิทธิภาพระหว่างตัวแบบหลัก (M1) กับตัวแบบที่ลดทอนตัวแปรกลุ่มดังกล่าวออก เพื่อประเมินว่าปัจจัยเหล่านี้ช่วยยกระดับความแม่นยำในการพยากรณ์ได้มากน้อยเพียงใด โดยผลการเปรียบเทียบเชิงสถิติได้แสดงไว้ในภาพที่ 4.15



ภาพที่ 4.15 กราฟ Boxplot เปรียบเทียบค่า CV ROC ของตัวแบบทั้งหมด M1–M7

จากภาพที่ 4.15 พบว่าตัวแบบ M1, M5, M6 และ M7 มีลักษณะการกระจายตัวของค่าพื้นที่ใต้กราฟความน่าจะเป็น (ROC) อยู่ในระดับที่ใกล้เคียงกันอย่างมีนัยสำคัญ โดยมีช่วงค่าความแม่นยำปรากฏระหว่าง

0.82 ถึง 0.86 ทั้งนี้ ตัวแบบ M7 มีค่ามัธยฐาน (Median) สูงที่สุดเมื่อเปรียบเทียบกับตัวแบบอื่นในกลุ่มเดียวกัน ในขณะที่ตัวแบบ M3 และ M4 ยังคงมีประสิทธิภาพในการทำนายอยู่ในระดับที่ต่ำกว่าอย่างชัดเจน ซึ่งสะท้อนให้เห็นถึงความแตกต่างของขีดความสามารถในการพยากรณ์ระหว่างกลุ่มตัวแบบ

4.5.4 เปรียบเทียบประสิทธิภาพของตัวแบบบนชุดข้อมูลทดสอบปี 2024

แม้ตัวแบบทั้ง 7 รูปแบบจะผ่านการประเมินด้วย Cross-Validation บนข้อมูลปี 2019–2023 แล้ว แต่ยังต้องตรวจสอบว่าประสิทธิภาพนั้นสามารถ Generalize ไปสู่ข้อมูลจริงที่ตัวแบบไม่เคยเห็นได้หรือไม่ ผู้วิจัยจึงนำตัวแบบทั้งหมดไปทดสอบบนชุดข้อมูลฤดูกาล 2024 ซึ่งเป็นชุดข้อมูลอิสระ เพื่อยืนยันความแม่นยำในเชิงปฏิบัติและเปรียบเทียบประสิทธิภาพสุดท้ายระหว่างตัวแบบ

เมื่อนำตัวแบบทั้งหมดไปพยากรณ์บนชุดข้อมูลทดสอบปี 2024 ได้ผลลัพธ์ ดังตารางที่ 4.5

ตารางที่ 4.5 ตารางเปรียบเทียบประสิทธิภาพตัวแบบ

ตัวแบบ	AUC	Accuracy	Precision	Recall	F1-Score
M1	0.8828	0.8100	0.7749	0.8750	0.8219
M2	0.8846	0.8100	0.7790	0.8667	0.8205
M3	0.8318	0.7641	0.7471	0.8000	0.7726
M4	0.8216	0.7683	0.7841	0.7417	0.7623
M5	0.8849	0.8038	0.7704	0.8667	0.8157
M6	0.8814	0.7912	0.7536	0.8667	0.8062
M7	0.8809	0.8100	0.7790	0.8667	0.8205

จากตารางที่ 4.5 พบว่าทุกตัวแบบในกลุ่ม M1 M2 M5 M6 และ M7 มีค่า AUC อยู่ในช่วง 0.88 ซึ่งใกล้เคียงกันมาก โดยตัวแบบ M5 มีค่า AUC สูงสุด (0.8849) รองลงมาคือตัวแบบ M2 (0.8846) และ ตัวแบบ M1 (0.8828) ในขณะที่ ตัวแบบ M3 และ M4 ที่ตัดปัจจัยหลักออกมีค่า AUC ต่ำกว่าอย่างชัดเจนที่ 0.8318 และ 0.8216 ตามลำดับ และเมื่อพิจารณาตาราง CV AUC เทียบกับ Test AUC พบว่าทุกตัวแบบมี Negative Gap สม่ำเสมอ

ตารางที่ 4.6 ตารางเปรียบเทียบค่า ROC-AUC ระหว่างตัวแบบ

ตัวแบบ	CV AUC	Test AUC	Gap
M1	0.8394	0.8828	-0.0434
M2	0.8349	0.8846	-0.0498
M3	0.7863	0.8318	-0.0455
M4	0.7797	0.8216	-0.0419
M5	0.8381	0.8849	-0.0467
M6	0.8367	0.8814	-0.0446
M7	0.8404	0.8809	-0.0405

จากตารางที่ 4.6 พบว่าส่วนต่างระหว่างค่าความแม่นยำของชุดข้อมูลฝึกฝนและชุดข้อมูลทดสอบ (Gap) ปรากฏเป็นค่าติดลบอย่างสม่ำเสมอในทุกตัวแบบ ซึ่งเป็นไปในทิศทางเดียวกับข้อวิเคราะห์ในเบื้องต้นที่ว่า ชุดข้อมูลทดสอบมีรูปแบบความสัมพันธ์ที่ชัดเจนและมีตัวแปรรบกวนน้อยกว่าช่วงปีที่ใช้ฝึกฝน ปรากฏการณ์ดังกล่าวสะท้อนว่า ฤดูกาล 2024 มีรูปแบบการแข่งขันที่สามารถพยากรณ์ได้ง่ายกว่าช่วงปี 2019–2023 โดยเฉพาะในช่วงครึ่งแรกของฤดูกาลที่นักขับอย่าง แม็กซ์ เวอร์สแตปเปน และทีมเรดบูล เรซซิ่ง ยังคงครองความได้เปรียบเชิงโครงสร้างอย่างชัดเจน ส่งผลให้การกระจายตัวของคะแนนมีความสม่ำเสมอสูงกว่าช่วงปี 2021–2022 ที่มีการขับเคี่ยวกันอย่างสูสีระหว่างกลุ่มทีมผู้นำ ด้วยคุณลักษณะของข้อมูลที่ความซับซ้อนลดลงนี้เอง จึงส่งผลให้ตัวแบบที่ผ่านการประเมินอย่างเข้มงวด สามารถระบุรูปแบบและทำนายผลลัพธ์ในชุดทดสอบได้แม่นยำยิ่งขึ้นจนเกิดส่วนต่างประสิทธิภาพดังที่ปรากฏ

จากการเปรียบเทียบแบบจำลองทั้ง 7 รูปแบบ พบว่าแบบจำลองหลักสามารถพยากรณ์คะแนนนักขับได้อย่างมีประสิทธิภาพ โดยมีค่า AUC สูงสุดที่ 0.8849 ในตัวแบบ M5 ทั้งนี้ แม้ผลการวิเคราะห์อิทธิพลของตัวแปรจะบ่งชี้ว่า ปัจจัยด้านสภาพอากาศและลักษณะสนามมีค่าคะแนนความสำคัญในระดับต่ำเมื่อเปรียบเทียบกับปัจจัยพื้นฐานอื่น แต่ยังคงปรากฏแนวโน้มความสัมพันธ์เชิงกายภาพที่น่าสนใจในบางกรณีศึกษา อย่างไรก็ตาม ภายใต้ขอบเขตการวิเคราะห์ด้วยเทคนิคการเรียนรู้ของเครื่องและการใช้ค่าอิทธิพล SHAP ในงานวิจัยนี้ มุ่งเน้นการอธิบายปัจจัยในระดับภาพรวม (Global Explanation) ซึ่งประเด็นด้านปฏิสัมพันธ์เชิงลึก (Interaction Effects) และการวิเคราะห์รายกรณีสนามจะถูกนำไปร่วมอภิปรายผลและนำเสนอเป็นแนวทางสำหรับการศึกษาในลำดับถัดไป

บทที่ 5 สรุปผล อภิปรายผล และข้อเสนอแนะ

5.1 สรุปผลการวิจัย

งานวิจัยนี้มีวัตถุประสงค์ 3 ข้อ ซึ่งสามารถตอบได้ดังนี้

วัตถุประสงค์ที่ 1 จำแนกและจัดกลุ่มสนามแข่งขัน

การประยุกต์ใช้ Gower Distance ร่วมกับ Hierarchical Clustering สามารถจัดกลุ่มรายการแข่งขัน 128 รายการออกเป็น 5 กลุ่มที่มีเอกลักษณ์เฉพาะตัวได้อย่างมีประสิทธิภาพ ตั้งแต่สนามความเร็วสูงที่ยางสึกหรอหนัก (กลุ่มสนามที่ 2) ไปจนถึงสนามเฉพาะทางอย่าง สนามโมนาโก (กลุ่มสนามที่ 5) ที่แยกตัวออกมาอย่างชัดเจนจากแผนภาพDendrogram

วัตถุประสงค์ที่ 2 เปรียบเทียบตัวแบบพยากรณ์

อัลกอริทึม XGBoost ร่วมกับการใช้ตัวแปรกลุ่มสนาม M1(มีข้อมูลทั้งหมด) ให้ประสิทธิภาพสูงสุดและเสถียรที่สุด โดยมี CV AUC = 0.8394 และ Test AUC = 0.8828 การบูรณาการ Unsupervised Learning เข้ากับ Supervised Learning ช่วยลดมิติข้อมูลจาก 9 ตัวแปรสนามเหลือเพียง 1 ตัวแปร โดยไม่ลดประสิทธิภาพของตัวแบบ

วัตถุประสงค์ที่ 3 วิเคราะห์และอธิบายปัจจัยสำคัญ

ผลจาก SHAP ระบุว่าตำแหน่งออกตัว และประวัติความสำเร็จของทีมผู้ผลิต เป็นปัจจัยที่มีอิทธิพลสูงสุด โดย ตำแหน่งออกตัว มีค่า Mean |SHAP| = 0.705 ซึ่งสูงกว่าตัวแปรอื่นอย่างโดดเด่น สำหรับสภาพอากาศพบว่า ค่าเฉลี่ยความเร็วลม และ ค่าเฉลี่ยอุณหภูมิ มีอิทธิพลสูงกว่า ค่าเฉลี่ยปริมาณฝนโดย ค่าเฉลี่ยอุณหภูมิ มีค่า Mean |SHAP| สูงสุดในกลุ่มสภาพอากาศทั้งในตัวแบบ M1 และ M2 ส่วนตัวแปรกลุ่มสนามมี contribution น้อยมากเมื่อมีปัจจัยหลักอยู่ในตัวแบบ แต่มี relative importance สูงขึ้นอย่างชัดเจนเมื่อตัดปัจจัยหลักออก โดยเฉพาะ กลุ่มสนามที่ 3 และ กลุ่มสนามที่ 4 ที่ขึ้นมามีอิทธิพลวัดได้ชัดเจนในตัวแบบ M3

5.2 อภิปรายผล

1) อิทธิพลของตำแหน่งออกตัวและสมรรถนะของทีมผู้ผลิต

ผลลัพธ์จากค่าความสำคัญของตัวแปร (SHAP Value) ที่ชี้ว่าตำแหน่งออกตัว เป็นปัจจัยชี้ขาดที่มีผลต่อคะแนนสูงสุด (ดังปรากฏในภาพที่ 4.7 และ 4.8) สอดคล้องกับงานวิจัยของ van Kesteren & Bergkamp ที่พบว่าความแปรปรวนของผลการแข่งขันกว่าร้อยละ 88 เกิดจากประสิทธิภาพของทีมผู้ผลิตและเทคโนโลยีรถแข่ง โดยตำแหน่งออกตัวสะท้อนทั้งสมรรถนะของรถแข่งในรอบรอบคัดเลือก (Qualifying) และความได้เปรียบเชิงกลยุทธ์ในการรักษาตำแหน่งช่วงเริ่มการแข่งขัน โดยเฉพาะในสนาม กลุ่มสนามที่ 5 อย่างโมนาโก ที่มีการจัดกลุ่มให้เห็นว่ามีลักษณะกายภาพเฉพาะตัวสูง (ภาพที่ 4.5) ซึ่งมีลักษณะแคบและการแซงทำได้ยาก ตำแหน่งออกตัวจะทวีความสำคัญขึ้นอย่างมาก เนื่องจากนักขับที่ออกตัวหน้าสามารถรักษาตำแหน่งได้ง่ายกว่า สอดคล้องกับงานวิจัยของ de Groote (2021) ที่พบว่าอัตราการแซงในสนามโมนาโก ต่ำกว่าสนาม สนามอิสตันบูล พาร์ก ถึงเกือบ 8 เท่า

2) เหตุใดการจัดกลุ่มสนามจึงไม่แสดงความโดดเด่นในเชิงประจักษ์

แม้ว่างานวิจัยของ Choi (2025) จะยืนยันว่าลักษณะสนามส่งผลต่อสมรรถนะของทีมผู้ผลิต แต่ในบริบทของฟอร์มูล่าวัน ยุคปัจจุบัน ทีมผู้ผลิตที่แข็งแกร่งอย่าง ทีมเรดบูล เรซซิ่ง หรือทีมเมอร์เซเดส-เบนซ์ สามารถทำผลงานได้ดีในทุกประเภทสนาม ทำให้การจัดกลุ่มสนามไม่สามารถแยกแยะผลการแข่งขันได้ชัดเจนเท่ากับปัจจัยด้านทีมผู้ผลิตและนักขับ(ภาพที่ 4.7) ทั้งนี้ ผลจาก การทดสอบโดยตัดตัวแปรออกในตัวแบบM3 พบว่าเมื่อตัดปัจจัยหลักออก กลุ่มสนามที่ 3 และ กลุ่มสนามที่ 4 ขึ้นมามีค่า Mean |SHAP| ที่วัดได้ชัดเจน (0.009 และ 0.008 ตามลำดับ) (ดังแสดงในภาพที่ 4.13) ยืนยันว่าตัวแปรกลุ่มสนามมีข้อมูลที่มีประโยชน์อยู่จริง แต่ถูกบดบังโดยปัจจัยหลักในตัวแบบเต็ม

ในด้านข้อจำกัดของการวิเคราะห์ ผลที่ได้จากตัวแบบในงานวิจัยนี้เป็นการวิเคราะห์ในระดับภาพรวม ซึ่งค่า SHAP ที่คำนวณได้สะท้อนอิทธิพลเฉลี่ยของตัวแปรแต่ละตัวข้ามทุกสนามและทุกสภาวะ จึงอาจบดปฏิสัมพันธ์เฉพาะส่วนที่อาจเกิดขึ้นในบริบทเฉพาะเจาะจง เช่น ในสนามที่มีฝนตกหนักอย่างสนามสปา-ฟรองโกชองส์ หรือสนามที่มีลักษณะทางกายภาพเฉพาะตัวสูงอย่างสนามโมนาโกความสัมพันธ์ระหว่างสภาพอากาศ ลักษณะสนาม และตำแหน่งออกตัวอาจมีปฏิสัมพันธ์กันในลักษณะที่ค่า SHAP แบบแยกส่วน ไม่สามารถจับได้อย่างครบถ้วน นอกจากนี้ ค่า SHAP ในรูปแบบที่ใช้ในงานวิจัยนี้อธิบายอิทธิพลหลักของตัวแปรแต่ละตัวเป็นหลัก แต่ยังมีข้อจำกัดในการอธิบาย อิทธิพลร่วมระดับสูง (High-order Interaction) ระหว่างตัวแปรเชิงเทคนิคหลายตัวพร้อมกัน เช่น ปฏิสัมพันธ์ระหว่างอุณหภูมิผิวสนาม ประเภท

ยาง และสมรรถนะเครื่องยนต์ที่อาจส่งผลต่อผลการแข่งขันในลักษณะที่ซับซ้อนกว่าที่ตัวแบบปัจจุบันสามารถแสดงได้ การวิเคราะห์ SHAP Interaction Values หรือ Partial Dependence Plot เฉพาะกลุ่มสนามในงานวิจัยลำดับถัดไปจึงอาจเปิดเผยรูปแบบความสัมพันธ์ที่ซ่อนอยู่เหล่านี้ได้ชัดเจนยิ่งขึ้น และอีกประเด็นหนึ่งที่ควรพิจารณาประกอบการตีความผลดังกล่าวคือ ในบริบทของการแข่งขันจริง ทีมผู้ผลิตและนักขับมิได้รับอิทธิพลจากสภาพสนามและสภาพอากาศโดยตรงในลักษณะที่ตัวแบบสังเกตเห็น เนื่องจากทีมผู้ผลิตมีกระบวนการปรับตัวและชดเชยตัวแปรเหล่านี้อยู่แล้วผ่านการวางกลยุทธ์เข้าจุดพัก และการเลือกชนิดของคอมปาวด์ยางให้เหมาะสมกับอุณหภูมิผิวสนามและระดับการสึกหรอที่คาดการณ์ไว้ล่วงหน้า กล่าวได้ว่าค่า SHAP ที่ปรากฏในงานวิจัยนี้สะท้อนอิทธิพลของสนามและอากาศในสถานะที่ทีมผู้ผลิตได้ปรับกลยุทธ์รับมือไปแล้ว มิใช่สถานะก่อนการปรับตัว ดังนั้นการที่ตัวแปรกลุ่มนี้ดูมีอิทธิพลน้อยในตัวแบบจึงอาจสะท้อนความสามารถในการปรับตัวของทีมระดับฟอร์มูล่าวัน มากกว่าที่จะสื่อว่าสนามและอากาศไม่มีนัยสำคัญต่อผลการแข่งขันจริง

เพื่อตรวจสอบว่าปัจจัยที่มีอิทธิพลต่อผลการแข่งขันแตกต่างกันตามลักษณะสนามหรือไม่ งานวิจัยนี้ได้สร้างตัวแบบแยกสำหรับแต่ละกลุ่มสนาม โดยวิเคราะห์ได้เพียง 4 กลุ่มแรก เนื่องจากกลุ่มสนามที่ 5 ซึ่งประกอบด้วยสนามโมนาโกเพียงสนามเดียวมีข้อมูลไม่เพียงพอต่อการสร้างตัวแบบที่เชื่อถือได้ ผลที่ได้แสดงให้เห็นว่าตัวแบบรายกลุ่มสนามยังคงสามารถทำนายได้ดี โดยมีค่า AUC เกิน 0.75 ในทุกกลุ่ม และตัวแปรสำคัญอย่างตำแหน่งออกตัวและประวัติความสำเร็จของทีมผู้ผลิตยังคงเป็นปัจจัยหลักที่สอดคล้องกับตัวแบบภาพรวม แม้จะตัดตัวแปร Nationality ออกไปแล้วก็ตาม

นอกจากนี้ เมื่อวิเคราะห์รายกลุ่มสนามพบรูปแบบที่น่าสนใจซึ่งตัวแบบภาพรวมไม่สามารถเปิดเผยได้ กล่าวคือ ตำแหน่งออกตัวในกลุ่มสนามที่ 4 มีค่า Mean |SHAP| สูงถึง 0.935 ซึ่งสูงกว่าตัวแบบภาพรวมอย่างเห็นได้ชัด บ่งชี้ว่าในกลุ่มสนามนี้การได้ตำแหน่งออกตัวที่ดีตั้งแต่ต้นมีความสำคัญต่อการได้คะแนนมากเป็นพิเศษ ซึ่งสอดคล้องกับลักษณะทางกายภาพของสนามในกลุ่มนี้ อาทิ สนามเรดบูลริง และ สนามฮังการอริง ที่เป็นที่รู้จักในแวดวง Formula 1 ว่าเป็นสนามที่การแซงทำได้ยาก ดังนั้นนักขับที่สามารถออกตัวในตำแหน่งดีจึงมีโอกาสรักษาตำแหน่งและได้คะแนนได้ง่ายกว่าอย่างมีนัยสำคัญ ผลดังกล่าวยืนยันว่าการวิเคราะห์รายกลุ่มสนามสามารถเปิดเผยมิติของความสำคัญของตัวแปรที่ซ่อนอยู่ในตัวแบบภาพรวมได้ และเป็นแนวทางที่ควรดำเนินการต่อในงานวิจัยลำดับถัดไป

3) ปรากฏการณ์ Negative Gap

Negative Gap ที่สม่ำเสมอในทุกตัวแบบตั้งแต่โมเดล M1 ถึง M7 (ช่วง -0.0405 ถึง -0.0498) (ดังปรากฏในภาพที่ 4.12)ไม่ได้เกิดจาก Overfitting ของตัวแบบใดตัวแบบหนึ่ง เนื่องจากหากเป็น Overfitting จะพบ Gap เฉพาะในตัวแบบที่ซับซ้อนเท่านั้น แต่การที่ Gap ปรากฏสม่ำเสมอแม้แต่ในตัวแบบ M3 และ M4 ที่ตัดตัวแปรออกไปมากแล้ว สะท้อนว่าเกิดจากการที่ชุดข้อมูลมีรูปแบบที่เปลี่ยนไปการเปลี่ยนแปลงการกระจายตัวของข้อมูลระหว่างชุดฝึก (2019–2023) และชุดทดสอบ (2024)

โดยในฤดูกาล 2024 แม็กซ์ เวอร์สแตปเปน และ ทีมเรดบูล เรซซิ่ง ยังคงครองความได้เปรียบอย่างชัดเจนในช่วงครึ่งแรกของฤดูกาล ทำให้รูปแบบการกระจายตัวของคะแนนมีความสม่ำเสมอและคาดเดาได้ง่ายกว่าช่วงปี 2021–2022 ที่มีการแข่งขันสูสีระหว่าง ทีมเรดบูล เรซซิ่ง, ทีมเฟอร์รารี และ ทีมเมอร์เซเดส-เบนซ์ อย่างเข้มข้น ส่งผลให้ตัวแบบที่เรียนรู้ความซับซ้อนจากข้อมูลในอดีตสามารถพยากรณ์ชุดข้อมูลปี 2024 ที่มีรูปแบบชัดเจนกว่าได้อย่างแม่นยำสูง (Hastie et al., 2009; James et al., 2023)

5.3 ข้อจำกัดของงานวิจัย

1. ข้อมูลสภาพอากาศที่ใช้เป็นค่าเฉลี่ยรายชั่วโมง ไม่ใช่ข้อมูลรายรอบการแข่งขัน ทำให้อาจสูญเสียรายละเอียดของการเปลี่ยนแปลงสภาพอากาศระหว่างการแข่งขันซึ่งส่งผลต่อกลยุทธ์การเลือกยางและการเข้าจุดพักได้อย่างมีนัยสำคัญ

2. ตัวแบบไม่ได้รวมข้อมูล เซฟตี้คาร์ (Safety Car) และธงแดง (Red Flag) ซึ่งส่งผลต่อผลการแข่งขันอย่างมีนัยสำคัญในหลายรายการ เช่น กรณีที่ เซฟตี้คาร์ออกในช่วงท้ายการแข่งขันอาจพลิกผลการแข่งขันได้อย่างสิ้นเชิง

3. การจัดกลุ่มสนามอ้างอิงจาก Pirelli Rating ที่มีลักษณะเป็น Ordinal Scale ซึ่งอาจมี subjectivity ในการกำหนดระดับ และอาจเปลี่ยนแปลงได้ตามการตัดสินใจของ Pirelli ในแต่ละฤดูกาล

5.4 ข้อเสนอแนะสำหรับการวิจัยในอนาคต

1. เพิ่มข้อมูล ส่วนต่างเวลาในรอบคัดเลือก (Qualifying Gap) เพื่อวัดความต่างของความเร็วรถระหว่างทีมในแต่ละสนามอย่างละเอียด ซึ่งจะช่วยให้ตัวแบบสามารถแยกแยะศักยภาพของรถออกจากทักษะของนักขับได้ชัดเจนขึ้น

2. พิจารณาเพิ่มข้อมูล เซฟตี้คาร์ และธงแดง เป็นตัวแปรอิสระ เพื่อให้ตัวแบบสามารถจับความผันผวนของผลการแข่งขันที่เกิดจากเหตุการณ์ฉุกเฉินได้ดียิ่งขึ้น

3. ทดลองใช้ LSTM หรือ ตัวแบบที่คำนึงถึงลำดับเวลา (Time-aware Model) เพื่อจับ ทิศทางและแรงส่ง (Momentum) ของนักขับและทีมผู้ผลิตที่เปลี่ยนแปลงตลอดฤดูกาลได้ดียิ่งขึ้น เนื่องจากตัวแบบปัจจุบันใช้ข้อมูลสะสมแบบ ภาพรวม ณ จุดเวลาใดเวลาหนึ่ง (Snapshot) ซึ่งอาจไม่สามารถจับรูปแบบการเปลี่ยนแปลงระยะสั้นได้อย่างเต็มประสิทธิภาพ

4. ควรดำเนินการวิเคราะห์เชิงลึกรายสถานการณ์ โดยแยกชุดข้อมูลออกตามลักษณะเฉพาะของสนามหรือสภาวะการแข่งขัน เช่น การสร้างตัวแบบเฉพาะสำหรับสนามที่มีฝนตกในช่วงการแข่งขัน หรือการวิเคราะห์เฉพาะสนามในกลุ่มที่ 5 ที่มีลักษณะทางกายภาพเฉพาะตัวสูง วิธีการนี้จะช่วยเปิดเผยปฏิสัมพันธ์เฉพาะส่วน ระหว่างสภาพอากาศ ลักษณะสนาม และปัจจัยเชิงกลยุทธ์ที่ตัวแบบระดับภาพรวมไม่สามารถจับได้ ทั้งนี้ในกรณีที่ค่า SHAP Beeswarm แสดงการกระจายตัวของสีที่ไม่ชัดเจนหรือมีการ Blend กันระหว่างค่าสูงและค่าต่ำ ควรวิเคราะห์เพิ่มเติมด้วย SHAP Interaction Values เพื่อแยกแยะว่าอิทธิพลของตัวแปรนั้นเกิดจาก Main Effect หรือเป็นผลมาจากปฏิสัมพันธ์กับตัวแปรอื่น (ทินรัตน์ อารมย์สุข, 2565)

5. ควรพิจารณาบูรณาการข้อมูลสภาพอากาศแบบ ตามเวลาจริง (Real-time) หรือข้อมูลจาก อุปกรณ์ตรวจจับ (Sensor) บนตัวรถ เช่น อุณหภูมิยาง แรงกด และอัตราการสึกหรอ แทนการใช้ค่าเฉลี่ยรายชั่วโมงจาก ระบบเชื่อมต่อข้อมูล (API) เพื่อให้สามารถสะท้อน อิทธิพลร่วม (Interaction Effect) ระหว่างสภาพแวดล้อมและสมรรถนะทางเทคนิคได้อย่างละเอียดและแม่นยำยิ่งขึ้น

6. ควรพิจารณาเปลี่ยนจุดโฟกัสของการพยากรณ์จากผลลัพธ์ภาพรวมของฤดูกาลมาสู่การพยากรณ์ผลลัพธ์ภายใต้สภาวะวิกฤต โดยเฉพาะสนามที่มีสภาพอากาศแปรปรวนรุนแรงหรือสนามที่มีอัตราการออกรถนิรภัย และ ธงแดง สูง นอกจากนี้ ควรพิจารณาเพิ่มตัวแปรด้านกลยุทธ์การแข่งขัน ได้แก่ ข้อมูลกลยุทธ์การเข้าจุดพัก เช่น จำนวนครั้งและช่วงรอบที่เข้าจุดพัก รวมถึงข้อมูลการเลือกใช้ยาง เข้าสู่ตัวแบบ เนื่องจาก

ตัวแปรเหล่านี้ทำหน้าที่เป็นกลไกที่ทีมผู้ผลิตใช้ตอบสนองต่อสภาพสนามและสภาพอากาศในสนามจริง การรวมข้อมูลดังกล่าวจะช่วยให้ตัวแบบสามารถจับความสัมพันธ์ระหว่างสภาพแวดล้อมและผลการแข่งขันได้อย่างสมบูรณ์ยิ่งขึ้น และอาจเปิดเผยได้ว่าอิทธิพลของสนามและอากาศที่ดูเล็กน้อยในตัวแบบปัจจุบันนั้นแท้จริงแล้วถ่ายทอดผ่านตัวแปรกลยุทธ์เหล่านี้อยู่โดยปริยาย

เอกสารอ้างอิง

ทินรัตน์ อารมย์สุข. (2565). **การตีความตัวแบบการเรียนรู้ของเครื่องด้วย SHAP (Shapley Additive Explanations): กรณีศึกษาตัวแบบการจำแนกและตัวแบบการถดถอย** [**วิทยานิพนธ์ปริญญามหาบัณฑิต, มหาวิทยาลัยธรรมศาสตร์**]. TU Digital Collections. https://ethesisarchive.library.tu.ac.th/thesis/2022/TU_2022_6523147012_16321_28017.pdf

Bergmeir, C., & Benítez, J. M. (2012). **On the use of cross-validation for time series predictor evaluation**. Information Sciences, 191, 192–213. https://doi.org/10.1016/j.ins.2011.12.028

Chen, T., & Guestrin, C. (2016). **XGBoost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining** (pp. 785–794). ACM. https://dl.acm.org/doi/pdf/10.1145/2939672.2939785

Chiu, N. (2021). **The real reason why F1 struggles to race in torrential rain conditions**. RacingNews365. https://racingnews365.com/the-real-reason-why-f1-struggles-to-race-in-torrential-rain-conditions

Choi, P. (2025). **Examining the correlation between circuit demands and performance gaps between F1 constructors**. ResearchGate. https://www.researchgate.net/figure/Bar-graph-representing-the-number-of-points-each-constructor-earned-on-high-speed-circuits_fig1_387914601

Daly, N. M. (2019). **Formula One and weather impacts on race performance [Master's thesis, National College of Ireland]**. NORMA. https://norma.ncirl.ie/6920/1/niamhmarydaly.pdf

de Groote, J. (2021). **Overtaking in Formula 1 during the Pirelli era: A driver-level analysis**. Journal of Sports Analytics, 7(4), 233–246. https://journals.sagepub.com/doi/epub/10.3233/JSA-200466

El Haber, E., Sawaya, E., Attieh, M., Tannous, A., Ghazaly, W., & Owayjan, M. (2021). **Formula 1 race winner prediction using Random Forest and SHAP analysis**. HAL Open Science. https://hal.science/hal-05148972/document

Formula 1. (2023a). **Beginner's guide to F1**. https://www.formula1.com/en/latest/article/beginners-guide-to-f1.1fY8HvHkICzpj6s353iw82

Formula 1. (2023b). **The 10 greatest innovations F1 has given the world**. https://www.formula1.com/en/latest/article/the-10-greatest-innovations-f1-has-given-the-world.1fY8HvHkICzpj6s353iw82

García Tejada, L. (2023). **Applying machine learning to forecast Formula 1 race outcomes** [Master's thesis, Aalto University]. Aaltodoc. https://aaltodoc.aalto.fi/server/api/core/bitstreams/70d5a580-c282-4278-8462-94d061471546/content

Gower, J. C. (1971). **A general coefficient of similarity and some of its properties. Biometrics**, 27(4), 857–871. https://doi.org/10.2307/2528823

Hastie, T., Tibshirani, R., & Friedman, J. (2009). **The elements of statistical learning: Data mining, inference, and prediction (2nd ed.). Springer Science & Business Media**.

Hyndman, R. J., & Athanasopoulos, G. (2018). Forecasting: Principles and practice (2nd ed.). OTexts. https://otexts.com/fpp2/

Kaufman, L., & Rousseeuw, P. J. (1990). **Finding groups in data: An introduction to cluster analysis**. John Wiley & Sons.

Kuhn, M., & Johnson, K. (2013). **Applied predictive modeling. Springer**.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2023). **An introduction to statistical learning: With applications in R (2nd ed.)**. Springer. https://hastie.su.domains/ISLR2/ISLRv2_corrected_June_2023.pdf

Jolliffe, I. T., & Cadima, J. (2016). **Principal component analysis: A review and recent developments. Philosophical Transactions of the Royal Society A: Mathematical**, Physical and Engineering Sciences, 374(2065), 20150202. https://royalsocietypublishing.org/doi/pdf/10.1098/rsta.2015.0202

Lundberg, S. M., & Lee, S. I. (2017). **A unified approach to interpreting model predictions**. In Advances in Neural Information Processing Systems 30 (pp. 4765–4774). https://proceedings.neurips.cc/paper/2017/file/8a20a8621978632d76c43dfd28b67767-Paper.pdf

Mitchell, T. M. (1997). **Machine Learning**. McGraw-Hill. https://www.cs.cmu.edu/~tom/files/Machine_Learning_TomMitchell.pdf

Pandey, D., Niwaria, K., & Chourasia, B. (2020). **Machine learning algorithms: A review**. International Journal of Computer Applications, 175(14), 1–6. https://d1wqtxts1xzle7.cloudfront.net/59817925/IRJET-V6I217620190621-73452-h5pwu7-libre.pdf

Rane, R. (2025). **Predicting Formula 1 race outcomes: Decomposing the roles of drivers and constructors through linear modeling**. arXiv. https://arxiv.org/pdf/2508.00200

Rockerbie, D. (2021). **Separating and conjoining the car and driver in F1 racing** (MPRA Paper No. 109053). Munich Personal RePEc Archive. https://mpra.ub.uni-muenchen.de/109053/

Rousseeuw, P. J. (1987). **Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics**, 20, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

van Kesteren, B., & Bergkamp, T. (2022). **Bayesian analysis of Formula One race results: Disentangling driver skill and constructor advantage**. arXiv. https://arxiv.org/pdf/2203.08489

Williams Racing. (2023). **How fast can an F1 car go?**. https://www.williamsf1.com/posts/253b1dc5-aee9-4d3b-b720-8e30f3a83093/how-fast-can-an-f1-car-go

Zhao, Z. (2024). **Deep Neural Network-based lap time forecasting of Formula 1 racing**. Proceedings of ACE. https://direct.ewa.pub/proceedings/ace/article/view/10867